DISPENSA UNIVERSITARIA

Modellistica e simulazione dei processi di produzione discreti

Sistemi, automi, processi stocastici,
catene di Markov, code e reti

Materiale di riferimento: lezioni del prof. Paolo Salaris
Università di Pisa

Elaborazione didattica e revisione matematica
21 ottobre 2026

Come usare questa dispensa

Il percorso segue le nove unità documentali fornite, nell'ordine delle lezioni: nove PDF per 407 pagine. Lo scopo è ricostruire il ragionamento che conduce dalle scelte di modellazione ai risultati prestazionali. Le pagine citate sono sempre quelle del PDF, contando la copertina come pagina 1; non si attribuiscono numeri di slide non leggibili sull'originale.

Il **livello A** identifica modelli, convenzioni, esempi e risultati delle lezioni. Il **livello B** comprende la prosa esplicativa e le derivazioni ricostruite in questa dispensa: non sono testi attribuiti al docente. Le integrazioni bibliografiche sostanziali sono indicate come **livello C**. Le note tecniche riportano la formulazione problematica della fonte, la motivazione del dubbio e la correzione, con il suo grado di certezza. Le correzioni non vanno confuse con nuove convenzioni del corso.

Gli strumenti richiesti sono analisi, algebra lineare, equazioni differenziali e probabilità di base. Una lettura utile procede dalle ipotesi verso le equazioni, controllando poi unità di misura, condizioni di validità e casi limite. Un risultato di equilibrio non può essere applicato prima di averne verificato l'esistenza.

La distribuzione di probabilità sarà normalmente il vettore **riga** Π; p_{ij} indica una transizione dal corrente i al futuro j. Per una coda X include i clienti in servizio, mentre X_Q conta solo quelli in attesa. La capacità K, nei modelli del capitolo 8, è il numero massimo di clienti **complessivamente presenti**. I tassi λ e μ hanno dimensione inversa del tempo. Il simbolo ρ è adimensionale, ma cambia interpretazione fra nodo aperto, nodo con molti serventi e rete chiusa: il contesto viene ogni volta precisato.

I registri allegati consentono di risalire da ciascuna pagina alla sezione pertinente e da ogni gruppo di equazioni numerate al sorgente. Le relazioni ripetute sono accorpate; il censimento riguarda relazioni o gruppi, non il numero di simboli uguaglianza. I frontespizi e le riprese senza nuovi contenuti sono tracciati senza riprodurre elementi ornamentali.

Indice

1 Sistemi e modelli 5
1.1 Sistema e finalità del modello 5
1.2 Memoria, stato e forma di stato 5
1.3 Circuiti, serbatoio e pendolo 7
1.4 Classificazione dei modelli 9
1.5 Sistemi ad eventi discreti 10
1.6 Code, reti e calcolatori 10
1.7 Produzione, blocking e controllo 11
1.8 Comunicazione e traffico 12
2 Linguaggi e automi 14
2.1 Alfabeti, stringhe e linguaggi 14
2.2 Automi deterministici e linguaggi generati 14
2.3 Esempi di riconoscimento e servizio 15
2.4 Regolarità ed espressioni regolari 17
2.5 Equivalenza e minimizzazione 18
2.6 Automi con uscita e trasmettitore 19
2.7 Composizione di trasmettitori 20
2.8 Filosofi e risorse condivise 21
3 Sistemi ad eventi discreti temporizzati 23
3.1 Tempo, clock, durata, residuo ed età 23
3.2 Automa temporizzato e ricorsione dei clock 24
3.3 Simulazione di una coda 25
3.4 Calendario degli eventi 25
3.5 Esercizio e controllo della soluzione 26
4 Processi stocastici e memoria 27
4.1 Processi, realizzazioni e distribuzioni 27
4.2 Stazionarietà e indipendenza 27
4.3 Proprietà di Markov e processi semi-Markov 28
4.4 Memoria e ampliamento dello stato 29
5 GSMP e processi di Poisson 31
5.1 Clock stocastici e GSMP 31
5.2 Esempi e contatori 31
5.3 Definizione del processo di Poisson 32
5.4 Legge di conteggio e momenti 33
5.5 Tempi esponenziali e assenza di memoria 34
5.6 Sovrapposizione e competizione 34
5.7 Code e riduzione markoviana 35
6 Catene di Markov a tempo discreto 37
6.1 Specifica di una catena e primi esempi 37
6.2 Chapman–Kolmogorov e omogeneità 38
6.3 Permanenza e distribuzioni di stato 38
6.4 Analisi transitoria: roulette e processori 39
6.5 Raggiungibilità e classi 40
6.6 Ricorrenza e passeggiata riflessa 40
6.7 Periodicità 42
6.8 Distribuzioni invarianti e limite 43
7 Catene di Markov a tempo continuo 45
7.1 Transizioni, generatore ed equazioni differenziali 45
7.2 Permanenza e significato dei tassi 45
7.3 Assemblaggio e analisi transitoria 46

7.4 Flussi ed equilibrio 47
7.5 Nascita e morte 48
7.6 Nascita pura e Poisson 48
7.7 Equilibrio di nascita e morte 49
7.8 Uniformizzazione 49
8 Teoria delle code 51
8.1 Struttura, notazione e prestazioni 51
8.2 Utilizzazione, ricorrenze e attesa 52
8.3 Legge di Little 53
8.4 Coda M/M/1 e dimensionamento 54
8.5 Coda M/M/m ed Erlang C 55
8.6 Infiniti serventi 56
8.7 Capacità finita M/M/1/K 56
8.8 Perdita pura ed Erlang B 58
8.9 Popolazione finita e terminali 58
8.10 Modello M/M/m/K/N 60
9 Reti di code 61
9.1 Reti aperte, chiuse e stato congiunto 61
9.2 Teorema di Burke 61
9.3 Equazioni di traffico e tandem 62
9.4 Feedback e teorema di Jackson 63
9.5 Dimensionamento del routing 65
9.6 Reti chiuse e Gordon–Newell 66
9.7 Esempio chiuso a tre nodi 67
Fonti e tracciabilità 69

1 Sistemi e modelli

1.1 Sistema e finalità del modello

Fonte A: documento 0, pagine PDF 1–2.

Un sistema è un insieme di componenti che interagiscono per realizzare una funzione complessiva. La definizione non richiede componenti soltanto fisici: un'organizzazione, una rete informatica o un processo produttivo rientrano nella stessa prospettiva. Il modello matematico è un'astrazione selettiva. Deve rappresentare ciò che serve a descrivere il comportamento, riprodurlo mediante simulazione, valutarne le prestazioni o progettare un controllo.

Il primo atto di modellazione è scegliere il confine del sistema. Le grandezze determinate dall'esterno diventano ingressi u; quelle misurate o di interesse diventano uscite y. Non tutte le variabili interne devono essere conservate. Una scelta è adeguata quando mantiene le informazioni necessarie alle domande poste, alle scale temporali e alle condizioni operative considerate. Due modelli dello stesso oggetto possono essere entrambi corretti e rispondere a domande differenti.

Scrivere $y = g(u)$ esprime un legame ingresso–uscita, ma non implica che il sistema sia privo di memoria: in un modello dinamico g è, in generale, un operatore sull'intera storia dell'ingresso e sulla condizione iniziale. Una relazione algebrica istantanea è una specializzazione. Questa distinzione prepara il concetto di stato, che comprime la storia rilevante in un insieme di variabili disponibili nell'istante corrente.

1.2 Memoria, stato e forma di stato

Fonte A: documento 0, pagine PDF 3–8.

Nel partitore resistivo delle lezioni, due resistenze r e R sono in serie a una sorgente di tensione V. La corrente è comune e la tensione d'uscita è misurata ai capi di R. Per resistenze positive, la legge di Ohm e il bilancio delle tensioni danno

$$i = \frac{V}{R + r}, \quad v = Ri = V\frac{R}{R + r}. \tag{1}$$

Le unità sono ampere per i, volt per v, V, ohm per R, r. Se r e R sono parametri costanti, si può scegliere $u = V$, $y = v$. Se la sorgente è fissata e si manipola r, l'ingresso può essere r e l'uscita ancora v. Con ingresso vettoriale (V, r) si può invece richiedere $y = i$. Il circuito non cambia; cambia la relazione da studiare. Essa è lineare rispetto a V con resistenze fissate, ma non rispetto a r.

Un sistema **statico** associa l'uscita corrente all'ingresso corrente. Un sistema **dinamico** conserva memoria. La massa collegata a una molla e a uno smorzatore viscoso mostra perché la sola uscita non basta. Indicando con p lo spostamento, $v = \dot{p}$ la velocità, $a = \dot{v}$ l'accelerazione e con F la forza applicata, il bilancio lungo l'asse del moto è

$$m\ddot{p}(t) + b\dot{p}(t) + kp(t) = F(t), \quad y(t) = p(t). \tag{2}$$

Il segno dei termini resistenti segue dalla scelta positiva dello spostamento: la molla esercita $-kp$ e lo smorzatore $-bv$. Le dimensioni sono $[m] = \mathrm{kg}$, $[b] = \mathrm{N\ s/m}$, $[k] = \mathrm{N/m}$, così ogni addendo è una forza. Sapere che $p(t_1) = 0$ non consente di prevedere il moto successivo: la massa potrebbe essere ferma oppure attraversare l'origine con velocità non nulla. Serve anche $v(t_1)$.

La figura riprende il sistema e la risposta a un impulso rettangolare di forza. Il grafico superiore ha in ordinata la forza in newton; quello inferiore lo spostamento in metri. Le oscillazioni dopo ogni variazione dell'ingresso sono il segno della memoria dinamica, non di una dipendenza istantanea dalla forza.

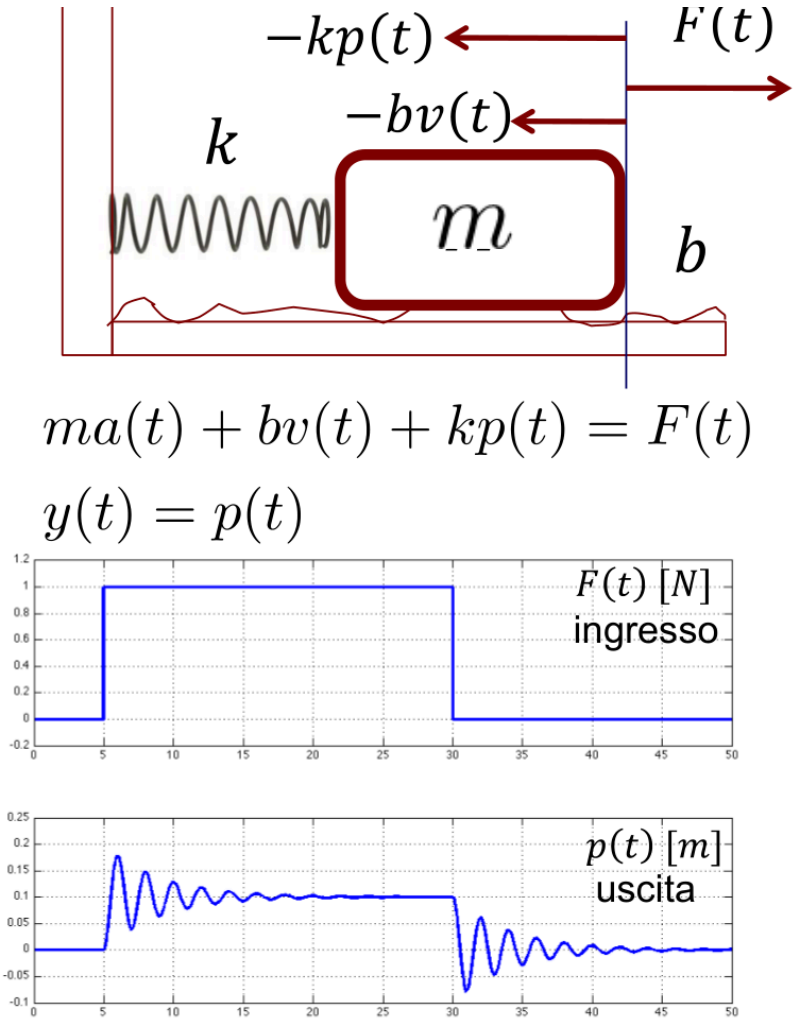


Figura 1: Sistema massa–molla–attrito e risposta temporale. Ritaglio del documento 0, pagina 3.

Lo **stato** $x(t_0)$ è l'informazione che, insieme all'ingresso futuro, determina univocamente l'evoluzione futura nel modello deterministico. Lo spazio di stato $\mathcal{X}$ raccoglie i valori ammissibili. La forma generale delle lezioni è

$$\dot{\boldsymbol{x}}(t) = \boldsymbol{f}(\boldsymbol{x}(t), \boldsymbol{u}(t), t), \quad \boldsymbol{x}(t_0) = \boldsymbol{x}_0, \quad \boldsymbol{y}(t) = \boldsymbol{g}(\boldsymbol{x}(t), \boldsymbol{u}(t), t). \tag{3}$$

La definizione presuppone un problema di evoluzione ben posto. Non rende automaticamente legittima qualunque scelta di variabili: occorre verificare che due storie con lo stesso stato e lo stesso ingresso futuro non producano futuri differenti. Per la massa una scelta naturale è $x = (p, v)^T$, che trasforma un'equazione del secondo ordine in due del primo:

$$\dot{\boldsymbol{x}} = \begin{pmatrix} 0 & 1 \\ -\frac{k}{m} & -\frac{b}{m} \end{pmatrix} \boldsymbol{x} + \begin{pmatrix} 0 \\ \frac{1}{m} \end{pmatrix} F, \quad y = (1 \;\; 0)\boldsymbol{x}. \tag{4}$$

La matrice di stato è 2×2, l'ingresso 2×1 e la matrice d'uscita 1×2. La realizzazione conserva la stessa fisica dell'equazione iniziale. Lo stato non coincide necessariamente con l'uscita e non è unico: un cambio invertibile di coordinate conserva l'informazione.

Anche un condensatore introduce memoria. Nel circuito con C in serie alle resistenze $r + R$, indicando con v_C la tensione del condensatore,

$$i = C\dot{v}_C, \quad V = v_C + (R + r)i, \quad \dot{v}_C = \frac{V - v_C}{(R + r)C}, \quad v = Ri = \frac{R}{R + r}(V - v_C). \tag{5}$$

Una tensione iniziale $v_C(t_0)$ diversa modifica l'uscita anche a parità di ingresso futuro. La costante di tempo $(R + r)C$ ha unità di secondi. Una relazione differenziale, anziché puramente algebrica, è quindi necessaria.

> **Nota tecnica A01.** Nel documento 0, pagina 5, il modello a coefficienti variabili mostra $m(t)a(t) + b(t)v(t) + K(t) = F(t)$. Il termine elastico richiede la dipendenza dallo spostamento: con K inteso come rigidezza la forma coerente è $k(t)p(t)$. È una correzione dimensionale certa rispetto a questa interpretazione. Se varia realmente la massa, la legge fisica può inoltre richiedere un bilancio della quantità di moto con flussi di massa: sostituire soltanto m con $m(t)$ è un modello fenomenologico, non una derivazione generale.

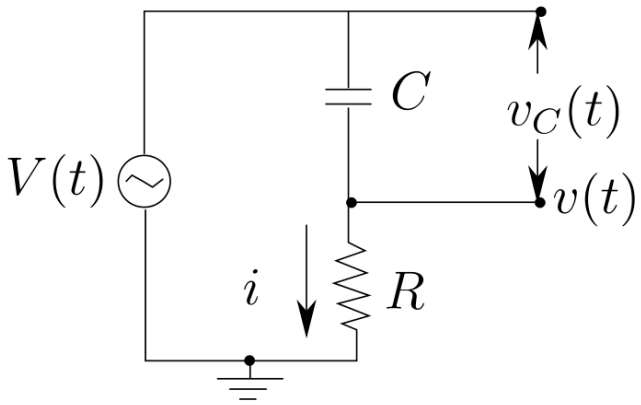
1.3 Circuiti, serbatoio e pendolo

Fonte A: documento 0, pagine PDF 9–11.

Per il circuito privo di r, lo stato è $x = v_C$, l'ingresso $u = V$ e l'uscita è la tensione sulla resistenza. Il bilancio precedente si riduce a

$$\dot{x} = \frac{V - x}{RC}, \quad y = V - x, \quad x(t_0) = v_{C,0}. \tag{6}$$

La tensione non è qui misurata sul condensatore: confondere l'uscita con lo stato invertirebbe il significato della risposta. Per un ingresso costante V_0, la derivazione ricostruita integra l'equazione lineare: $x(t) = V_0 + (x(t_0) - V_0)e^{-\frac{t-t_0}{RC}}$. Il condensatore tende alla tensione di alimentazione e l'uscita sulla resistenza tende a zero.



$$\boldsymbol{u}(t) = V(t) \rightarrow \text{Ingresso}$$
$$\boldsymbol{y}(t) = v(t) \rightarrow \text{Uscita}$$
$$\boldsymbol{x}(t) = v_C(t) \rightarrow \text{Stato}$$

$$i = C\dot{v}_C, \qquad v = iR,$$
$$V = v + v_C$$

$$\dot{x}(t) = \frac{1}{RC}(V(t) - x(t))$$
$$y(t) = V(t) - x(t);$$

Figura 2: Circuito R C e scelta di ingresso, uscita e stato. Documento 0, pagina 9.

Nel serbatoio lo stato è il livello x, compreso tra fondo 0 e capacità K. Le portate in ingresso e in uscita sono $\lambda(t)$ e $\mu(t)$. Le equazioni delle lezioni adottano implicitamente area unitaria, oppure portate già convertite in velocità di livello. Con area costante A, il bilancio fisico è $A\dot{x} = q_{\text{in}} - q_{\text{out}}$ ponendo $\lambda = \frac{q_{\text{in}}}{A}$ e $\mu = \frac{q_{\text{out}}}{A}$ si ottiene

$$\dot{x} = \begin{cases} 0 & \text{se } x = 0 \ \text{ e } \ \lambda \le \mu \\ 0 & \text{se } x = K \ \text{ e } \ \lambda \ge \mu, \\ \lambda - \mu & \text{altrimenti} \end{cases} \quad \mathcal{X} = [0, K], \quad y = x. \tag{7}$$

Ai bordi il bilancio libero potrebbe richiedere un livello negativo o superiore alla capacità. Il modello satura: in basso l'uscita effettiva non supera il liquido disponibile; in alto l'eccesso viene perso per traboccamento. La non linearità deriva dai vincoli anche quando le portate sono assegnate.

L'esempio usa $\mu = 1$, $K = 2$, $x(0) = 0$ e ingresso uguale a 3 fino a $t = 2$, zero fino a $t = 3$, quindi 1. Prima del riempimento la derivata è 2, quindi si raggiunge K a $t = 1$. Tra 1 e 2 la saturazione mantiene il livello; poi lo svuotamento ha pendenza -1. Dopo 3 le portate si compensano:

$$x(t) = \begin{cases} 2t & 0 \le t \le 1 \\ 2 & 1 < t \le 2 \\ 4 - t & 2 < t \le 3 \\ 1 & t > 3 \end{cases}. \tag{8}$$

La figura rende visibili i cambi di pendenza e il tratto di saturazione; l'asse orizzontale è il tempo, quello verticale il livello. Un tratto orizzontale può significare equilibrio delle portate oppure saturazione: è l'equazione, insieme alla posizione nello spazio di stato, a distinguere le due cause.

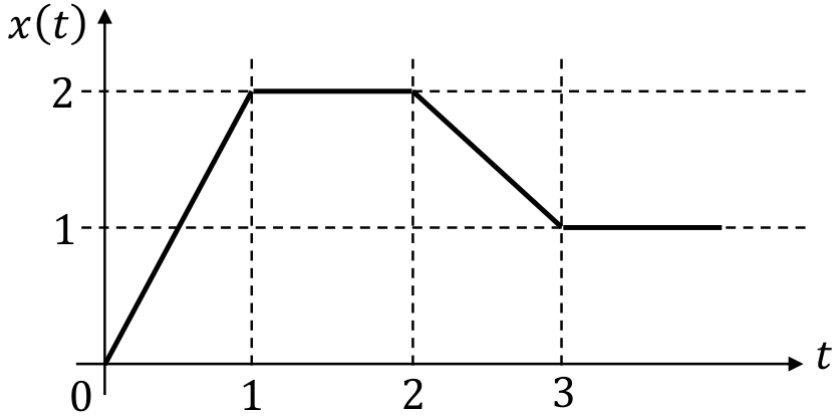


Figura 3: Livello del serbatoio nell'esempio. Documento 0, pagina 11.

Un sistema è lineare se le mappe di stato e d'uscita sono lineari nelle variabili, con condizioni iniziali trattate coerentemente. La forma matriciale generale è $\dot{x} = A(t)x + B(t)u$, $y = C(t)x + D(t)u$. Coefficienti dipendenti dal tempo consentono linearità senza tempo invarianza. Una costante additiva produce invece una mappa affine; un cambio di equilibrio può ricondurla a una forma lineare nelle perturbazioni.

Il pendolo mostra una non linearità geometrica. Con lunghezza ℓ, massa m, angolo θ rispetto alla verticale discendente e tensione del filo T, la proiezione radiale e quella tangenziale riportate sono

$$m\ell\dot{\theta}^2 = T - mg\cos(\theta), \quad m\ell\ddot{\theta} = \tau - mg\sin(\theta). \tag{9}$$

Il disegno originale mostra la verticale di riferimento, l'angolo, la tensione lungo il filo e l'azione applicata al perno; rende visibile anche l'ambiguità dimensionale discussa nella nota.

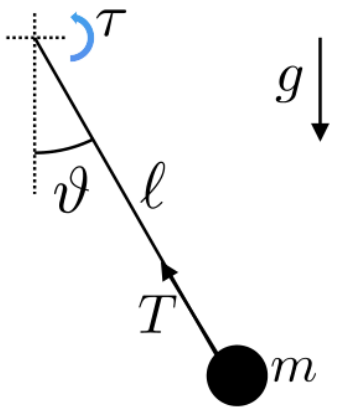


Figura 4: Geometria e azioni sul pendolo. Documento 0, pagina 10.

> **Nota tecnica A02.** Nel documento 0, pagina 10, il disegno rappresenta τ come azione rotatoria, mentre la seconda relazione somma forze. Se τ è una forza tangenziale, l'equazione è dimensionalmente corretta. Se è una coppia, la forma corretta è $m\ell^2\ddot{\theta} = \tau - mg\ell\sin(\theta)$. L'ambiguità della grandezza originale resta dichiarata; la correzione per il caso di coppia è certa.

Il seno impedisce la sovrapposizione. Solo dichiarando piccoli angoli in radianti si può usare $\sin(\theta) \approx \theta$ e ricostruire una linearizzazione locale. Il limite è fisico: grandi oscillazioni non sono descritte accuratamente dalla stessa approssimazione.

Il **movimento** comprende la coppia stato–tempo $(x(t), t)$; la **traiettoria** è la sua proiezione nello spazio di stato. Una stessa curva geometrica può essere percorsa con velocità differenti. I grafici temporali conservano l'informazione di quando si passa in uno stato; la sola traiettoria geometrica la perde.

1.4 Classificazione dei modelli

Fonte A: documento 0, pagine PDF 12–19.

Le classificazioni delle lezioni rispondono a domande indipendenti. La distinzione statico/dinamico riguarda la memoria; tempo variante/invariante riguarda la dipendenza dalla collocazione assoluta nel tempo. Un modello tempo invariante produce una risposta traslata quando si traslano ingresso e condizione iniziale in modo coerente. Non significa che lo stato sia costante. Il termine «stazionario» usato qui per un sistema non coincide con la stazionarietà probabilistica di un processo.

Lo stato è continuo quando appartiene a un sottoinsieme di $\mathbb{R}^n$, discreto quando assume valori separati, ad esempio conteggi in $\mathbb{N}^n$. Il tempo è continuo quando l'evoluzione è definita per ogni istante, discreto quando è definita su una successione di istanti, tipicamente $t_k = t_0 + kT$. Campionare un segnale significa porre $x_k = x(t_k)$ i valori di x_k possono restare reali. Pertanto discretizzare il tempo non discretizza lo spazio di stato. Nei sistemi a tempo discreto le equazioni differenziali sono sostituite da ricorrenze $x_{k+1} = f(x_k, u_k, k)$, ottenute per natura del problema o per discretizzazione numerica.

La forma completa a tempo discreto comprende anche condizione iniziale e uscita:

$$x_{k+1} = f(x_k, u_k, k), \quad x_0 = \text{dato}, \quad y_k = g(x_k, u_k, k). \tag{10}$$

Il magazzino con capacità illimitata e movimentazioni singole è invece discreto nello stato e continuo nel tempo. Con $e = a$ arrivo ed $e = p$ partenza,

$$x(t^+) = \begin{cases} x(t^-) + 1 & e = a \\ x(t^-) - 1 & e = p \ \text{ e } \ x(t^-) > 0, \quad \mathcal{X} = \mathbb{N}_0. \\ x(t^-) & \text{nessun evento} \end{cases} \tag{11}$$

Le ipotesi originali escludono movimentazioni simultanee e uscite da magazzino vuoto. Lo stato resta costante fra eventi; l'istante dell'evento non è obbligato a cadere su una griglia di campionamento.

Un'uscita discreta non rende discreto lo stato fisico. Etichettare il serbatoio con 0 se vuoto, 1 se parzialmente pieno e 2 se pieno non conserva il livello. Due serbatoi entrambi etichettati 1, ma con livelli differenti, raggiungono il pieno in tempi differenti sotto la stessa portata. L'etichetta non soddisfa quindi la proprietà richiesta a uno stato. Un modello astratto di queste etichette può essere utile per una specifica domanda logica, ma richiede una giustificazione propria e non sostituisce automaticamente il modello continuo.

La mappa di sola osservazione è $s(x) = 0$ per $x = 0$, $s(x) = 1$ per $0 < x < K$ e $s(x) = 2$ per $x = K$: è un'uscita del modello, non uno stato sufficiente.

Nei sistemi **time driven** l'aggiornamento è sincronizzato da un clock. Per uno stato discreto, a ogni colpo di clock si può selezionare un evento, incluso quello nullo. Nei sistemi **event driven** processi concorrenti e asincroni determinano gli istanti degli eventi: l'evoluzione procede da un evento al successivo. La scelta ha conseguenze computazionali. Simulare ogni piccolo intervallo vuoto può costare molto; saltare direttamente al prossimo evento evita quel lavoro, purché i tempi siano correttamente programmati.

Infine, un modello deterministico consente di determinare il futuro dati stato e ingressi; un modello stocastico determina una legge di probabilità a partire dalla legge iniziale e dagli ingressi aleatori. Il rumore della sorgente, la portata dovuta alle precipitazioni, i ritardi di consegna o i guasti introducono incertezza. La stessa equazione di bilancio può rimanere valida campione per campione: a cambiare è la natura degli ingressi e delle previsioni.

1.5 Sistemi ad eventi discreti

Fonte A: documento 0, pagine PDF 20–24.

Un sistema ad eventi discreti, SED o DES, ha uno spazio di stato discreto e transizioni associate a occorrenze di eventi. Un evento può essere un'azione comandata, come premere un pulsante, un'occorrenza spontanea, come un guasto, o il manifestarsi di una condizione, come il superamento di una soglia. L'alfabeto $\mathcal{E}$ raccoglie i tipi di evento. Occorre distinguere il tipo, ad esempio «arrivo», dalla sua singola occorrenza a un certo istante.

Una descrizione non temporizzata conserva la successione degli eventi e degli stati, ma non le durate. La temporizzazione aggiunge gli istanti. La modellazione stocastica aggiunge leggi per tali durate e, se necessario, per la scelta della destinazione. Il corso percorre esattamente questa catena: linguaggi e automi descrivono la logica; i clock la collocano nel tempo; i processi stocastici permettono di valutare probabilità e prestazioni.

La passeggiata aleatoria su reticolo è un esempio essenziale: lo stato è una coppia di coordinate intere e l'evento identifica un passo nord, sud, est oppure ovest. La regola di aggiornamento è deterministica una volta assegnato l'evento. Diventa stocastico il moto quando la direzione o il tempo del passo sono estratti casualmente. Ciò mostra che «evento discreto» e «casuale» sono proprietà distinte.

Le domande qualitative riguardano raggiungibilità, sequenze consentite, blocchi e rispetto delle specifiche. Quelle quantitative richiedono tempi, frequenze, occupazioni e costi. Un modello logico può essere sufficiente per dimostrare che due risorse non sono mai usate contemporaneamente; non basta per stimare il tempo medio di attesa.

1.6 Code, reti e calcolatori

Fonte A: documento 0, pagine PDF 25–28.

Una coda comprende clienti, risorse di servizio e spazio di attesa. «Cliente» designa qualsiasi entità che richiede la risorsa: pezzi, job, messaggi, veicoli. Il blocco di servizio rappresenta un ritardo positivo; non descrive necessariamente i dettagli interni della lavorazione. La disciplina, ad esempio FIFO o LIFO, stabilisce l'ordine di selezione. La capacità specifica quante entità possono essere ammesse e va sempre dichiarata insieme alla convenzione sul servizio.

La figura introduce la rappresentazione grafica usata nel seguito: i comparti rettangolari sono lo spazio d'attesa e il cerchio è il servente. Le frecce indicano il percorso del cliente, non necessariamente un flusso continuo di materia.

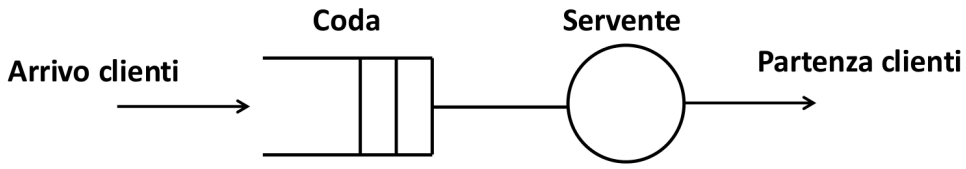


Figura 5: Elementi di una coda di servizio. Documento 0, pagina 25.

Con eventi arrivo a e partenza p, lo stato più semplice è il numero presente $X \in \mathbb{N}_0$, includendo per convenzione il cliente in servizio. La partenza è abilitata solo se $X > 0$. Questa variabile basta alla logica del conteggio; per prevedere tempi di partenza con servizi generali servirà anche l'informazione temporale sul servizio in corso.

Una rete collega più code. Una coda può alimentare più serventi, e più code possono contendersi lo stesso servente. Le regole di instradamento e selezione sono parte del modello. Nel sistema con CPU e due dischi lo stato di conteggio è

$$\boldsymbol{x} = (x_{\mathrm{CPU}}, x_{\mathrm{D1}}, x_{\mathrm{D2}}) \in \mathbb{N}_0^3, \quad \mathcal{E} = \{a, p, r_1, r_2, d_1, d_2\}. \tag{12}$$

Un arrivo esterno incrementa la coda CPU; una terminazione definitiva p la decrementa; r_i trasferisce un job dalla CPU al disco i, quindi modifica due componenti con conservazione del numero totale; d_i esegue il trasferimento inverso. La figura rende immediato il controllo di questi bilanci.

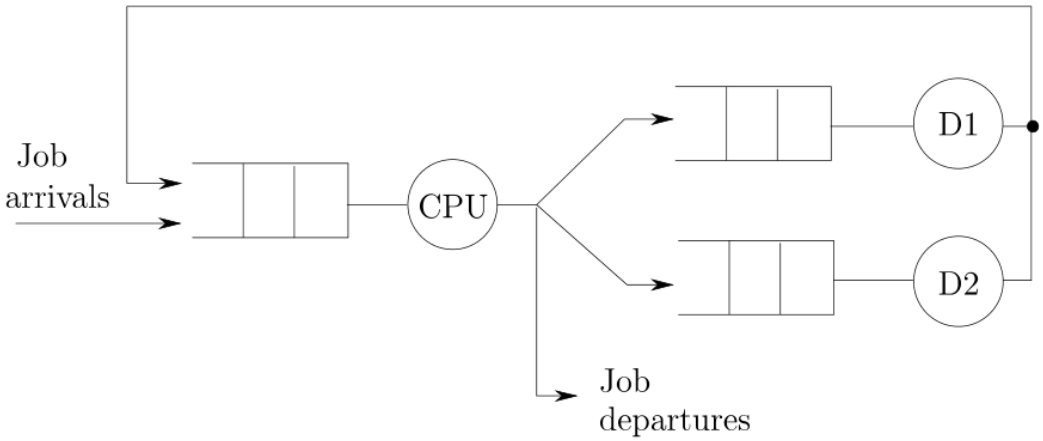


Figura 6: CPU con due dischi e ricircolo dei job. Documento 0, pagina 28.

1.7 Produzione, blocking e controllo

Fonte A: documento 0, pagine PDF 29–33.

In una linea di produzione i pezzi sono clienti e le macchine sono serventi. La capacità del buffer intermedio è spesso piccola. Quando la macchina a monte termina e non può depositare il pezzo, rimane bloccata: è il **blocking**. Quando il buffer è vuoto, la macchina a valle può invece rimanere inattiva per mancanza di materiale. Anche due sole stazioni producono quindi interazioni che non si risolvono confrontando soltanto i tempi medi di lavorazione.

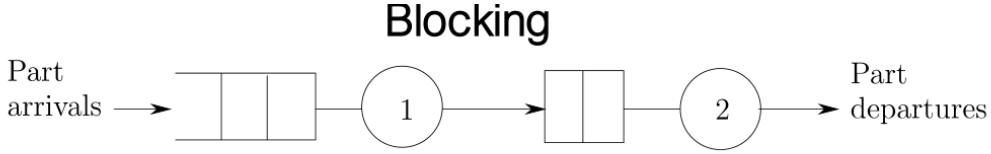


Figura 7: Due stazioni con buffer intermedio e possibilità di blocking. Documento 0, pagina 29.

Le lezioni propongono $\mathcal{E} = \{a, c_1, p_2\}$: arrivo alla macchina 1, completamento della lavorazione 1, partenza dalla macchina 2. Una prima rappresentazione usa $x_1 \geq 0$ e $x_2 \in \{0, 1, 2, 3, B\}$. Il valore 3 indica tre pezzi

presso la stazione 2, incluso quello lavorato; B distingue il caso in cui la stazione 1 trattiene inoltre un pezzo finito. Senza tale distinzione il completamento di una lavorazione e la disponibilità della macchina a monte verrebbero confusi.

Una rappresentazione alternativa considera gli stati delle macchine: $x_1 \in \{I, W, B\}$, $x_2 \in \{I, W\}$, con I inattiva, W in lavorazione e B bloccata. È una descrizione utile per la logica, ma non conserva in generale tutti i conteggi dei buffer. Se la domanda richiede questi conteggi, essi devono essere aggiunti. Non basta elencare simboli: bisogna verificare che rappresentazioni ritenute equivalenti conservino la stessa informazione necessaria.

Per il dimensionamento interessa sapere se conviene ampliare il buffer o installare una seconda macchina, quale throughput si ottiene, quale sia il tempo di attraversamento e quale capacità renda trascurabile il blocco. Per l'automazione interessa come rilevare il buffer pieno, inibire la macchina a monte, farla ripartire e assegnare priorità. Il modello permette di validare queste regole prima dell'esecuzione sul PLC e di cercare deadlock quando la linea viene estesa. Sono usi differenti dello stesso sistema, che richiedono livelli di dettaglio diversi.

1.8 Comunicazione e traffico

Fonte A: documento 0, pagine PDF 34–36.

In una rete di comunicazione i messaggi competono per canali e apparati. Un accesso non coordinato può generare collisioni e perdita del messaggio. Nell'esempio due utenti A, B condividono un canale capace di servire un utente alla volta. Gli arrivi a_A, a_B, i tentativi di trasmissione t_A, t_B e il completamento del canale t_{CH} definiscono

$$\begin{aligned} \mathcal{E} &= \{a_A, a_B, t_A, t_B, t_{\mathrm{CH}}\}, \\ \mathcal{X} &= \{(x_A, x_B, x_{\mathrm{CH}}) : x_A, x_B \in \{I, T, W\}, x_{\mathrm{CH}} \in \{I, T, C\}\}. \end{aligned} \tag{13}$$

C indica collisione, T trasmissione, W attesa e I inattività. Il prodotto elencato è uno spazio candidato; la dinamica può rendere alcune combinazioni irraggiungibili. Progettare un protocollo significa restringere le transizioni per ottenere accesso corretto e prestazioni accettabili.

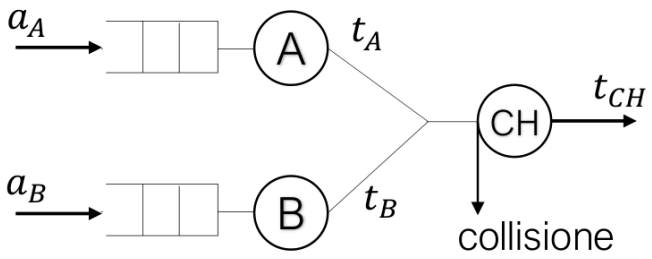


Figura 8: Due utenti e un canale condiviso. Documento 0, pagina 35.

Per l'incrocio delle lezioni, le quattro direzioni di movimento sono 12, 13, 23 e 32. Gli eventi sono gli arrivi a_{ij}, le partenze p_{ij} e i cambi di fase v, r:

$$\begin{aligned} \mathcal{E} &= \{a_{12}, a_{13}, a_{23}, a_{32}, p_{12}, p_{13}, p_{23}, p_{32}, v, r\}, \\ \boldsymbol{x} &= (x_{12}, x_{13}, x_{23}, x_{32}, y), \quad x_{ij} \in \mathbb{N}_0, \quad y \in \{V, R\}. \end{aligned} \tag{14}$$

Il colore è parte dello stato perché, a parità di veicoli presenti, abilita partenze diverse. La geometria della figura associa gli indici alle strade: gli indici descrivono origine e destinazione, non il numero di corsie. Un modello prestazionale dovrà aggiungere tempi di arrivo e attraversamento; un modello di sicurezza dovrà rendere esplicite le compatibilità tra movimenti e le transizioni semaforiche.

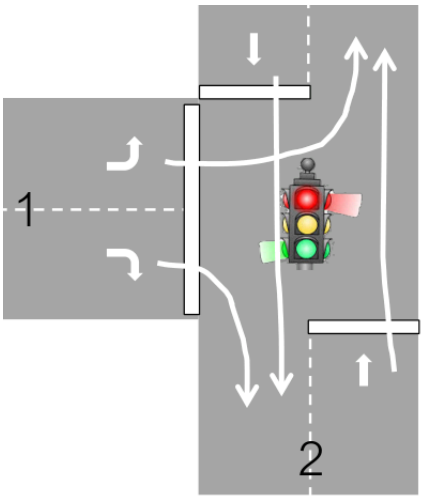


Figura 9: Geometria dell'incrocio e fase semaforica. Documento 0, pagina 36.

Il problema comune a magazzini, calcolatori, linee e reti è ormai identificato: definire uno stato informativo, un insieme di eventi e una regola di transizione. Il prossimo capitolo formalizza queste tre scelte prima di introdurre il tempo.

2 Linguaggi e automi

2.1 Alfabeti, stringhe e linguaggi

Fonte A: documento 1, pagine PDF 1–6.

Prima di chiedere quanto dura una lavorazione, occorre stabilire quali sequenze di operazioni siano possibili. Un modello non temporizzato risponde a questa domanda conservando l'ordine degli eventi e dimenticando gli intervalli. Una sequenza temporizzata è invece una successione di coppie (e_k, t_k); la sua versione stocastica attribuisce leggi probabilistiche alle occorrenze. In questa fase studiamo la correttezza della logica: quale linguaggio può «parlare» il sistema e come costruire un dispositivo che riconosca una specifica.

L'alfabeto E è l'insieme dei tipi di evento. Una stringa, o parola, è una sequenza finita di simboli; la stringa vuota ε ha lunghezza zero e rappresenta l'assenza di eventi. Le lezioni la includono convenzionalmente in E. Operativamente si conserva però la distinzione fra un evento effettivo e la parola vuota, che non aggiunge una transizione fisica. E^* denota tutte le parole finite, inclusa ε; un linguaggio è un sottoinsieme $L \subseteq E^*$.

Con $E = \{a, b, g\}$, gli esempi sono $L_1 = \{\varepsilon, a, abb\}$, $L_2 = aE^2$, tutte le parole di lunghezza 3 che iniziano con a, e $L_3 = aE^*$, tutte le parole finite che iniziano con a. L_1 e L_2 sono finiti; L_3 è infinito pur avendo una descrizione finita. La concatenazione accosta parole, senza sommare né riordinare simboli:

$$(ab)b = a(bb) = abb, \quad a\varepsilon = \varepsilon a = a, \quad E^* = \bigcup_{k=0}^{\infty} E^k, \quad E^0 = \{\varepsilon\}. \tag{15}$$

Se $s = tuv$, allora t è un prefisso, u una sottostringa e v un suffisso. La posizione conta: lo stesso insieme di simboli in ordine diverso definisce una parola diversa. Anche la concatenazione dei linguaggi è quindi generalmente non commutativa.

$$\begin{aligned} L_a \cup L_b &= \{s \in E^* : s \in L_a \ \text{ oppure } \ s \in L_b\}, \\ L_a \cap L_b &= \{s \in E^* : s \in L_a \ \text{ e } \ s \in L_b\}. \end{aligned} \tag{16}$$

$$L_a L_b = \{s_a s_b : s_a \in L_a, s_b \in L_b\}, \quad L^* = \bigcup_{k=0}^{\infty} L^k = \{\varepsilon\} \cup L \cup LL \cup LLL \cup \dots. \tag{17}$$

Per $L_a = \{\varepsilon, a, abb, ac\}$ e $L_b = \{x, y\}$ si ottiene $L_a L_b = \{x, y, ax, ay, abbx, abby, acx, acy\}$. Se $L = \{\varepsilon, a, abb, ac\}$, la chiusura contiene, tra le altre, $\varepsilon, a, abb, ac, aa, aabb, aac, abba, abbabb, abbac$. Non impone un limite al numero di concatenazioni, ma ogni singola parola resta finita.

> **Nota tecnica A03.** Nel documento 1, pagina 6, unione e intersezione sono scritte usando $s = s_a \cup s_b$ e $s = s_a \cap s_b$. Le parole non si uniscono come insiemi per definire queste operazioni: le definizioni corrette usano rispettivamente «oppure» ed «e» sull'appartenenza della stessa parola. Correzione certa.

2.2 Automi deterministici e linguaggi generati

Fonte A: documento 1, pagine PDF 7–10.

Un automa realizza regole di evoluzione mediante un grafo orientato. I nodi sono stati, gli archi sono transizioni etichettate da eventi. Una freccia senza origine identifica lo stato iniziale; un doppio cerchio identifica uno stato marcato. La marcatura esprime una proprietà scelta dal modellista, spesso il completamento di un compito. Non significa necessariamente arresto dell'evoluzione.

$$\begin{aligned} G &= (\mathcal{X}, E, f, \Gamma, x_0, \mathcal{X}_m), \quad f : \mathcal{X} \times E \to \mathcal{X}, \\ \Gamma(x) &= \{e \in E : f(x, e) \ \text{ è definita}\}, \quad \mathcal{X}_m \subseteq \mathcal{X}. \end{aligned} \tag{18}$$

f è generalmente parziale: un evento può non essere consentito nello stato corrente. Il determinismo significa che, per uno stesso stato e uno stesso evento abilitato, vi è un'unica destinazione; non significa che il prossimo

evento sia già noto. La mappa di abilitazione ha codominio l'insieme delle parti di E, poiché restituisce un insieme di eventi.

> **Nota tecnica A04.** Le pagine 8 e 39 del documento 1 scrivono $\Gamma : \mathcal{X} \to E$. Il codominio coerente con gli insiemi elencati è 2^E. Correzione formale certa.

L'esempio iniziale ha $\mathcal{X} = \{x, y, z\}$, $E = \{a, b, g\}$, $x_0 = x$ e $\mathcal{X}_m = \{x, z\}$. La tabella esplicita ogni arco; un trattino denota transizione non definita.

Stato	a	b	g
x	x	—	z
y	x	y	—
z	y	z	y

Tabella 1: Transizioni dell'automa a tre stati del documento 1, pagina 7.

Da x si può eseguire gba: si passa a z, vi si rimane con b, poi si raggiunge y. La parola è generabile ma non marcata. Per formalizzare queste verifiche si estende f alle parole:

$$f(x, \varepsilon) = x, \quad f(x, se) = f(f(x, s), e). \tag{19}$$

La seconda relazione vale se tutti i passaggi sono definiti. Si procede per induzione sulla lunghezza: il prefisso determina lo stato intermedio e l'ultimo simbolo completa la transizione. I due linguaggi associati sono

$$\mathcal{L}(G) = \{s \in E^* : f(x_0, s) \ \text{ è definita}\}, \quad \mathcal{L}_m(G) = \{s \in \mathcal{L}(G) : f(x_0, s) \in \mathcal{X}_m\}. \tag{20}$$

Il linguaggio generato è chiuso rispetto ai prefissi: poter eseguire una parola implica poter eseguire ciascuna parte iniziale. Quello marcato può non esserlo: completare un task non implica che ogni suo prefisso lo completi. Due automi sono equivalenti nel senso delle lezioni se hanno uguali entrambi i linguaggi, generato e marcato; l'uguaglianza dei grafi non è richiesta.

Per riconoscere tutte le parole su $\{a, b\}$ che finiscono con a bastano due stati: 0 significa «l'ultimo simbolo non è a, oppure non è stato letto nulla», 1 significa «l'ultimo simbolo è a». Lo stato iniziale è 0 e il solo marcato è 1. Le transizioni sono $f(0, a) = f(1, a) = 1$, $f(0, b) = f(1, b) = 0$. Il generato è E^* e il marcato è $E^* a$. Un automa che conta tutti gli a consecutivi dopo l'ultimo b possiede più stati, anche infiniti, ma può riconoscere lo stesso linguaggio: il conteggio dettagliato è informazione superflua per questa specifica.

2.3 Esempi di riconoscimento e servizio

Fonte A: documento 1, pagine PDF 11–16.

Nel carrello su binario i sensori A, B, C sono ordinati da sinistra a destra e segnalano attraversamenti in entrambe le direzioni. Partendo dall'estremo sinistro, lo stato è il tratto occupato: 0 prima di A, 1 fra A e B, 2 fra B e C, 3 dopo C. Un sensore non adiacente al tratto corrente indica una sequenza incoerente e porta allo stato d'errore 4. La figura associa geometria e grafo: lo stesso evento può portare a destra o a sinistra secondo lo stato corrente.

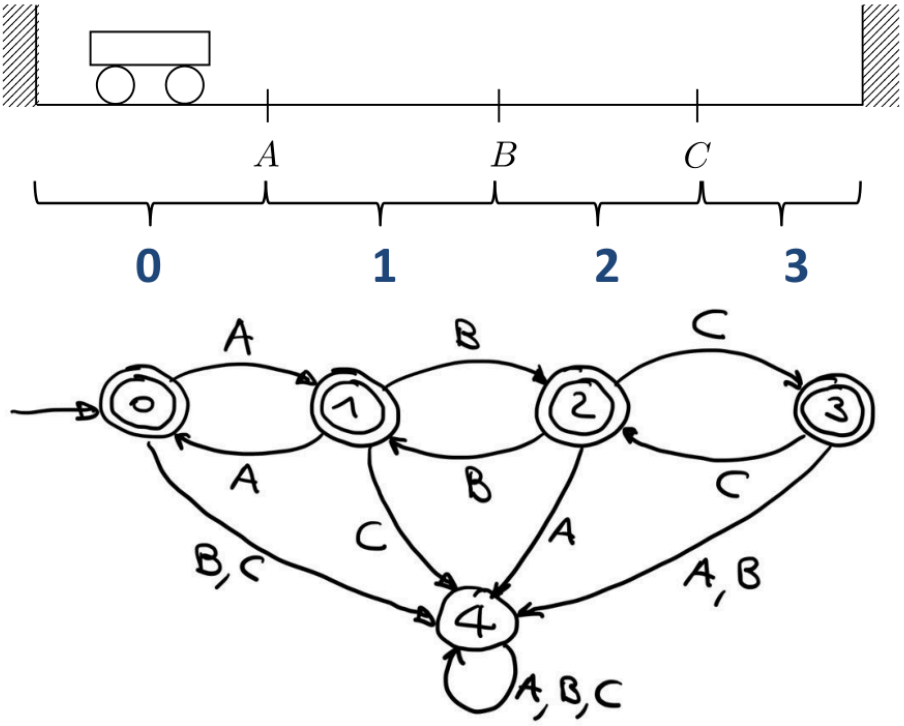


Figura 10: Localizzazione per tratti e rilevazione di sequenze incoerenti. Documento 1, pagina 11.

Stato	A	B	C
0	1	4	4
1	0	2	4
2	4	1	3
3	4	4	2
4	4	4	4

Tabella 2: Tabella completa del carrello. Gli stati 0–3 sono marcati; 4 è assorbente e non marcato.

L'automa rileva incompatibilità con il modello assunto; non identifica univocamente quale sensore sia guasto né rileva qualsiasi guasto possibile. Un sensore che omette un segnale può condurre a una successiva incongruenza, ma il solo modello logico non fornisce una diagnosi fisica completa.

Il verificatore di task accetta un prefisso di tre eventi: b, poi a_1 oppure a_2, infine di nuovo b; dopo il completamento è consentita qualunque continuazione. Il linguaggio è

$$L = b(a_1 + a_2)bE^*, \quad E = \{a_1, a_2, b\}. \tag{21}$$

Qui $+$ denota unione di alternative, non somma numerica. Gli stati sono 0 inizializzazione, 1 acceso, 2 esito OK, 3 problema rilevato, 4 task completato e marcato, 5 errore. Da 0 un b conduce a 1, mentre a_1, a_2 conducono a 5. Da 1, a_1 conduce a 2 e a_2 a 3; un altro b conduce a 5. Da 2 e 3, b porta a 4, gli altri eventi a 5. Gli stati 4 e 5 hanno cappi per tutti gli eventi. I due esiti 2 e 3 sono mantenuti perché hanno un significato diagnostico diverso, benché la specifica del linguaggio li accetti entrambi quando segue b.

Nel riconoscitore lessicale, L indica una lettera, C una cifra, S un segno e P il punto decimale. Un identificatore inizia con lettera e prosegue con lettere o cifre. Un numero può avere segno, richiede almeno una cifra e ammette il punto iniziale o finale. Le famiglie sono

$$L_{\mathrm{id}} = L(L + C)^*, \quad L_{\mathrm{int}} = (\varepsilon + S)CC^*, \quad L_{\mathrm{dec}} = (\varepsilon + S)(CC^*PC^* + PCC^*). \tag{22}$$

La parola «.» e un segno isolato non sono numeri. Una macchina completa può usare gli stati iniziale, identificatore, intero, decimale valido, solo segno, solo punto e pozzo d'errore. Dal solo segno si può leggere una cifra o un punto; dal solo punto serve una cifra. L'intero è marcato e rimane tale leggendo cifre; il punto lo

porta al decimale, marcato anche prima di altre cifre perché il punto finale è ammesso. Una lettera dopo una sequenza numerica è un errore per il token considerato. La figura conserva il grafo manoscritto delle lezioni; la descrizione chiarisce la funzione di ogni gruppo di archi.

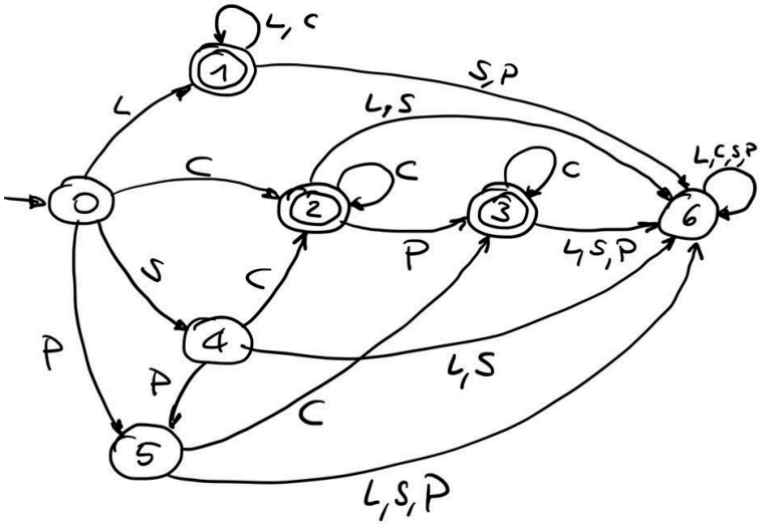


Figura 11: Riconoscitore di identificatori e numeri. Documento 1, pagina 13.

Per una coda non temporizzata, $\mathcal{X} = \mathbb{N}_0$, $E = \{a, p\}$, $f(x, a) = x + 1$ per $x \geq 0$ e $f(x, p) = x - 1$ per $x > 0$. Si ha $\Gamma(0) = \{a\}$ e $\Gamma(x) = \{a, p\}$ per $x > 0$. Per osservare invece il solo servente si introducono I inattivo, B occupato e D guasto, con eventi α inizio, β completamento, λ guasto e μ riparazione:

$$\begin{gathered} f(I, \alpha) = B, \quad f(B, \beta) = I, \quad f(B, \lambda) = D, \quad f(D, \mu) = I; \\ \Gamma(I) = \{\alpha\}, \quad \Gamma(B) = \{\beta, \lambda\}, \quad \Gamma(D) = \{\mu\}. \end{gathered} \tag{23}$$

In questo esempio il cliente in servizio al momento del guasto è perso e, dopo la riparazione, il servente torna inattivo. Non si assume ripresa del lavoro interrotto. I simboli λ, μ sono qui **nomi di eventi**, non tassi: è il contesto a stabilirne il significato.

2.4 Regolarità ed espressioni regolari

Fonte A: documento 1, pagine PDF 17–22.

Un linguaggio è regolare se è marcato da un automa a stati finiti. L'infinità del linguaggio non implica l'infinità del numero di stati: tutte le parole che terminano in a sono infinite, ma bastano due stati. Il problema è quanta memoria distinta serva per decidere l'appartenenza.

Per $L = \{a^n b^n : n \geq 0\}$ occorre ricordare senza limite il numero di a per verificare il successivo numero di b. Una dimostrazione ricostruita usa gli stati raggiunti dopo $\varepsilon, a, a^2, \ldots$. Se un automa finito facesse coincidere gli stati dopo a^r e a^s, con $r < s$, la continuazione b^r sarebbe accettata da entrambi o da nessuno: dovrebbe invece accettare solo $a^r b^r$. La contraddizione mostra che il linguaggio non è regolare. Un automa infinito può rappresentarlo, ma richiede memoria non limitata. Le reti di Petri sono citate nelle lezioni come formalismo utile per alcuni problemi non regolari, senza svilupparne qui la teoria.

Le espressioni regolari si costruiscono da $\varnothing$, ε e dai singoli eventi mediante concatenazione, unione e stella di Kleene. Il teorema di Kleene stabilisce l'equivalenza espressiva fra queste espressioni e gli automi finiti. La stella ha precedenza sulla concatenazione, che ha precedenza sull'unione; le parentesi evitano ambiguità.

Per $E = \{a, b, g\}$, $(a + b)g^*$ genera $a, b, ag, bg, agg, bgg, \ldots$: prima si sceglie a o b, poi si ripete g un numero arbitrario di volte. L'espressione $(ab)^* + g$ genera $\varepsilon, g, ab, abab, \ldots$. Non genera abg: l'unione sceglie una delle due famiglie complete.

Nel grafo a due stati senza cappio b in 0, ogni ritorno 0–1–0 legge uno o più a seguiti da b; la visita finale a 1 legge uno o più a. Il linguaggio marcato è

$$\mathcal{L}_m = (aa^*b)^*aa^*. \tag{24}$$

Se si aggiunge il cappio b nello stato 0 si consentono anche b quando non si è appena letto a. Le rappresentazioni delle lezioni diventano

$$\mathcal{L}_m = \left(b^*(aa^*b)^*\right)^*aa^* = (b + aa^*b)^*aa^* = E^*a. \tag{25}$$

L'ultima uguaglianza è una lettura ricostruita: ogni parola che termina in a si scompone in blocchi di b e blocchi di a terminati da b, seguiti dalla corsa finale di a. Il cappio aggiunto modifica quindi il linguaggio e non può essere ignorato confrontando figure simili.

L'ascensore ha stati A attesa a porte aperte, C chiusura e M movimento. Gli eventi sono r richiesta, f fotocellula, c porte chiuse e a arrivo. Le sole transizioni sono $f(A, r) = C$, $f(C, f) = A$, $f(C, c) = M$, $f(M, a) = A$. La fotocellula durante la chiusura riporta all'attesa; non si modella un movimento a porte aperte. Con A iniziale e unico marcato, i cicli completi sono rf e rca:

$$\alpha = ((rf)^*(rca)^*)^* = (rf + rca)^*. \tag{26}$$

Una concatenazione arbitraria di questi cicli descrive tutti i ritorni in attesa, inclusa la parola vuota. Il linguaggio generato include anche i prefissi incompleti, ad esempio r e rc, che non sono marcati.

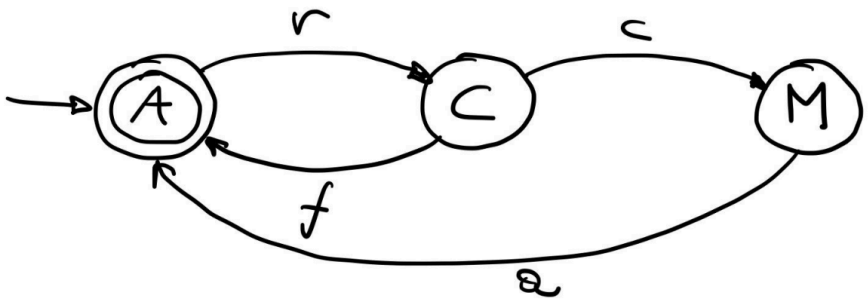


Figura 12: Automa logico dell'ascensore. Documento 1, pagina 22.

2.5 Equivalenza e minimizzazione

Fonte A: documento 1, pagine PDF 23–38.

La composizione di molti componenti può produrre uno spazio di stato molto grande. Aggregare stati ridondanti permette di ottenere un riconoscitore più piccolo, ma l'aggregazione va giustificata dalle continuazioni future. Indicando con $G(x)$ l'automa avviato in x, gli stati x, y sono equivalenti rispetto alla marcatura quando

$$\mathcal{L}_m(G(x)) = \mathcal{L}_m(G(y)), \quad \forall u \in E^* : (f(x,u) \in \mathcal{X}_m \Leftrightarrow f(y,u) \in \mathcal{X}_m). \tag{27}$$

Per automi parziali le continuazioni non definite si intendono non accettate. Se si vuole preservare anche il linguaggio generato, si deve inoltre conservare la definibilità delle continuazioni; un completamento con un pozzo non marcato rende esplicito il rifiuto, ma non deve far dimenticare la distinzione originaria fra «impossibile» e «possibile non marcato».

La parola vuota distingue immediatamente un marcato da un non marcato. A parità di marcatura, se ogni evento porta i due stati alla stessa destinazione essi sono equivalenti. È sufficiente anche che alcuni eventi li scambino fra loro e gli altri conducano a destinazioni comuni. Più in generale, un insieme R tutto marcato o tutto non marcato può essere aggregato se le transizioni che escono da R hanno, per ogni evento, la stessa destinazione per tutti gli stati di R; quelle interne rimangono nella classe. L'argomento è induttivo: finché si rimane in R la marcatura non distingue; quando si esce, i futuri coincidono.

> **Nota tecnica A05.** L'osservazione 3 del documento 1, pagina 24, enuncia il criterio degli stati che si scambiano senza ripetere l'ipotesi di uguale marcatura. Questa ipotesi è necessaria: altrimenti ε distingue già i due stati. Integrazione certa del presupposto.

Il riconoscitore del suffisso 123 legge $E=\{1,2,3\}$ e marca $E^{*}123$. I cinque stati iniziali sono x_0 nessuna cifra, x_1 suffisso utile 1, x_{12} suffisso utile 12, x_{123} suffisso completo, x_{not1} nessun suffisso utile. «Utile» significa che può essere prolungato fino alla parola cercata; non si memorizza tutta la storia.

Stato	1	2	3
x_0	x_1	x_{not1}	x_{not1}
x_1	x_1	x_{12}	x_{not1}
x_{12}	x_1	x_{not1}	x_{123}
x_{123}	x_1	x_{not1}	x_{not1}
x_{not1}	x_1	x_{not1}	x_{not1}

Tabella 3: Transizioni complete del riconoscitore. Solo x_{123} è marcato.

Da x_{12}, leggere 1 non cancella tutta l'informazione: resta il suffisso 1. Da x_{123}, leggere 2 cancella invece il suffisso completo e non lascia un prefisso di 123. I tre archi uscenti da x_0 e da x_{not1} hanno identiche destinazioni e la marcatura è la stessa: sono equivalenti. La loro fusione produce quattro stati.

L'algoritmo delle coppie rende sistematica la verifica. Si eliminano dapprima gli stati irraggiungibili se si cerca un automa minimo dall'iniziale. Si costruisce poi una tabella triangolare di coppie non ordinate. Si contrassegnano le coppie con marcatura diversa. Per ogni coppia ancora libera e ogni evento si calcola la coppia delle destinazioni; se questa è già distinta, si contrassegna anche la coppia d'origine. Si ripete fino a quando nessuna nuova distinzione è possibile. Le coppie residue identificano le classi di equivalenza.

La versione tabellare delle lezioni assume una transizione totale, per cui $\mathcal{L}(G)=E^{*}$. Il quoziente canonico ha uno stato per ogni classe di equivalenza:

$$G_{\mathrm{can}}=\left(\frac{\mathcal{X}}{\sim},E,f_{\mathrm{can}},\Gamma_{\mathrm{can}},[x_0],\mathcal{X}_{m,\mathrm{can}}\right),\quad f_{\mathrm{can}}([x],e)=[f(x,e)]. \tag{28}$$

L'equivalenza assicura che la destinazione non dipenda dal rappresentante scelto. Le classi marcate sono quelle contenenti stati marcati; il linguaggio marcato resta uguale e il generato resta E^{*}. Dopo aver eliminato gli stati irraggiungibili, due classi diverse sono distinguibili da una continuazione: qualunque riconoscitore dello stesso linguaggio deve quindi mantenerle distinte. Questo giustifica la minimalità; il risultato è unico a meno dei nomi assegnati agli stati.

La giustificazione è costruttiva: una distinzione iniziale è testimoniata da ε; se u distingue le destinazioni dopo e, allora eu distingue gli stati di partenza. Per implementare l'algoritmo senza ripassare tutta la tabella, a ogni coppia si associa una lista di coppie dipendenti: quando viene contrassegnata, la distinzione si propaga ricorsivamente a queste liste. Una dipendenza da se stessa non prova distinguibilità e non va contrassegnata senza un testimone esterno.

Nel riconoscitore, tutte le quattro coppie contenenti x_{123} sono subito distinte. La cifra 3 distingue x_{12} da ciascuno degli altri non marcati. La continuazione 23 distingue x_1 da x_0 e da x_{not1}. Delle dieci coppie complessive, nove sono dunque distinte e solo (x_0,x_{not1}) rimane libera. Questa ricostruzione condensa le successive tabelle delle lezioni conservando la causa di ciascun contrassegno.

L'altro esempio ha stati 0,1,2, con 1 e 2 marcati, 0 su a verso 1, 1 su a verso 2, 2 su a a se stesso e da 1 o 2 su b verso 0. Gli stati 1 e 2 sono equivalenti: le destinazioni sono uguali per ogni evento. Lo stesso vale per la versione infinita che conta il numero di a consecutivi e riporta ogni stato positivo a 0 su b. Per riconoscere la proprietà basta conservare «zero» oppure «positivo». Il quoziente ha due stati; non contiene il cappio b in 0 se esso manca nell'automa originario.

2.6 Automi con uscita e trasmettitore

Fonte A: documento 1, pagine PDF 39–42.

La marcatura segnala una proprietà di stato, ma molti dispositivi producono un'uscita su ogni evento. Il modello delle lezioni è

$$G_u = (\mathcal{X}, E, f, \Gamma, x_0, Y, h), \quad h : \mathcal{X} \times E \to Y, \quad y = h(x, e), \quad e \in \Gamma(x). \tag{29}$$

È un'uscita dipendente da stato ed evento. Nel trasmettitore gli stati sono I inattivo, M messaggio in memoria, T trasmissione in corso; gli eventi sono a arrivo del messaggio, t trasmissione, s timeout e ack conferma. Un nuovo messaggio è acquisito soltanto in I; negli altri stati l'arrivo viene ignorato. Una copia è conservata per poter ritrasmettere dopo il timeout. La conferma cancella la copia e produce uscita 1; le altre transizioni producono 0.

Stato	a	t	s	ack
I	$(M, 0)$	–	–	–
M	$(M, 0)$	$(T, 0)$	–	–
T	$(T, 0)$	–	$(M, 0)$	$(I, 1)$

Tabella 4: Destinazione e uscita del protocollo. Un trattino denota un evento disabilitato.

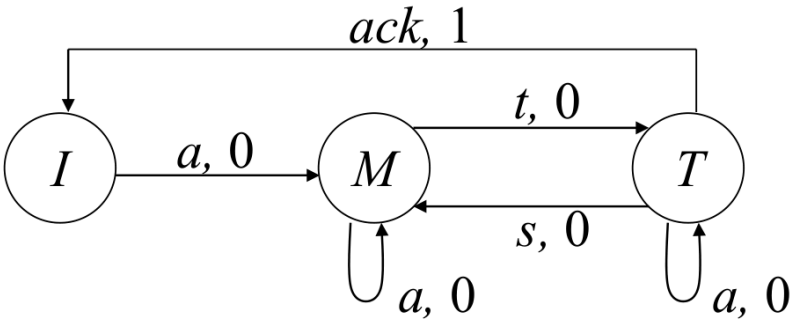


Figura 13: Protocollo con memoria, timeout e conferma. Documento 1, pagina 42.

Il cappio di arrivo in M o T è un evento reale senza cambio di stato; non è la stringa vuota. La logica può essere verificata senza conoscere il valore del timeout. Per stimare ritardi e ritrasmissioni sarà invece necessario temporizzarla.

2.7 Composizione di trasmettitori

Fonte A: documento 1, pagine PDF 43–45.

Due trasmettitori sul medesimo canale introducono un vincolo di mutua esclusione. Si distingue ogni evento con un indice 1 o 2. Lo stato candidato è una coppia di stati locali, ma (T_1, T_2) è vietato: entrambi i messaggi andrebbero persi se si trasmettesse contemporaneamente. Il protocollo assunto osserva il canale e ritarda l'avvio quando è occupato. Restano otto stati

$$\mathcal{X} = \{I, M, T\}^2 \setminus \{(T, T)\}, \quad E = \{a_1, a_2, t_1, t_2, s_1, s_2, \mathrm{ack}_1, \mathrm{ack}_2\}. \tag{30}$$

Un evento del componente i aggiorna la sua coordinata secondo il modello locale e lascia invariata l'altra. L'evento t_i è abilitato soltanto se il componente i è in M e l'altro non è in T. Arrivi, timeout e conferme conservano le abilitazioni locali. In particolare,

$$\Gamma(M_1, T_2) = \{a_1, a_2, s_2, \mathrm{ack}_2\}, \quad \Gamma(T_1, M_2) = \{a_1, a_2, s_1, \mathrm{ack}_1\}. \tag{31}$$

La figura originale mostra tutte le transizioni raggiungibili: i cappi di arrivo rappresentano richieste scartate, gli archi s_i riportano il messaggio in memoria e gli archi di conferma liberano il trasmettitore. La regola sulla trasmissione è sufficiente a rendere irraggiungibile il doppio T, purché l'osservazione e l'avvio siano modellati come transizione atomica. Non costituisce, da sola, una garanzia di equità fra i due utenti.

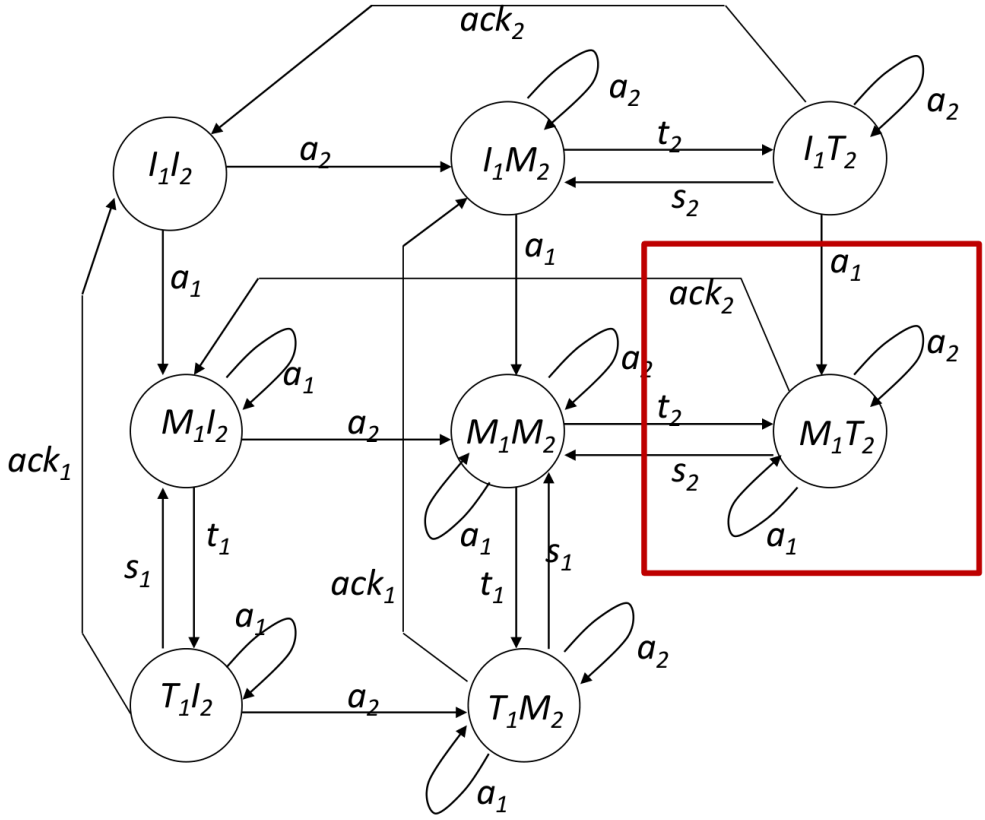


Figura 14: Composizione con esclusione della trasmissione simultanea. Documento 1, pagina 45.

2.8 Filosofi e risorse condivise

Fonte A: documento 1, pagine PDF 46–51.

Il problema dei filosofi illustra processi concorrenti che richiedono risorse esclusive. Un filosofo pensa oppure tenta di mangiare; può prendere una forchetta alla volta e mangia soltanto possedendone due. Al termine restituisce entrambe. Nella versione a due filosofi, $F_i f_j$ indica la presa della forchetta j da parte di i, e F_i il termine del pasto. Ciascun filosofo ha quattro stati P_i, $A_i f_1$, $A_i f_2$, M_i. Ogni forchetta ha due stati, disponibile D o non disponibile ND.

Il prodotto non vincolato contiene $4 \times 4 \times 2 \times 2 = 64$ quadruple, ma la sincronizzazione degli eventi e la condizione iniziale ne rendono raggiungibili solo nove. Sono: entrambi pensano e le due forchette sono libere; quattro stati in cui un solo filosofo possiede una sola forchetta; due stati in cui un filosofo mangia e l'altro pensa; due stati in cui ognuno possiede una forchetta diversa. In questi ultimi nessuno può acquisire la seconda e nessuno può restituire con l'evento di fine pasto, che richiede lo stato M_i: sono deadlock.

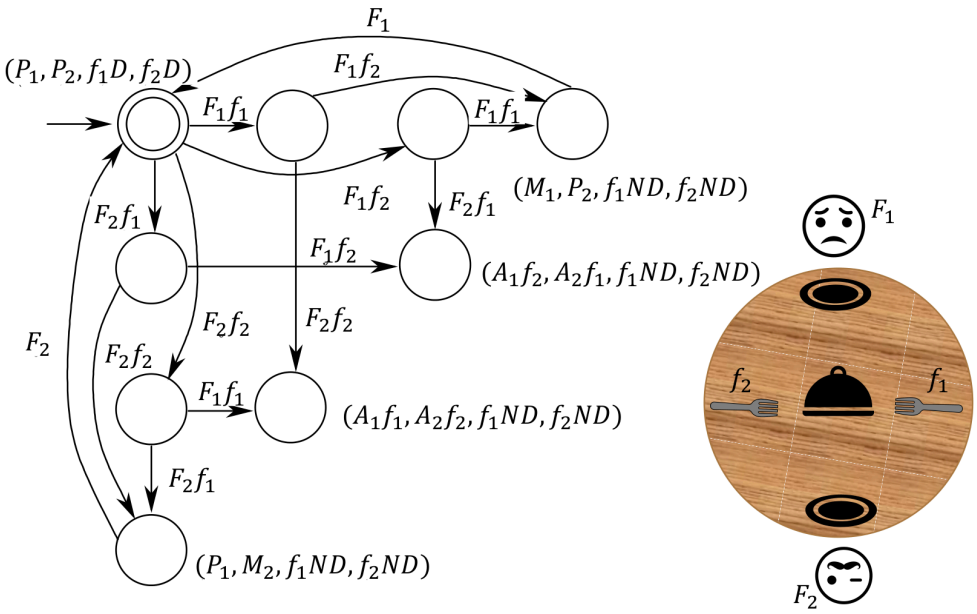


Figura 15: Composizione dei due filosofi e delle due forchette. Documento 1, pagina 49.

Il grafo rende visibili gli stati senza archi uscenti: $(A_1f_1, A_2f_2, \mathrm{ND}, \mathrm{ND})$ e $(A_1f_2, A_2f_1, \mathrm{ND}, \mathrm{ND})$. Il difetto non è locale al singolo filosofo: nasce dall'interazione fra le sue regole e la disponibilità condivisa delle risorse. Il prodotto va quindi costruito sincronizzando ogni presa con la forchetta corrispondente; combinare arbitrariamente gli stati locali introdurrebbe configurazioni fisicamente impossibili.

La soluzione proposta ordina numericamente le risorse e impone l'acquisizione in ordine crescente. Con cinque filosofi, F_i per $i = 1, \ldots, 4$ prende prima f_i e poi f_{i+1}; F_5 prende prima f_1 e poi f_5, invertendo l'ordine delle mani. La prova ricostruita dell'assenza di attesa circolare è semplice: lungo un'eventuale catena di richieste la risorsa desiderata dovrebbe avere indice strettamente maggiore di quella già posseduta. Un ciclo richiederebbe una successione strettamente crescente che torna al punto iniziale, impossibile.

L'assenza di deadlock non implica assenza di **starvation**: un filosofo può essere rinviato indefinitamente da una politica iniqua mentre gli altri continuano. Per escluderlo servono condizioni sull'assegnazione o sull'equità dell'esecuzione. La distinzione chiude la parte logica del corso: la raggiungibilità può rivelare uno stallo, ma i tempi di attesa e le probabilità di rinvio richiedono i clock introdotti nel capitolo successivo.

3 Sistemi ad eventi discreti temporizzati

3.1 Tempo, clock, durata, residuo ed età

Fonte A: documento 2, pagine PDF 1–7.

L'automa non temporizzato stabilisce che una partenza può avvenire se la coda non è vuota; non stabilisce quando avverrà. Per rispondere si associa un orologio, o clock, a ciascun evento abilitato. La traiettoria discreta assume valori costanti fra gli istanti $t_0, t_1, t_2, \ldots$ e viene aggiornata con $x_{k+1} = f(x_k, e_{k+1})$. Il processo in tempo continuo si ricostruisce ponendo $x(t) = x_k$ per $t_k \leq t < t_{k+1}$.

Con un solo evento permanentemente abilitato, il tempo di vita v_k è l'intervallo fra attivazione e occorrenza. All'istante intermedio t si distinguono età z_k e vita residua y_k:

$$v_k = t_k - t_{k-1}, \quad y_k = t_k - t, \quad z_k = t - t_{k-1}, \quad v_k = y_k + z_k. \tag{32}$$

Le quattro grandezze sono tempi e devono usare la stessa unità. L'età aumenta mentre il residuo diminuisce con velocità unitaria. Il valore iniziale del clock è una durata; non è un istante assoluto. La sequenza $V_i = \{v_{i,1}, v_{i,2}, \ldots\}$ fornisce le durate da usare a ogni nuova attivazione dell'evento i.

Con due eventi permanentemente abilitati, α, β, vince quello con clock minore. Se $v_{\alpha,1} < v_{\beta,1}$, il primo evento è α a $t_1 = t_0 + v_{\alpha,1}$. Il clock di α è rinnovato a $v_{\alpha,2}$; quello di β conserva il residuo $v_{\beta,1} - v_{\alpha,1}$. Se ora quest'ultimo è il minore, β accade a $t_2 = t_1 + v_{\beta,1} - v_{\alpha,1}$. È quindi scorretto rinnovare tutti i clock dopo ogni evento generale: si cancellerebbe il lavoro temporale già compiuto dagli altri.

Se un evento viene disabilitato, il suo clock è interrotto e rimosso. Una successiva riabilitazione usa il campione successivo della sua sequenza. Questo è il meccanismo adottato dal corso: cancellazione e nuova inizializzazione, con conservazione del residuo solo per eventi rimasti abilitati. Una politica di sospensione e ripresa del vecchio residuo sarebbe un altro modello, da dichiarare separatamente. La distinzione si manifesta, per esempio, quando un'operazione viene annullata anziché semplicemente messa in pausa.

Il diagramma seguente esplicita il meccanismo: le frecce orizzontali misurano durate e residui, le verticali segnano gli eventi del sistema. Il clock di α inizializzato a t_2 viene interrotto a t_3 e un nuovo campione viene usato a t_4; il clock persistente di β continua invece a scorrere.

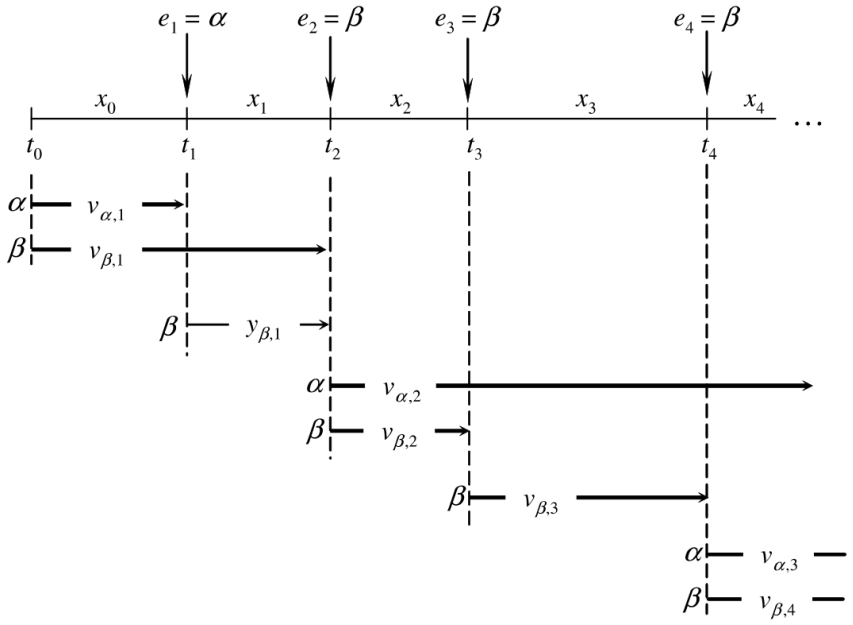


Figura 16: Clock persistenti e clock interrotti. Documento 2, pagina 7.

3.2 Automa temporizzato e ricorsione dei clock

Fonte A: documento 2, pagine PDF 8–17.

La struttura di temporizzazione è $V = \{V_i : i \in E\}$ ed è un ingresso del DES. L'automa temporizzato è la sestupla

$$G_t = (\mathcal{X}, E, f, \Gamma, x_0, V). \tag{33}$$

Per eseguirlo occorrono, oltre a x e al tempo corrente t, i residui y_i e i contatori N_i. Il contatore indica quante volte il clock dell'evento i è stato inizializzato: è un puntatore nella sequenza V_i. Non conta semplicemente quante volte l'evento si è verificato. Anche un clock inizializzato e poi cancellato consuma un campione.

All'inizio si pone $N_i = 1$, $y_i = v_{i,1}$ per $i \in \Gamma(x_0)$; per gli altri $N_i = 0$ e il residuo non è definito. I contatori si conservano anche durante la disabilitazione, altrimenti si riutilizzerebbero campioni già consumati. L'apice indica i valori dopo il prossimo evento:

$$y^* = \min_{i \in \Gamma(x)} y_i, \quad e' = \arg\min_{i \in \Gamma(x)} y_i, \quad t' = t + y^*, \quad x' = f(x, e'). \tag{34}$$

Se più residui sono minimi, si usa la priorità stabilita nelle lezioni: l'indice minore ha priorità maggiore. L'argomento del minimo diventa così univoco. Dopo il primo evento alla stessa data, l'abilitazione viene rivalutata: un altro evento a residuo zero può essere ancora eseguito oppure cancellato dal cambio di stato. Questo ordinamento è parte del modello, non un dettaglio innocuo del programma.

Per esprimere senza ambiguità l'aggiornamento definiamo l'insieme degli eventi persistenti P e quello dei clock da inizializzare A:

$$P = (\Gamma(x) \cap \Gamma(x')) \setminus \{e'\}, \quad A = \Gamma(x') \setminus P. \tag{35}$$

$$y_i' = \begin{cases} y_i - y^* & i \in P \\ v_{i,N_i+1} & i \in A, \end{cases} \quad N_i' = \begin{cases} N_i + 1 & i \in A \\ N_i & i \notin A. \end{cases} \tag{36}$$

Il residuo è definito solo per $i \in \Gamma(x')$. In A rientrano sia l'evento appena avvenuto, se ancora abilitato, sia gli eventi prima disabilitati e ora abilitati. Gli eventi usciti dall'insieme di abilitazione perdono il residuo. Se $\Gamma(x)$ è vuoto, non esiste un prossimo evento: si è in uno stato terminale o di stallo, secondo la specifica.

Questa ricorsione fornisce uno stato di simulazione più ricco del solo stato logico. Due esecuzioni con uguale x ma residui diversi possono avere prossimi eventi differenti. Richiediamo inoltre che non si accumulino infiniti eventi in un tempo finito. Durate strettamente positive non bastano da sole a escludere un'accumulazione, perché una serie positiva può convergere; la non esplosione è una condizione sulla successione completa. Le durate nulle dell'esercizio sono ammissibili se non producono una catena infinita di eventi alla stessa data.

L'esempio delle lezioni ha $\mathcal{X} = \{0, 1, 2\}$, $E = \{\alpha, \beta\}$, $\Gamma(0) = \Gamma(2) = \{\alpha, \beta\}$ e $\Gamma(1) = \{\alpha\}$. Gli archi sono $0 \xrightarrow{\alpha} 1$, $1 \xrightarrow{\alpha} 2$, $2 \xrightarrow{\alpha} 1$, $0 \xrightarrow{\beta} 2$ e $2 \xrightarrow{\beta} 0$. Con $x_0 = 0$, $t_0 = 0$, $V_\alpha = (1, 1.5, 1.5, \ldots)$ e $V_\beta = (2, 0.5, 1.5, \ldots)$ si ricostruisce l'esecuzione seguente.

Istante	Evento	Nuovo stato	y_α	y_β	(N_α, N_β)
0	inizio	0	1	2	(1,1)
1	α	1	1.5	non definito	(2,1)
2.5	α	2	1.5	0.5	(3,2)
3	β	0	1	1.5	(3,3)
4	α	1	campione 4	non definito	(4,3)

Tabella 5: Evoluzione dei clock nell'esempio a tre stati.

Al tempo 1 il clock di β, pur avendo ancora residuo 1, viene cancellato. Quando β torna abilitato a 2.5, si usa 0.5 e non il vecchio residuo. Al tempo 3 il clock di α rimane attivo: $1.5 - 0.5 = 1$. Si ottiene $x(3.5) = 0$. Nell'intervallo $[0, 4]$ i tempi complessivi negli stati 0,1,2 sono rispettivamente 2, 1.5, 0.5. Il punto finale non

modifica gli integrali di occupazione; la convenzione destra continua determina invece il valore puntuale a un evento.

3.3 Simulazione di una coda

Fonte A: documento 2, pagine PDF 18–19.

Per la coda $E = \{a, d\}$, lo stato x è il numero di clienti, $f(x, a) = x + 1$ e $f(x, d) = x - 1$ se $x > 0$. L'arrivo è sempre abilitato; la partenza solo a coda non vuota. Con priorità all'arrivo in caso di parità,

$$e' = \begin{cases} d & x > 0 \ \text{ e } \ y_d < y_a \\ a & \text{altrimenti} \end{cases}. \tag{37}$$

Se arriva un cliente quando il servente è occupato, il servizio corrente non ricomincia. Se il cliente arriva a coda vuota, si inizializza il clock del nuovo servizio. Quando una partenza lascia ancora clienti, inizia il servizio del successivo. Quando svuota la coda, non si inizializza alcuna nuova partenza.

$$y'_a = \begin{cases} v_{a,N_a+1} & e' = a \\ y_a - y_d & e' = d \end{cases}, \quad N'_a = N_a + \mathbf{1}_{e'=a}. \tag{38}$$

$$y'_d = \begin{cases} y_d - y_a & e' = a \ \text{ e } \ x > 0 \\ v_{d,N_d+1} & (e' = a \ \text{ e } \ x = 0) \ \text{ oppure } \ (e' = d \ \text{ e } \ x > 1) \end{cases}, \tag{39}$$

$$N'_d = N_d + \mathbf{1}_{(e'=a \ \text{ e } \ x=0) \ \text{ oppure } \ (e'=d \ \text{ e } \ x>1)}. \tag{40}$$

La seconda equazione è definita soltanto quando $x' > 0$ altrimenti il clock d è rimosso. L'indicatore $\mathbf{1}_B$ vale 1 se la condizione B è vera e 0 altrimenti. I campioni v_d rappresentano tempi di servizio e non genericamente intervalli fra partenze: questi ultimi possono includere un periodo d'inattività del servente.

> **Nota tecnica A06.** Nel documento 2, pagina 19, il primo ramo stampato per y'_a associa $y_a - y_d$ alla condizione $e' = a$. Deve essere $e' = d$: solo una partenza fa trascorrere y_d conservando il clock d'arrivo. Inoltre il ramo di rinnovo del clock di servizio va applicato solo quando il nuovo stato è positivo. Correzione certa dalla ricorsione generale.

3.4 Calendario degli eventi

Fonte A: documento 2, pagine PDF 20–21.

Una simulazione può mantenere gli istanti assoluti anziché sottrarre il tempo trascorso da ogni residuo. A un clock appena inizializzato alla data t_n si associa la data programmata $T_i = t_n + v_{i,N_i+1}$. Il calendario è una lista ordinata

$$\mathcal{C} = \{(e_k, T_k) : k = 1, \ldots, m_{\mathcal{C}}\}, \quad m_{\mathcal{C}} \le |E|, \quad T_1 \le T_2 \le \ldots. \tag{41}$$

Il primo elemento è il prossimo evento. Si avanza il tempo alla sua data, si esegue la transizione e si elimina l'elemento estratto. Si rimuovono anche gli eventi divenuti disabilitati; gli eventi persistenti mantengono la data; i nuovi clock sono inseriti con data corrente più durata. Le parità si ordinano con la stessa priorità del modello a residui.

L'equivalenza è esatta perché $y_i = T_i - t$: conservare una data mentre il tempo avanza equivale a diminuire il residuo della medesima quantità. Il vantaggio è implementativo: una struttura a priorità permette di trovare e aggiornare il minimo senza aggiornare numericamente tutti i clock. Occorre però gestire la cancellazione; lasciare nel calendario un evento non più possibile causerebbe una transizione illegittima.

3.5 Esercizio e controllo della soluzione

Fonte A: documento 2, pagine PDF 22–25.

L'esercizio assegna tre stati x_1, x_2, x_3 e tre eventi sempre abilitati. Da x_1, α porta a x_3, β a x_2 e γ lascia lo stato invariato. Da x_2, α porta a x_1, β a x_3 e γ è un cappio. Da x_3, α, β sono cappi e γ porta a x_2. Lo stato iniziale è x_1.

I campioni disponibili sono $V_\alpha = (0, 1, 2.3, 5.6)$, $V_\beta = (0.2, 3.1, 6.4, 9.7)$ e $V_\gamma = (2.2, 5.3)$. Le priorità sono α prima di β prima di γ. Poiché tutti gli eventi rimangono abilitati, le date di ciascun tipo sono somme cumulative dei propri campioni, finché essi sono disponibili:

$$T_\alpha = (0, 1, 3.3, 8.9), \quad T_\beta = (0.2, 3.3, 9.7, 19.4), \quad T_\gamma = (2.2, 7.5). \tag{42}$$

Data	Evento	Prima	Dopo
0	α	x_1	x_3
0.2	β	x_3	x_3
1	α	x_3	x_3
2.2	γ	x_3	x_2
3.3	α	x_2	x_1
3.3	β	x_1	x_2
7.5	γ	x_2	x_2
8.9	α	x_2	x_1
9.7	β	x_1	x_2

Tabella 6: Eventi determinabili dai campioni forniti; le ultime due righe richiedono che i campioni successivi non introducano eventi precedenti.

La permanenza intermedia in x_1 alla data 3.3 ha durata zero. Fino a 7.5 la sequenza è completamente determinata. Dopo la seconda occorrenza di γ manca però il campione successivo; dopo 8.9 manca anche il successivo di α. La probabilità empirica di occupazione su un orizzonte è in realtà una frazione temporale deterministica per questa esecuzione:

$$\hat{\pi}_2(10) = \frac{1}{10}\int_0^{10} \mathbf{1}_{x(t)=x_2}\,\mathrm{d}t. \tag{43}$$

> **Nota tecnica A07.** La soluzione del documento 2, pagina 25, riporta 0.78 mantenendo x_2 da 2.2 a 10, ma ignora α già programmato a 8.9 e β a 9.7. Inoltre le sequenze finite non fissano i nuovi campioni di γ e α: il risultato completo fino a 10 non è univocamente determinato. Se si aggiunge l'ipotesi che nessun campione non fornito produca eventi prima di 10, l'occupazione corretta è $\frac{(8.9-2.2)+(10-9.7)}{10} = 0.70$. L'omissione degli eventi già programmati è certa; il valore 0.70 è condizionato all'ipotesi dichiarata e non viene presentato come unica soluzione dei dati originali.

Il controllo dell'esercizio evidenzia tre responsabilità separate: aggiornare lo stato, mantenere correttamente le date future e disporre di dati sufficienti per tutto l'orizzonte richiesto. Una simulazione formalmente corretta non può colmare campioni mancanti senza una regola aggiuntiva. Il capitolo successivo introduce le leggi probabilistiche con cui tali campioni possono essere generati.

4 Processi stocastici e memoria

4.1 Processi, realizzazioni e distribuzioni

Fonte A: documento 3, pagine PDF 1–6.

Un ingresso casuale non modifica necessariamente la legge di evoluzione, ma trasforma lo stato in una variabile aleatoria dipendente dal tempo. Il modello non predice una singola traiettoria prima che la casualità si realizzi: assegna probabilità a famiglie di traiettorie. Per formalizzarlo si parte da uno spazio di probabilità $(\Omega, \mathcal{F}, P)$, dove Ω contiene gli esiti elementari, $\mathcal{F}$ gli eventi misurabili e P la probabilità.

Un processo stocastico è una famiglia di variabili aleatorie $\{X(t) : t \in \mathcal{T}\}$ sullo stesso spazio, con valori nello spazio di stato $\mathcal{X}$. Si può scrivere $X(\omega, t)$ per evidenziare le due dipendenze. Fissando ω si ottiene una **realizzazione**, cioè una funzione del tempo. Fissando t si ottiene una variabile aleatoria. Fissando entrambi si ottiene un valore. Questo duplice punto di vista collega il grafico di una simulazione alla sua descrizione probabilistica.

Il tempo e lo stato possono essere discreti o continui indipendentemente: il numero di clienti in una coda osservata continuamente ha stato discreto e tempo continuo; la temperatura campionata ha tempo discreto e stato continuo; una catena di simboli letti a passi interi ha entrambi discreti. Una realizzazione di uno stato discreto può avere lunghi tratti costanti senza diventare un processo a tempo discreto.

La distribuzione a un istante è descritta dalla funzione di ripartizione marginale. Per descrivere il processo servono anche le dipendenze fra istanti:

$$\begin{aligned} F_X(x;t) &= P(X(t) \le x), \\ F_X(x_1,\dots,x_n;t_1,\dots,t_n) &= P(X(t_1) \le x_1,\dots,X(t_n) \le x_n). \end{aligned} \tag{44}$$

Le distribuzioni congiunte per ogni numero finito n e ogni scelta degli istanti sono le distribuzioni finito dimensionali. Con sole marginali non si può ricostruire se un processo resta nello stesso valore, alterna valori o li estrae indipendentemente. Due processi possono avere uguale legge in ciascun istante e traiettorie profondamente diverse. Per stati discreti si usano probabilità di massa; per leggi continue eventualmente dotate di densità, la derivata della ripartizione restituisce la densità. Non ogni distribuzione ammette una densità.

> **Nota tecnica A08.** Nel documento 3, pagina 3, $\Omega = \{\mathrm{UP}, \mathrm{DOWN}\}$ è sufficiente a illustrare una singola variabile di stato, ma non contiene tutte le possibili storie di guasti e riparazioni. Per un processo arbitrario il campione elementare deve determinare l'intera traiettoria, ad esempio una successione di durate o una funzione del tempo. Precisazione certa sul significato dello spazio campionario.

4.2 Stazionarietà e indipendenza

Fonte A: documento 3, pagine PDF 7–8.

La stazionarietà stretta richiede che spostare tutti gli istanti della stessa quantità non modifichi alcuna distribuzione congiunta:

$$F_X(x_1,\dots,x_n;t_1,\dots,t_n) = F_X(x_1,\dots,x_n;t_1+h,\dots,t_n+h). \tag{45}$$

L'uguaglianza vale per ogni scelta ammissibile di n, soglie e istanti. Il processo può continuare a cambiare in ogni realizzazione; è la sua legge a non dipendere dall'origine del tempo. Una coda stabile inizializzata vuota ha tipicamente un transitorio: i suoi parametri possono essere costanti senza che il processo sia già stazionario.

Se esistono momenti secondi finiti, la stazionarietà in senso lato richiede media costante e autocorrelazione dipendente solo dal ritardo:

$$m_X(t) = E[X(t)] = m, \quad R_X(s,t) = E[X(s)X(t)] = R_X(t-s), \\ C_X(s,t) = R_X(t-s) - m^2. \tag{46}$$

La covarianza C_X sottrae il prodotto delle medie e misura la dipendenza lineare. La stazionarietà stretta con momenti secondi implica quella in senso lato: le leggi a uno e due istanti sono invarianti. Il contrario non vale in generale, perché primi e secondi momenti non determinano tutte le distribuzioni congiunte. Non si devono quindi sostituire le due definizioni senza ipotesi ulteriori.

Un processo ha valori indipendenti quando ogni famiglia finita a istanti distinti è indipendente:

$$F_X(x_1, ..., x_n; t_1, ..., t_n) = \prod_{k=1}^{n} F_X(x_k; t_k). \tag{47}$$

Se le marginali sono anche identiche, si parla di valori indipendenti e identicamente distribuiti, i.i.d. L'indipendenza non implica da sola che le leggi siano identiche; marginali identiche non implicano indipendenza. Nei modelli a clock useremo sequenze i.i.d. di durate. Ciò non rende i valori successivi dello stato indipendenti: lo stato successivo viene costruito a partire da quello corrente e da un nuovo campione.

4.3 Proprietà di Markov e processi semi-Markov

Fonte A: documento 3, pagine PDF 9–11.

Un processo è markoviano quando, condizionando allo stato presente, la storia passata non aggiunge informazione per prevedere il futuro. A tempo discreto la relazione essenziale è

$$P(X_{k+1} = j \mid X_k = i, X_{k-1} = i_{k-1}, ..., X_0 = i_0) = P(X_{k+1} = j \mid X_k = i). \tag{48}$$

Le uguaglianze si intendono per condizioni di probabilità positiva. La versione continua sostituisce gli indici con istanti ordinati e condiziona al passato fino all'istante corrente. «Assenza di memoria» non significa che passato e futuro siano indipendenti senza condizionamento: il passato può influire sul futuro attraverso lo stato presente. La scelta dello stato è quindi decisiva.

$$P(X(t_{k+1}) \le x_{k+1} \mid X(t_k) = x_k, ..., X(t_0) = x_0) \\ = P(X(t_{k+1}) \le x_{k+1} \mid X(t_k) = x_k). \tag{49}$$

Nelle lezioni le proprietà sono separate in M1, selezione del prossimo stato dipendente dal corrente, e M2, permanenza senza memoria. Per una catena omogenea a tempo continuo, il tempo di permanenza non degenere nello stato ha distribuzione esponenziale. Per una catena a tempo discreto è invece geometrico. Un processo di Markov non omogeneo può avere tassi dipendenti dall'istante assoluto: non si può attribuirgli automaticamente un'esponenziale a parametro costante.

Un processo semi-Markov consente tempi di permanenza generali mantenendo una struttura markoviana ai salti, con una legge del prossimo stato e della durata dipendente dallo stato corrente e, nelle formulazioni generali, dalla destinazione. Il solo stato discreto osservato a un istante arbitrario può non essere markoviano: occorre sapere da quanto tempo vi si permane. Un GSMP con più clock concorrenti è più generale ancora: i residui degli eventi persistenti possono trasportare memoria attraverso più transizioni del sistema.

> **Nota tecnica A09.** L'affermazione del documento 3, pagina 11, che associa ai processi di Markov una permanenza esponenziale va riferita alle catene omogenee a tempo continuo. Le catene a tempo discreto hanno permanenza geometrica. Inoltre il solo stato discreto di un GSMP non soddisfa in generale la proprietà di Markov. Le qualificazioni sono necessarie e certe.

Approfondimento · livello C. Il formalismo di P. W. Glynn, **A GSMP Formalism for Discrete Event Systems**, distingue il descrittore osservato dallo stato interno necessario a generare il futuro. L'aggiunta di variabili supplementari, in particolare dei clock residui, permette di costruire uno stato markoviano sotto opportune ipotesi sui campioni futuri. Questo chiarisce perché una ricorsione locale sullo stato logico non basti a eliminare la memoria temporale. Fonte: articolo originale, sezioni II–V.

4.4 Memoria e ampliamento dello stato

Fonte A: documento 3, pagine PDF 12–14.

L'esempio delle lezioni considera la ricorrenza

$$X_{k+1} = X_k - X_{k-1}, \quad k \geq 1, \quad P(X_0 = 0) = P(X_0 = 1) = P(X_1 = 0) = P(X_1 = 1) = \frac{1}{2}. \tag{50}$$

Le marginali iniziali non fissano la legge congiunta di (X_0, X_1). Per sviluppare i quattro percorsi equiprobabili si aggiunge esplicitamente l'indipendenza iniziale. Con questa ipotesi, ognuna delle quattro coppie ha probabilità $\frac{1}{4}$ e l'evoluzione successiva è deterministica.

Coppia iniziale	X_0	X_1	X_2	X_3	X_4	X_5	X_6
(0,0)	0	0	0	0	0	0	0
(0,1)	0	1	1	0	−1	−1	0
(1,0)	1	0	−1	−1	0	1	1
(1,1)	1	1	0	−1	−1	0	1

Tabella 7: Realizzazioni della ricorrenza, con coppie iniziali equiprobabili.

Lo stesso valore presente può provenire da storie differenti. Quando $X_2 = 0$ si è nel percorso iniziale $(0, 0)$ oppure $(1, 1)$. Nel primo caso $X_3 = 0$, nel secondo $X_3 = -1$. Pertanto

$$P(X_3 = -1 \mid X_2 = 0) = \frac{1}{2}, \quad P(X_3 = -1 \mid X_2 = 0, X_1 = 1) = 1. \tag{51}$$

La differenza dimostra che X_k non è markoviano sotto questa legge iniziale. Non sarebbe corretto invocare soltanto la presenza di X_{k-1} nella formula come prova universale: con particolari leggi degeneri la storia aggiuntiva potrebbe essere già determinata dal presente. Qui le due storie hanno entrambe probabilità positiva e forniscono una verifica effettiva.

Il confronto con la Equazione 3 è utile: come posizione e velocità chiudono il modello meccanico, la coppia di valori successivi chiude qui la memoria della ricorrenza.

Il test delle lezioni usa già il passo precedente e conduce alla stessa conclusione:

$$P(X_2 = 0 \mid X_1 = 0, X_0 = 0) = 1, \quad P(X_2 = 0 \mid X_1 = 0, X_0 = 1) = 0. \tag{52}$$

Si ripara il descrittore, non la ricorrenza, definendo $Z_k = (X_k, X_{k-1})^T$ per $k \geq 1$:

$$Z_{k+1} = \begin{pmatrix} 1 & -1 \\ 1 & 0 \end{pmatrix} Z_k = A Z_k. \tag{53}$$

Il futuro di Z dipende solo da Z_k. La transizione è deterministica, caso particolare di una transizione markoviana con probabilità 1. In questo modello $A^3 = -I$ e $A^6 = I$, come si verifica moltiplicando le matrici; le traiettorie sono quindi periodiche con periodo che divide 6. Questa osservazione ricostruita spiega il ripetersi dei valori nella tabella senza introdurre ulteriore casualità.

> **Nota tecnica A10.** Nel documento 3, pagine 12–13, le quattro realizzazioni non hanno probabilità determinabili dalle sole marginali indicate. Il peso $\frac{1}{4}$ richiede l'indipendenza di X_0 e X_1, qui dichiarata. Il controesempio alla proprietà di Markov usa tale ipotesi, o più in generale una legge che dia peso positivo alle storie distinguibili. Nell'elenco a pagina 12 il quarto percorso ripete quello con coppia iniziale $(1,0)$: la tabella ricostruisce invece anche la coppia $(1,1)$ direttamente dalla ricorrenza.

Lo stesso principio verrà applicato ai DES: per durate generali si conservano residui ed eventuali informazioni sul campione in uso; con durate esponenziali la proprietà di assenza di memoria consentirà invece di eliminarli dalla descrizione probabilistica del futuro. È questo passaggio, e non una semplice scelta di notazione, a collegare i GSMP alle catene di Markov.

5 GSMP e processi di Poisson

5.1 Clock stocastici e GSMP

Fonte A: documento 4, pagine PDF 1–7.

La struttura di clock deterministica assegnava un elenco di durate. La struttura stocastica assegna invece le loro distribuzioni $G = \{G_i : i \in \mathcal{E}\}$, con $G_i(t) = P\big(V_{i,k} \le t\big)$. Nel modello delle lezioni i campioni di uno stesso tipo sono i.i.d.; le sequenze di tipi diversi sono indipendenti. L'indipendenza è un'ipotesi di semplicità, non una proprietà universale dei sistemi reali: tempi di lavorazione correlati richiederebbero un modello più ricco.

Si rende casuale anche lo stato iniziale, con legge $p_0(x) = P(X_0 = x)$, e si consente che l'evento non determini univocamente la destinazione. Il nucleo $p(x'; x, e)$ indica la probabilità del nuovo stato x' dato il corrente x e l'evento trigger e:

$$p(x'; x, e) = P(X' = x' \mid X = x, E' = e), \quad \sum_{x' \in \mathcal{X}} p(x'; x, e) = 1 \quad \text{per } e \in \Gamma(x). \tag{54}$$

Per eventi disabilitati si pone $p(x'; x, e) = 0$. Nel caso deterministico, $p(x'; x, e) = \mathbf{1}_{x' = f(x,e)}$. Il modello è la sestupla

$$G_{\text{st}} = (\mathcal{E}, \mathcal{X}, \Gamma, p, p_0, G). \tag{55}$$

Il meccanismo esecutivo resta quello già studiato. Si estrae lo stato iniziale, si inizializzano i clock abilitati e si confrontano i residui. Identificato il trigger, si estrae la destinazione secondo p; quindi si aggiornano abilitazioni e clock. Con $P = (\Gamma(X) \cap \Gamma(X')) \setminus \{E'\}$ e $A = \Gamma(X') \setminus P$,

$$Y^* = \min_{i \in \Gamma(X)} Y_i, \quad E' = \arg\min_{i \in \Gamma(X)} Y_i, \quad T' = T + Y^*, \tag{56}$$

$$Y_i' = \begin{cases} Y_i - Y^* & i \in P \\ V_{i, N_i + 1} & i \in A, \end{cases} \quad N_i' = N_i + \mathbf{1}_{i \in A}. \tag{57}$$

I campioni nuovi hanno le leggi specificate e sono indipendenti dalle estrazioni già consumate secondo le ipotesi del modello. I residui sono definiti soltanto per gli eventi attivi. Condizionatamente all'iniziale, si pone $Y_i = V_{i,1}$ e $N_i = 1$ se $i \in \Gamma(X_0)$, altrimenti $N_i = 0$. Le estrazioni continue indipendenti eliminano normalmente le parità con probabilità uno; la priorità rimane necessaria per modelli con atomi, durate deterministiche o simultaneità imposta.

Un processo ottenuto così è un processo semi-Markov generalizzato, GSMP. La legge del tempo fino al prossimo evento emerge dalla competizione dei clock, non viene assegnata direttamente a ogni stato. In un processo semi-Markov, invece, è specificata una legge del salto e della durata condizionata al descrittore corrente. Il GSMP può conservare clock di eventi avviati in stati precedenti: il descrittore logico X non elimina tale memoria.

> **Nota tecnica A11.** Il documento 4, pagina 6, scrive $T' = Y + Y^*$: il primo termine deve essere il tempo corrente T. A pagina 7 il GSMP è detto soddisfare M1 sul solo stato discreto; ciò non vale in generale perché l'evento vincente dipende dai residui ereditati. La formulazione è corretta sullo stato ampliato opportuno, o in casi speciali come i clock esponenziali. Correzioni certe.

5.2 Esempi e contatori

Fonte A: documento 4, pagine PDF 8–12.

L'esempio a tre stati riprende quello del capitolo 3: $p(1; 0, \alpha) = p(2; 0, \beta) = p(2; 1, \alpha) = p(0; 2, \beta) = p(1; 2, \alpha) = 1$, e tutte le altre destinazioni hanno probabilità zero. Le durate $(1, 1.5, 1.5, \ldots)$ e $(2, 0.5, 1.5, \ldots)$ sono ora una possibile realizzazione delle leggi G_α, G_β. Condizionando a questi campioni e a $X_0 = 0$, si ottiene

la stessa tabella già calcolata: eventi a 1, 2.5, 3 e 4, con stati 1,2,0,1. La casualità del modello non richiede una nuova regola di esecuzione.

> **Nota tecnica A12.** Nel documento 4, pagina 9, dopo il terzo evento è scritto $N_{\alpha,3} = 4$, ma il clock di α è persistente e il contatore resta 3. Nella stessa pagina l'ultimo tempo è scritto $t_4 = t_2 + y_3^*$: deve essere $t_3 + y_3^*$. Entrambe le correzioni sono certe e coerenti con il diagramma della pagina 10.

La coda con arrivi deterministici ogni unità e servizi generali è un altro GSMP. Si ha $p_0(0) = 1$, $V_{a,k} = 1$ per ogni k, mentre $V_{d,k}$ segue una legge generale G_d. Il modello è indicato successivamente con D/G/1. L'arrivo è sempre attivo, il completamento solo a coda non vuota. Il grafico delle lezioni mostra arrivi equispaziati e partenze non equispaziate: le variazioni verticali di $X(t)$ sono $+1$ e -1; i segmenti orizzontali rappresentano la permanenza fra eventi. Un intervallo fra partenze può includere inattività e non coincide necessariamente con una durata di servizio.

La figura riporta questo esempio campione: in ascissa il tempo, in ordinata il numero presente; sopra sono segnati gli arrivi a distanza unitaria e sotto le partenze, con intervalli irregolari. Il tratto in cui $X = 0$ rappresenta inattività e spiega perché alcuni intervalli fra partenze includono più del solo servizio.

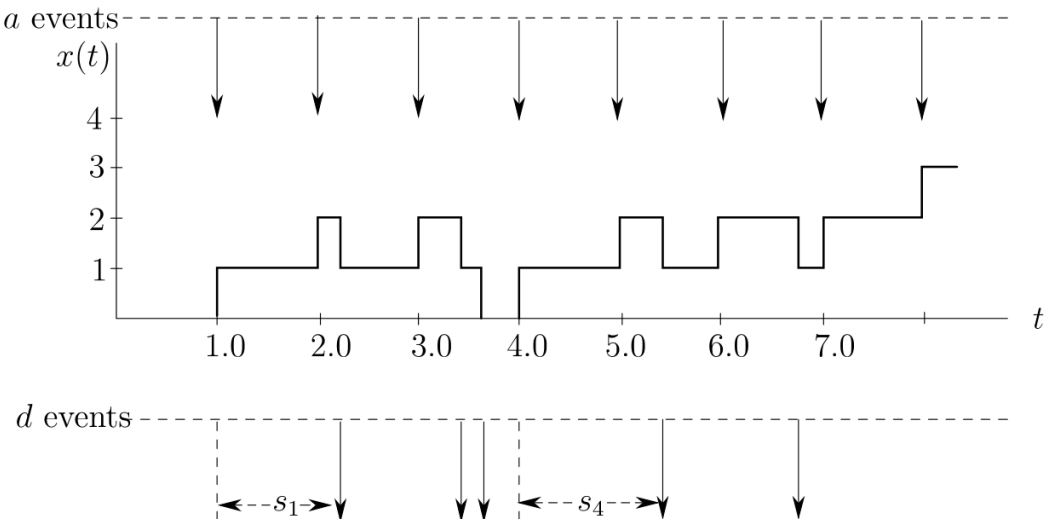


Figura 17: Evoluzione di una coda con arrivi deterministici e servizi generali. Documento 4, pagina 11.

Le quantità di interesse sono le probabilità $P(X(t) = x)$, la successione delle durate interevento Y_k^*, la successione dei tipi di evento e i conteggi. Per evitare una confusione della fonte, riserviamo $D_i(t)$ al numero di **occorrenze** di tipo i entro t, e manteniamo N_i per le **attivazioni del clock**. Con cancellazioni i due conteggi non coincidono. Inoltre un evento può essere un cappio: in tal caso si è avuto un evento, ma non un'uscita dallo stato. Anche il tempo fra eventi e il tempo di permanenza prima di un vero cambio di stato vanno distinti.

5.3 Definizione del processo di Poisson

Fonte A: documento 4, pagine PDF 13–20.

Consideriamo ora un unico tipo di evento e il processo $N(t)$ che conta le sue occorrenze in $(0, t]$. Questo $N(t)$ è un conteggio di occorrenze e non il precedente puntatore dei clock. Si assume $N(0) = 0$ e traiettorie non decrescenti a valori interi; l'incremento nell'intervallo $(s, t]$ è $N(s, t) = N(t) - N(s)$. Il processo di Poisson omogeneo ha incrementi indipendenti e stazionari: conteggi su intervalli disgiunti sono indipendenti e la loro legge dipende solo dalla lunghezza dell'intervallo.

Le lezioni aggiungono che non accadono due eventi nello stesso istante. Per rendere esplicito il passaggio infinitesimale adottiamo la consueta regolarità del processo semplice, non esplosivo, a intensità finita λ:

$$P(N(t, t+h) = 1) = \lambda h + o(h), \quad P(N(t, t+h) \geq 2) = o(h), \quad h \downarrow 0. \tag{58}$$

Di conseguenza la probabilità di nessun evento è $1-\lambda h+o(h)$. L'intensità ha dimensione tempo^{-1}, e λh è adimensionale. Il simbolo $o(h)$ indica un resto il cui rapporto con h tende a zero. La sola esclusione di eventi simultanei, isolata dalle condizioni di regolarità, non va usata come giustificazione automatica di ogni sviluppo al primo ordine.

Poniamo $P_n(t)=P(N(t)=n)$. Non avere eventi fino a $t+s$ significa non averne in $(0,t]$ e in $(t,t+s]$. L'indipendenza e la stazionarietà degli incrementi danno

$$P_0(t+s)=P_0(t)P_0(s),\quad P_0(0)=1. \tag{59}$$

Il lemma delle lezioni considera una funzione differenziabile g con $g(t+s)=g(t)g(s)$, $g(0)=1$ e valori in $[0,1]$. Si sottrae $g(t)$ e si divide per s:

$$\frac{g(t+s)-g(t)}{s}=g(t)\frac{g(s)-1}{s}\to g(t)g'(0),\quad g'(t)=cg(t),\quad g(t)=e^{ct}. \tag{60}$$

Poiché $g(t)\le 1$ per $t\ge 0$, deve essere $c\le 0$. Scrivendo $c=-\lambda$ si ottiene $P_0(t)=e^{-\lambda t}$. Il caso $\lambda=0$ corrisponde al processo senza eventi; per un processo non degenere si assume $\lambda>0$. Lo sviluppo di Taylor $e^{-\lambda h}=1-\lambda h+o(h)$ restituisce le probabilità infinitesimali.

> **Nota tecnica A13.** Il lemma del documento 4, pagine 17–18, conclude $\lambda>0$ dalle sole ipotesi indicate. Esse ammettono anche $g=1$ e dunque $\lambda=0$. La positività stretta richiede l'esclusione del caso degenere. Correzione certa.

5.4 Legge di conteggio e momenti

Fonte A: documento 4, pagine PDF 21–24.

Per determinare P_n si condiziona al numero di eventi nel breve intervallo finale. La formula esatta è una convoluzione finita; isolando i termini con zero o un evento,

$$P_n(t+h)=\sum_{k=0}^{n}P_{n-k}(t)P_k(h)=P_n(t)(1-\lambda h)+P_{n-1}(t)\lambda h+o(h). \tag{61}$$

Per $n=0$ il termine con indice -1 è assente. Sottraendo $P_n(t)$, dividendo per h e passando al limite si ottengono le equazioni

$$\dot P_0=-\lambda P_0,\quad \dot P_n=-\lambda P_n+\lambda P_{n-1}\quad (n\ge 1),\quad P_0(0)=1,\quad P_n(0)=0\quad (n\ge 1). \tag{62}$$

Il termine negativo rappresenta la perdita di probabilità dal conteggio n per un nuovo arrivo; il positivo rappresenta l'ingresso dal conteggio $n-1$. Per risolvere la ricorrenza si moltiplica per il fattore integrante $e^{\lambda t}$:

$$\frac{\mathrm{d}\left(e^{\lambda t}P_n(t)\right)}{\mathrm{d}t}=\lambda e^{\lambda t}P_{n-1}(t),\quad P_n(t)=e^{-\lambda t}\int_0^t \lambda e^{\lambda u}P_{n-1}(u)\,\mathrm{d}u. \tag{63}$$

L'induzione parte da $P_0=e^{-\lambda t}$. Se $P_{n-1}(u)=e^{-\lambda u}\frac{(\lambda u)^{n-1}}{(n-1)!}$, nell'integrale rimane $\lambda^n\frac{u^{n-1}}{(n-1)!}$; integrando si ottiene

$$P_n(t)=e^{-\lambda t}\frac{(\lambda t)^n}{n!},\quad n=0,1,2,\dots. \tag{64}$$

La normalizzazione segue dalla serie esponenziale: la somma su n è $e^{-\lambda t}e^{\lambda t}=1$. Il numero atteso di eventi cresce linearmente con il tempo, mentre il tasso rimane costante. Ponendo $a=\lambda t$ e spostando l'indice nelle somme,

$$E[N(t)]=e^{-a}\sum_{n=1}^{\infty}n\frac{a^n}{n!}=a,\quad E[N(t)(N(t)-1)]=a^2,\quad E\left[N(t)^2\right]=a^2+a. \tag{65}$$

La seconda identità usa $\frac{n(n-1)}{n!} = \frac{1}{(n-2)!}$. Sottraendo il quadrato della media si conclude $\mathrm{Var}(N(t)) = \lambda t$. Media e varianza sono numericamente uguali per la legge di Poisson; non sono uguali media e deviazione standard. Aumentando l'orizzonte, la fluttuazione assoluta cresce come $\sqrt{\lambda t}$, quella relativa diminuisce come $\frac{1}{\sqrt{\lambda t}}$.

5.5 Tempi esponenziali e assenza di memoria

Fonte A: documento 4, pagine PDF 25–29.

Il primo evento arriva dopo t se e solo se non si è verificato alcun evento entro t. Se V è il primo tempo d'attesa,

$$P(V > t) = P_0(t) = e^{-\lambda t}, \quad G(t) = 1 - e^{-\lambda t}, \quad g(t) = \lambda e^{-\lambda t} \quad (t \geq 0). \tag{66}$$

Per tempi negativi la ripartizione è zero. Gli incrementi indipendenti e la ripartenza del processo dopo un evento forniscono tempi fra occorrenze indipendenti con questa stessa legge. Viceversa, una successione di tempi esponenziali indipendenti di parametro λ genera il processo di conteggio di Poisson. L'intensità e il tempo medio sono reciproci, non identici.

I momenti si ricavano per integrazione. Usando integrazione per parti e il fatto che una potenza di t moltiplicata per $e^{-\lambda t}$ tende a zero,

$$E[V] = \int_0^\infty t\lambda e^{-\lambda t}\,\mathrm{d}t = \frac{1}{\lambda}, \quad E[V^2] = \int_0^\infty t^2\lambda e^{-\lambda t}\,\mathrm{d}t = \frac{2}{\lambda^2}, \quad \mathrm{Var}(V) = \frac{1}{\lambda^2}. \tag{67}$$

La media ha unità di tempo e la varianza di tempo al quadrato. Il parametro λ non è una probabilità e può superare numericamente 1 se si cambia l'unità temporale.

Supponiamo che il clock abbia già raggiunto età z senza scadere. La ripartizione della vita residua è

$$P(V - z \leq t \mid V > z) = \frac{G(z+t) - G(z)}{1 - G(z)}. \tag{68}$$

Per l'esponenziale la sopravvivenza condizionata semplifica:

$$P(V > z + t \mid V > z) = \frac{e^{-\lambda(z+t)}}{e^{-\lambda z}} = e^{-\lambda t} = P(V > t). \tag{69}$$

La probabilità di attendere ancora una certa durata non dipende dall'età. Non significa che il servizio accumulato venga fisicamente annullato; significa che la legge condizionata del futuro è uguale a quella iniziale. Per una durata deterministica di 10, sapere che sono trascorse 9 unità cambia invece radicalmente la previsione: resta esattamente 1.

La caratterizzazione è anche inversa. Se una durata non negativa e non degenere soddisfa questa proprietà, la sopravvivenza S verifica $S(z+t) = S(z)S(t)$ e $S(0) = 1$. Con la regolarità di una distribuzione propria, la soluzione è $S(t) = e^{-\lambda t}$ con $\lambda > 0$. Il lemma già dimostrato fornisce la versione differenziabile del ragionamento. Questa unicità spiega il ruolo speciale dell'esponenziale nei modelli markoviani a tempo continuo.

5.6 Sovrapposizione e competizione

Fonte A: documento 4, pagine PDF 30–39.

Sovrapporre processi di Poisson indipendenti significa contare tutti i loro eventi. Per due sorgenti di intensità λ_1, λ_2, la convoluzione delle leggi dà

$$P(N_1(t) + N_2(t) = n) = e^{-(\lambda_1+\lambda_2)t} \sum_{k=0}^{n} \frac{(\lambda_1 t)^k}{k!} \frac{(\lambda_2 t)^{n-k}}{(n-k)!} = e^{-(\lambda_1+\lambda_2)t} \frac{((\lambda_1+\lambda_2)t)^n}{n!}. \tag{70}$$

La somma intermedia è lo sviluppo binomiale dopo aver raccolto $\frac{t^n}{n!}$. L'indipendenza degli incrementi è conservata perché gli incrementi delle sorgenti su intervalli disgiunti sono indipendenti. La somma è quindi un processo di Poisson di tasso somma; la conclusione non vale per sorgenti arbitrariamente dipendenti.

Nel DES, in un dato stato x, competono soltanto gli eventi abilitati. Se i loro residui sono esponenziali indipendenti con parametri λ_i, si pone

$$\Lambda(x) = \sum_{i \in \Gamma(x)} \lambda_i, \quad P(Y^* > t \mid X = x) = \prod_{i \in \Gamma(x)} e^{-\lambda_i t} = e^{-\Lambda(x) t}. \tag{71}$$

Il tempo fino al prossimo evento è dunque esponenziale di parametro $\Lambda(x)$, con media $\frac{1}{\Lambda(x)}$. Lo stato condiziona l'insieme degli eventi: il tasso totale non è necessariamente costante lungo tutta la traiettoria, anche se ogni tipo ha un parametro costante.

Per trovare la probabilità che vinca i, si integra sulla sua data di scadenza. Il clock i scade a t con densità $\lambda_i e^{-\lambda_i t}$ e tutti gli altri devono sopravvivere fino a t:

$$P(E' = i \mid X = x) = \int_0^\infty \lambda_i e^{-\lambda_i t} \prod_{j \in \Gamma(x), j \neq i} e^{-\lambda_j t} \, \mathrm{d}t = \frac{\lambda_i}{\Lambda(x)}. \tag{72}$$

La derivazione equivalente delle lezioni considera $W = \min_{j \neq i} Y_j$ di tasso $\Lambda_i = \Lambda - \lambda_i$ e integra $P(Y_i < W) = \int_0^\infty \big(1 - e^{-\lambda_i w}\big) \Lambda_i e^{-\Lambda_i w} \, \mathrm{d}w = \frac{\lambda_i}{\lambda_i + \Lambda_i}$. Se i è l'unico evento attivo, vince con probabilità 1 e non serve introdurre un'esponenziale di parametro zero per W.

La densità congiunta di durata e vincitore è $\lambda_i e^{-\Lambda t}$. Essa si fattorizza come $\left(\frac{\lambda_i}{\Lambda}\right) \Lambda e^{-\Lambda t}$: condizionatamente allo stato, durata fino al prossimo evento e tipo vincente sono indipendenti in questa competizione esponenziale. È una proprietà più forte della sola formula del minimo.

> **Nota tecnica A14.** Nel documento 4, pagine 36 e 39, la quantità indicata con $p(i, x)$ è usata come probabilità del tipo di evento **dato** lo stato, cioè $P(E' = i | X = x)$, non come probabilità congiunta. Il formulario deve inoltre usare $\Lambda(x) = \sum_{i \in \Gamma(x)} \lambda_i$, non la somma di tutti i tipi anche disabilitati. Precisazioni certe.

5.7 Code e riduzione markoviana

Fonte A: documento 4, pagine PDF 40–47.

Nella coda FIFO a due classi, gli arrivi indipendenti hanno tassi λ_1, λ_2 e il servizio del cliente di classe i ha tasso μ_i. Se i tassi di servizio dipendono dalla classe, il solo numero totale non identifica il futuro: occorre conoscere almeno la classe in servizio e, per aggiornare correttamente dopo le partenze, l'ordine delle classi in attesa. Una parola di classi, ad esempio $(1, 2, 1)$, è uno stato adeguato alla logica FIFO e ai tassi esponenziali.

A sistema vuoto competono solo i due arrivi: l'inattività media è $\frac{1}{\lambda_1 + \lambda_2}$. Se è in servizio una classe 1, competono i due arrivi e la partenza; la probabilità che il prossimo evento sia il completamento è $\frac{\mu_1}{\lambda_1 + \lambda_2 + \mu_1}$. Non si deve aggiungere μ_2 se un cliente di classe 2 è solo in attesa e non possiede un servizio attivo.

Per una sola classe con arrivi λ e servizio μ, consideriamo il numero K di nuovi arrivi durante un singolo servizio iniziato. A ogni competizione fra prossimo arrivo e completamento, l'arrivo vince con probabilità $\frac{\lambda}{\lambda + \mu}$ e il completamento con $\frac{\mu}{\lambda + \mu}$. La proprietà senza memoria consente di ripetere il ragionamento dopo ogni arrivo:

$$P(K = k) = \left(\frac{\lambda}{\lambda + \mu}\right)^k \frac{\mu}{\lambda + \mu}, \quad P(K \geq k) = \left(\frac{\lambda}{\lambda + \mu}\right)^k, \quad E[K] = \frac{\lambda}{\mu}. \tag{73}$$

La legge geometrica su $k = 0, 1, \ldots$ si verifica anche condizionando alla durata V del servizio: $P(K = k) = \int_0^\infty e^{-\lambda t} \frac{(\lambda t)^k}{k!} \mu e^{-\mu t} \, \mathrm{d}t$. L'integrale gamma elementare $\int_0^\infty t^k e^{-at} \, \mathrm{d}t = \frac{k!}{a^{k+1}}$ restituisce la stessa espressione. Si conta un intervallo di servizio, non l'intero periodo durante il quale il servente rimane occupato servendo più clienti.

Con tutti i clock esponenziali indipendenti, i residui degli eventi persistenti hanno ancora la legge iniziale dopo la transizione. Nel modello probabilistico è quindi possibile rinnovare tutti i clock attivi senza cambiare la legge delle traiettorie. Questa semplificazione non è valida con durate generali. Il prossimo stato dipende dal corrente attraverso la miscela dei tipi vincenti:

$$p(x', x) = \sum_{i \in \Gamma(x)} p(x'; x, i) \frac{\lambda_i}{\Lambda(x)}. \tag{74}$$

La somma su x' vale 1 perché ogni nucleo condizionato è normalizzato e i pesi dei trigger sommano a 1. Si ottiene una catena ai tempi degli eventi, accompagnata da tempi di attesa esponenziali. Se alcuni eventi sono cappi, questa catena può restare nello stesso stato; il vero tempo prima di cambiare stato ha tasso inferiore al tasso di tutti gli eventi. Il generatore del capitolo 7 terrà conto di questa distinzione.

Il risultato centrale è la possibilità di eliminare dalla previsione probabilistica l'età dei clock, mantenendo lo stato logico abbastanza ricco da identificare abilitazioni e tassi. Le catene di Markov dei prossimi capitoli nascono da questa proprietà strutturale, mentre i GSMP generali rimangono il riferimento per simulare servizi e arrivi non esponenziali.

Le formule Equazione 34 e Equazione 36 restano la base della simulazione generale; la Equazione 74 spiega la semplificazione probabilistica specifica dei clock esponenziali.

6 Catene di Markov a tempo discreto

6.1 Specifica di una catena e primi esempi

Fonte A: documento 5, pagine PDF 1–10; 21–23.

Una catena di Markov a tempo discreto descrive una successione $X_0, X_1, \dots$ su uno spazio finito o numerabile. Un passo può essere un intervallo di campionamento, un anno accademico oppure un indice di evento: l'interpretazione deve essere fissata prima di costruire le probabilità. Lo stato deve contenere l'informazione che rende il futuro condizionatamente indipendente dal passato. La catena è specificata da una legge iniziale e dalle probabilità di transizione a un passo.

$$p_{ij}(k) = P(X_{k+1} = j \mid X_k = i), \quad p_{ij}(k) \geq 0, \quad \sum_j p_{ij}(k) = 1, \quad P(k) = \big[p_{ij}(k)\big]. \tag{75}$$

L'indice di riga è il corrente, quello di colonna il successivo. La matrice è stocastica per righe. Con vettore riga $\Pi(k)$, il prodotto futuro sarà a destra; con un vettore colonna, come in una prima parte delle lezioni, comparirà la trasposta. Le due convenzioni sono equivalenti se mantenute coerenti.

Nel modello del percorso universitario, gli stati 1,2,3 rappresentano gli anni di corso, 4 la laurea e 5 l'abbandono. La permanenza in un anno descrive una ripetizione; laurea e abbandono sono assorbenti. La matrice data è

$$P = \begin{pmatrix} .2 & .6 & 0 & 0 & .2 \\ 0 & 0 & .58 & .4 & .02 \\ 0 & 0 & .48 & .5 & .02 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{pmatrix}. \tag{76}$$

Le probabilità non dipendono dall'anno solare del passo: è un'ipotesi del modello, non una conclusione sui dati reali. Partendo dal primo anno, $\Pi(0) = (1, 0, 0, 0, 0)$, la prima riga dà $\Pi(1) = (.2, .6, 0, 0, .2)$. Al secondo passo ogni stato riceve probabilità dai possibili predecessori. Per esempio la laurea riceve $.6 \times .4 = .24$ e l'abbandono riceve $.2 \times .2 + .6 \times .02 + .2 \times 1 = .252$:

$$\Pi(2) = (.04, .12, .348, .24, .252). \tag{77}$$

La somma è 1. La probabilità di laurea dopo due passi è .24, mentre la probabilità di essere ancora nel primo anno è $.2^2 = .04$. Questo controllo di normalizzazione è indispensabile: un singolo errore decimale può rendere impossibile l'intera distribuzione.

> **Nota tecnica A15.** Il documento 5, pagina 7, stampa .4 anziché .04 per la prima componente della distribuzione al secondo passo. Il prodotto della matrice dà .04; il vettore con .4 somma a 1.36. Correzione certa.

Nel centralino a una sola linea lo stato 0 indica libero, 1 occupato. In ogni slot arriva al più una richiesta con probabilità α e una chiamata in corso termina con probabilità β, indipendentemente. La convenzione accetta un nuovo arrivo se nello stesso slot termina la chiamata precedente. Si ottiene

$$P = \begin{pmatrix} 1-\alpha & \alpha \\ \beta(1-\alpha) & 1-\beta(1-\alpha) \end{pmatrix}. \tag{78}$$

Da occupato a libero servono contemporaneamente completamento e assenza di arrivo. Tutti gli altri casi lasciano la linea occupata, compreso un nuovo arrivo perso oppure una sostituzione del cliente. Lo stesso stato futuro può quindi riunire esiti fisici diversi. Per contare le perdite occorre una ricompensa associata all'evento o un descrittore aggiuntivo, non soltanto osservare che il sistema è rimasto occupato.

6.2 Chapman–Kolmogorov e omogeneità

Fonte A: documento 5, pagine PDF 11–20.

Le probabilità su più passi si ottengono sommando su tutti gli stati intermedi. Definiamo $h_{ij}(k,k+n)=P(X_{k+n}=j|X_k=i)$ e la matrice $H(k,k+n)$. Per un istante intermedio $k+m$,

$$\begin{aligned} h_{ij}(k,k+n)&=\sum_{\ell} h_{i\ell}(k,k+m)h_{\ell j}(k+m,k+n),\\ H(k,k+n)&=H(k,k+m)H(k+m,k+n). \end{aligned} \tag{79}$$

La dimostrazione usa la partizione secondo $X_{k+m}=\ell$ e la proprietà di Markov per eliminare la dipendenza dal passato nel secondo tratto. Non richiede indipendenza non condizionata dei due segmenti. L'ordine dei prodotti matriciali segue l'ordine cronologico; invertirlo può cambiare il risultato.

La forma in avanti aggiunge l'ultimo passo; quella all'indietro separa il primo:

$$H(k,k+n)=H(k,k+n-1)P(k+n-1)=P(k)H(k+1,k+n),\quad H(k,k)=I. \tag{80}$$

Iterando si ottiene $H(k,k+n)=P(k)P(k+1)\dots P(k+n-1)$. Le somme di riga rimangono 1, perché il prodotto di matrici stocastiche per righe è ancora stocastico. Gli elementi non negativi sommano le probabilità dei percorsi che collegano i due estremi.

La catena è **omogenea** quando $p_{ij}(k)=p_{ij}$ non dipende da k. In questo caso

$$H(k,k+n)=P^n,\quad p_{ij}^{(n)}=(P^n)_{ij},\quad P^0=I. \tag{81}$$

La notazione $p_{ij}^{(n)}$ indica una probabilità in n passi e non la potenza numerica $\left(p_{ij}\right)^n$. Per esempio $\left(P^2\right)_{ij}=\sum_{\ell}p_{i\ell}p_{\ell j}$ contiene tutti i cammini a due passi. Una matrice costante rende invariante la legge della transizione nel tempo; non rende stazionaria la distribuzione di X_k per qualunque inizializzazione.

Le equazioni di Chapman–Kolmogorov offrono due modi di ragionare sullo stesso problema: enumerare i percorsi per pochi passi oppure moltiplicare matrici per sommarli automaticamente. L'enumerazione è utile per controllare casi limite e convenzioni; il prodotto è più efficiente quando il numero di cammini cresce. Nel caso numerabile infinito le somme sono giustificate dalla non negatività, ma il calcolo numerico richiede una gestione esplicita dell'eventuale troncamento.

6.3 Permanenza e distribuzioni di stato

Fonte A: documento 5, pagine PDF 24–28.

Entrando nello stato i, sia $V(i)$ il numero di passi trascorsi prima del primo passaggio a uno stato diverso. Occorrono $n-1$ autoritorni e poi un'uscita:

$$P(V(i)=n)=p_{ii}^{n-1}(1-p_{ii}),\quad n\geq 1,\quad P(V(i)>n)=p_{ii}^{n},\quad E[V(i)]=\frac{1}{1-p_{ii}}. \tag{82}$$

È una geometrica sul supporto $\{1,2,\dots\}$ con parametro di uscita $1-p_{ii}$. Alcuni testi chiamano parametro la probabilità di permanenza: va sempre letta la formula. La media si ricava dalla somma delle code $\sum_{n=0}^{\infty}p_{ii}^n$. Per $p_{ii}=0$ si esce necessariamente al passo seguente; per $p_{ii}=1$ lo stato è assorbente e la permanenza è infinita.

L'assenza di memoria segue da $P(V>m+n|V>m)=\frac{p_{ii}^{m+n}}{p_{ii}^{m}}=p_{ii}^{n}$. Il passato non modifica il numero di ulteriori passi da attendere, finché si sa soltanto di essere ancora nello stato. Il tempo medio fisico è $TE[V]$ se ogni passo dura T.

Indicando con $\pi_j(k)=P(X_k=j)$ la probabilità non condizionata, la probabilità totale dà

$$\begin{aligned} \pi_j(k+1)&=\sum_i \pi_i(k)p_{ij}(k),\\ \Pi(k+1)&=\Pi(k)P(k),\quad \Pi(k)=\Pi(0)P^k \ \text{ se omogenea.} \end{aligned} \tag{83}$$

Le componenti di $\Pi(k)$ non sono i valori dello stato, ma i pesi con cui gli stati possono presentarsi. Se si vogliono probabilità congiunte, la proprietà di Markov permette anche $P(X_k = i, X_{k+n} = j) = \pi_i(k)(P^n)_{ij}$. Questa distinzione evita di usare un elemento di P^n quando lo stato iniziale è casuale e va mediato.

6.4 Analisi transitoria: roulette e processori

Fonte A: documento 5, pagine PDF 29–38.

Nel gioco della roulette lo stato è il capitale intero non negativo. Ogni giocata su un colore vince un'unità con probabilità $p = \frac{18}{37}$ e perde un'unità con probabilità $q = \frac{19}{37}$ raggiunto 0 il giocatore si arresta. Quindi $p_{00} = 1$, $p_{i,i+1} = p$, $p_{i,i-1} = q$ per $i \geq 1$. Partendo da 3, arrivare a 6 dopo esattamente cinque giocate richiede quattro vittorie e una sconfitta. La singola sconfitta può occupare ciascuna delle cinque posizioni senza toccare 0:

$$P(X_5 = 6 | X_0 = 3) = \binom{5}{1} p^4 q = 5\left(\frac{18}{37}\right)^4 \left(\frac{19}{37}\right) \approx .1436. \tag{84}$$

Per un capitale finale positivo j dopo n passi, la parità richiede che $j - 3$ e n abbiano la stessa parità. Gli esiti che hanno già raggiunto 0 devono essere trattati con l'assorbimento; per essi non vale una semplice prosecuzione della passeggiata su tutti gli interi. «Raddoppiare entro cinque giocate» è inoltre un evento diverso da «avere capitale 6 al quinto passo», che è quello calcolato nella formula.

Una martingala integrabile soddisfa $E[X_{k+1} | X_0, \ldots, X_k] = X_k$. Per una catena, ciò richiede $\sum_j j p_{ij} = i$ in ogni stato pertinente. Nella roulette, per $i > 0$, l'incremento atteso è $p - q = -\frac{1}{37}$ non si ha una martingala del capitale. Il risultato nasce dal vantaggio del banco e non dalla memoria delle vincite precedenti. La proprietà di Markov e quella di martingala sono distinte: la prima riguarda la dipendenza condizionata, la seconda la media condizionata.

Il secondo esempio ha due processori identici, al più un arrivo per slot con probabilità α e un completamento indipendente per ogni processore impegnato con probabilità β. Un arrivo può occupare un posto liberato nello stesso slot; se entrambi erano disponibili si assegna il job al processore 1. Lo stato X_k è il numero di processori occupati. La scelta del processore non influisce sul conteggio, grazie all'uguaglianza dei tassi di completamento.

$$\begin{aligned} p_{00} = 1 - \alpha, \quad p_{01} = \alpha, \quad p_{02} = 0; \\ p_{10} = \beta(1-\alpha), \quad p_{11} = (1-\beta)(1-\alpha) + \alpha\beta, \quad p_{12} = \alpha(1-\beta). \end{aligned} \tag{85}$$

Da due occupati, nessuno rimane impegnato soltanto se entrambi finiscono e non arriva nessuno. Per passare a uno occupato, può finire uno dei due senza arrivo, oppure possono finire entrambi con un nuovo arrivo. Per restare a due, possono non finire entrambi, oppure finire esattamente uno con sostituzione:

$$p_{20} = \beta^2(1-\alpha), \quad p_{21} = 2\beta(1-\beta)(1-\alpha) + \alpha\beta^2, p_{22} = (1-\beta)^2 + 2\alpha\beta(1-\beta). \tag{86}$$

Queste alternative sono disgiunte e le righe sommano a 1. Il termine «nessun completamento» quando lo stato è 2 comprende tanto l'assenza quanto la presenza di un arrivo respinto; per questo nella sua probabilità non compare un fattore $1 - \alpha$.

Con $\alpha = .5$, $\beta = .7$ e sistema inizialmente vuoto,

$$\begin{aligned} P = \begin{pmatrix} .5 & .5 & 0 \\ .35 & .5 & .15 \\ .245 & .455 & .3 \end{pmatrix}, \quad \Pi(0) = (1, 0, 0), \\ \Pi(2) = (.425, .5, .075), \quad \Pi(3) = (.405875, .496625, .0975). \end{aligned} \tag{87}$$

La probabilità di vuoto all'istante 3 è dunque .405875, arrotondata a .406 nelle lezioni. La probabilità di non osservare completamenti **nel prossimo slot**, dato $X_k = j$, è $(1-\beta)^j$. Mediando sullo stato all'inizio dello slot,

$$P(\text{nessun completamento fra } k \text{ e } k+1) = \sum_{j=0}^{2} (1-\beta)^j \pi_j(k). \tag{88}$$

Con $k = 2$ vale .58175; con $k = 3$ vale .5636375. Infine $P(X_1 = 0, X_2 = 0) = \pi_0(1)p_{00} = .5 \times .5 = .25$: essere vuoto a entrambi gli estremi si ottiene qui restando vuoto nel primo e nel secondo aggiornamento.

> **Nota tecnica A16.** Il documento 5, pagina 38, chiama «terzo slot» il calcolo che pesa le probabilità di mancato completamento con $\Pi(3)$, ottenendo circa .56. Con X_k osservato dopo k aggiornamenti, lo slot da 2 a 3 deve usare $\Pi(2)$ e vale .58175; $\Pi(3)$ descrive lo slot da 3 a 4. È una questione di indicizzazione da dichiarare: il valore .56 è corretto per lo slot successivo allo stato X_3.

6.5 Raggiungibilità e classi

Fonte A: documento 5, pagine PDF 39–42.

Uno stato j è raggiungibile da i se $(P^n)_{ij} > 0$ per qualche $n \geq 1$. Nel grafo equivale all'esistenza di un cammino orientato di probabilità positiva. Due stati comunicano quando ciascuno è raggiungibile dall'altro; includendo la raggiungibilità in zero passi si ottiene una relazione di equivalenza e quindi una partizione in classi comunicanti.

Un insieme S è chiuso se non esiste probabilità di uscita:

$$p_{ij} = 0 \quad \forall i \in S, j \notin S. \tag{89}$$

Una volta entrata in S, la catena vi rimane. Il disegno delle lezioni distingue l'insieme chiuso $\{2, 3, 5\}$ da $\{0, 1, 4\}$, dal quale esistono transizioni verso il primo. Chiusura non significa che il grafo interno sia necessariamente fortemente connesso. Una classe chiusa e comunicante è una componente irriducibile; l'intera catena è irriducibile quando tutti gli stati comunicano. Uno stato assorbente costituisce da solo un insieme chiuso e ha $p_{ii} = 1$.

La figura originale permette di verificare la chiusura seguendo le frecce: da 2,3,5 nessun arco conduce a 0,1,4. Gli archi in entrata da fuori non violano la chiusura.

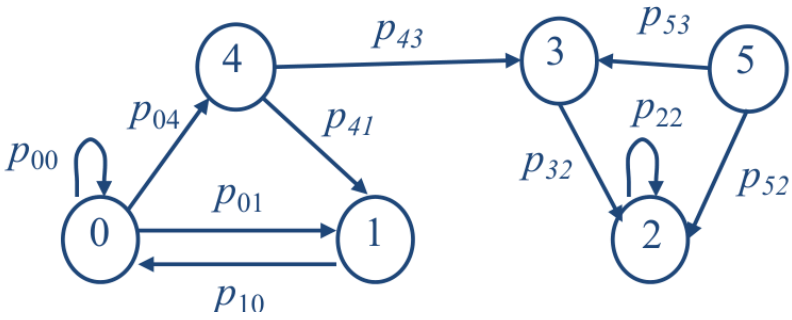


Figura 18: Insieme chiuso e stati esterni. Documento 5, pagina 40.

Una catena irriducibile con più di uno stato non contiene stati assorbenti. L'eccezione del solo stato assorbente è una catena irriducibile a un elemento. In una catena finita ogni classe comunicante chiusa è positiva ricorrente, mentre gli stati che non appartengono a classi chiuse sono transitori. Nel caso infinito, l'irriducibilità non basta a garantire una distribuzione di equilibrio normalizzabile: la probabilità può diffondersi verso stati sempre più lontani.

6.6 Ricorrenza e passeggiata riflessa

Fonte A: documento 5, pagine PDF 43–57.

Il primo tempo di arrivo a j, partendo da i, si definisce $T_{ij} = \inf\{n \geq 1 : X_n = j\}$, con valore infinito se lo stato non viene mai raggiunto. Per $i = j$ è il primo **ritorno** dopo almeno un passo; non richiede di essere prima usciti da i, quindi un cappio produce un ritorno al passo 1. Definiamo

$$\rho_i^{(n)} = P(T_{ii} = n \mid X_0 = i), \quad \rho_i = \sum_{n=1}^{\infty} \rho_i^{(n)} = P(T_{ii} < \infty \mid X_0 = i). \tag{90}$$

Se $\rho_i < 1$, lo stato è transitorio; se $\rho_i = 1$, è ricorrente. Nel secondo caso si ritorna con probabilità uno e, dopo ogni ritorno, la proprietà di Markov permette di ripetere l'argomento: le visite sono infinite con probabilità uno. Per uno stato transitorio il numero di visite, contando quella iniziale, ha media $\frac{1}{1-\rho_i}$, poiché dopo ogni visita la probabilità di almeno un'altra è ρ_i. Le prime probabilità di ritorno, espandendo i cammini senza visite intermedie a i, sono

$$\rho_i^{(1)} = p_{ii}, \quad \rho_i^{(2)} = \sum_{j \neq i} p_{ij} p_{ji}, \quad \rho_i^{(3)} = \sum_{j \neq i} \sum_{\ell \neq i} p_{ij} p_{j\ell} p_{\ell i}. \tag{91}$$

Gli stati di una stessa classe comunicante hanno la stessa natura transitoria o ricorrente; nella classe ricorrente è comune anche la distinzione positiva/nulla. I valori numerici dei tempi medi di ritorno possono invece differire da stato a stato.

Per uno stato ricorrente il tempo medio di ritorno è

$$M_i = E[T_{ii} | X_0 = i] = \sum_{n=1}^{\infty} n \rho_i^{(n)}. \tag{92}$$

La ricorrenza è positiva se $M_i < \infty$, nulla se $M_i = \infty$. Una variabile può essere finita con probabilità uno e avere media infinita: ricorrenza nulla non significa che una singola escursione non termini con probabilità positiva. L'assorbente è positivo ricorrente secondo la definizione di ritorno, perché $T_{ii} = 1$.

Nell'esempio con stati 0,1,2,3, da 0 si rimane con probabilità $1-p$ o si passa a 1 con p; da 1 si torna a 0 con $1-p$ o si passa a 2 con p; da 2 si torna a 0 con $1-p$ o si passa a 3 con p; 3 è assorbente. Un primo ritorno a 0 avviene in uno, due o tre passi:

$$\rho_0^{(1)} = 1-p, \quad \rho_0^{(2)} = p(1-p), \quad \rho_0^{(3)} = p^2(1-p), \quad \rho_0 = 1 - p^3. \tag{93}$$

Per $0 < p \leq 1$ lo stato 0 è transitorio, perché esiste la probabilità p^3 di arrivare a 3 senza ritornare. Nell'esempio a due stati con ogni probabilità pari a $\frac{1}{2}$, invece, $\rho_0^{(n)} = 2^{-n}$: dopo il primo passaggio a 1 si può restare in 1 e poi tornare. La somma è 1 e $M_0 = \sum n 2^{-n} = 2$, per cui lo stato è positivo ricorrente.

La passeggiata riflessa su $\mathbb{N}_0$ ha probabilità di discesa p e di salita $q = 1-p$ negli stati positivi; al bordo 0 il passo verso il basso viene sostituito da un cappio di probabilità p. Assumiamo $0 < p < 1$. Per stabilire il ritorno a 0, indichiamo con $q_i(m)$ la probabilità di raggiungere 0 prima di m, partendo da i, con $q_0(m) = 1$ e $q_m(m) = 0$. Condizionando al primo passo,

$$q_i(m) = p\, q_{i-1}(m) + q\, q_{i+1}(m), \quad 1 \leq i \leq m-1. \tag{94}$$

Portando i termini dalla stessa parte si ottiene $q_{i+1} - q_i = \left(\frac{p}{q}\right)(q_i - q_{i-1})$. Con $\beta = \frac{p}{q}$ e $\delta_i = q_i - q_{i-1}$, vale $\delta_{i+1} = \beta \delta_i$. Sommando le differenze da 1 a m,

$$-1 = q_m - q_0 = \delta_1 \sum_{r=0}^{m-1} \beta^r, \quad q_1(m) = 1 - \frac{1}{\sum_{r=0}^{m-1} \beta^r}. \tag{95}$$

Se $\beta < 1$, la somma tende a $\frac{1}{1-\beta}$ e il limite di $q_1(m)$ è β. Se $\beta \geq 1$, la somma diverge e il limite è 1. Lasciando andare il livello superiore a infinito si ottiene la probabilità di colpire 0 partendo da 1. Dal bordo, un cappio è già un ritorno; se invece si sale occorre poi ritornare:

$$\rho_0 = p + q \lim_{m \to \infty} q_1(m) = \begin{cases} 2p & p < \frac{1}{2} \\ 1 & p \geq \frac{1}{2} \end{cases}. \tag{96}$$

La passeggiata è dunque transitoria per $p < \frac{1}{2}$, ricorrente per $p \geq \frac{1}{2}$. La distinzione positiva/nulla si completa con la normalizzazione dell'equilibrio nella sezione 6.8: è positiva per $p > \frac{1}{2}$ e nulla per $p = \frac{1}{2}$. Un moto mediamente diretto verso il bordo torna in tempo medio finito; nel caso simmetrico le escursioni rare e molto lunghe rendono infinita la media.

6.7 Periodicità

Fonte A: documento 5, pagine PDF 58–63; 66.

La ricorrenza riguarda il ritorno; la periodicità riguarda le date alle quali un ritorno è possibile. Il periodo dello stato i è

$$d_i = \gcd\{n \geq 1 : (P^n)_{ii} > 0\}. \tag{97}$$

Uno stato è aperiodico se $d_i = 1$ e periodico se $d_i > 1$. Gli stati che comunicano hanno lo stesso periodo: concatenando cammini fra due stati si trasferiscono i vincoli aritmetici sulle lunghezze dei ritorni. Un cappio rende possibile un ritorno in un passo e impone periodo 1. Viceversa, l'assenza di cappi non basta a provare periodicità.

> **Nota tecnica A17.** L'ultima osservazione del documento 5, pagina 58, dice che $p_{ii} > 0$ rende lo stato «certamente periodico». La parola corretta è **aperiodico**, perché 1 appartiene all'insieme di cui si prende il massimo comun divisore. Correzione certa.

Il massimo comun divisore non è necessariamente una lunghezza di ritorno effettivamente disponibile. Se un grafo consente cicli di lunghezza 4 e 6, il periodo può essere 2 anche in assenza di un ciclo di lunghezza 2. Il criterio delle lunghezze multiple va quindi applicato a tutti i cammini di ritorno, non interpretato come esistenza di un singolo ciclo di lunghezza minima uguale al periodo.

Nell'esempio a due stati con un cappio solo in 0 e archi in entrambe le direzioni, le possibili lunghezze sono $\Delta(0) = \{1, 2, 3, \dots\}$ e $\Delta(1) = \{2, 3, 4, \dots\}$. Entrambi i massimi comun divisori sono 1, anche se lo stato 1 non possiede un cappio. Questo verifica perché il cappio è sufficiente ma non necessario.

Nel ciclo deterministico a tre stati,

$$P = \begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{pmatrix}, \quad P^3 = I. \tag{98}$$

Le altre potenze riportate si leggono direttamente ruotando due volte: $P^2 = \begin{pmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix}$ e $P^4 = P$. I ritorni sono possibili esattamente ai multipli positivi di 3.

La distribuzione iniziale concentrata in uno stato ruota senza convergere. Esiste comunque la distribuzione invariante uniforme $\left(\tfrac{1}{3}, \tfrac{1}{3}, \tfrac{1}{3}\right)$: se si parte con essa, la legge rimane identica. Questo esempio separa già invarianza e convergenza.

Un altro esempio ha uno stato 0 che passa equiprobabilmente a 1 o 2, mentre 1 e 2 tornano sicuramente a 0:

$$P = \begin{pmatrix} 0 & \tfrac{1}{2} & \tfrac{1}{2} \\ 1 & 0 & 0 \\ 1 & 0 & 0 \end{pmatrix}, \quad P^2 = \begin{pmatrix} 1 & 0 & 0 \\ 0 & \tfrac{1}{2} & \tfrac{1}{2} \\ 0 & \tfrac{1}{2} & \tfrac{1}{2} \end{pmatrix}, \quad P^3 = P. \tag{99}$$

Le potenze dispari coincidono con P e quelle pari positive con P^2. I ritorni avvengono solo dopo un numero pari di passi: il periodo è 2. La distribuzione invariante è $\left(\tfrac{1}{2}, \tfrac{1}{4}, \tfrac{1}{4}\right)$, ma da un iniziale concentrato non si osserva convergenza; le due classi cicliche si scambiano a ogni passo.

Nel corrispondente esempio con cappi,

$$P = \begin{pmatrix} \tfrac{1}{2} & \tfrac{1}{2} & 0 \\ 0 & \tfrac{1}{2} & \tfrac{1}{2} \\ \tfrac{1}{2} & 0 & \tfrac{1}{2} \end{pmatrix}, \quad \lim_{n \to \infty} P^n = \begin{pmatrix} \tfrac{1}{3} & \tfrac{1}{3} & \tfrac{1}{3} \\ \tfrac{1}{3} & \tfrac{1}{3} & \tfrac{1}{3} \\ \tfrac{1}{3} & \tfrac{1}{3} & \tfrac{1}{3} \end{pmatrix}. \tag{100}$$

La catena è finita, irriducibile e aperiodica. Le probabilità delle diverse origini si mescolano finché ogni riga ha la stessa distribuzione. I grafici transitori delle lezioni illustrano proprio l'alternanza persistente nel caso

periodico e lo smorzamento verso valori comuni in quello aperiodico; l'asse orizzontale è il numero di passi, quello verticale una probabilità.

6.8 Distribuzioni invarianti e limite

Fonte A: documento 5, pagine PDF 64–65; 67–78.

Una distribuzione π è invariante se, usandola come iniziale, rimane la legge a ogni passo. Per una catena omogenea soddisfa

L'esempio riducibile delle lezioni rende esplicita la dipendenza dall'iniziale:

$$P = \begin{pmatrix} .5 & .25 & .25 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}. \tag{101}$$

Gli stati 1 e 2 sono assorbenti. Partendo da $\Pi(0) = (0, 1, 0)$ si ha $\Pi(k) = (0, 1, 0)$ per ogni k; partendo da $(0, 0, 1)$ si resta in $(0, 0, 1)$. Partendo da 0, invece, dopo n passi la probabilità ancora in 0 è 2^{-n} e le due probabilità di assorbimento sono uguali, quindi il limite è $\left(0, \frac{1}{2}, \frac{1}{2}\right)$. Il limite esiste in tutti questi casi ma non è universale rispetto all'iniziale.

$$\pi = \pi P, \quad \pi_j \geq 0, \quad \sum_j \pi_j = 1. \tag{102}$$

La distribuzione limite è invece l'eventuale limite di $\Pi(0)P^n$ da una certa condizione iniziale. Per una catena irriducibile positiva ricorrente, l'invariante esiste ed è unica; la convergenza da ogni iniziale richiede anche aperiodicità. Con stati finiti e irriducibilità, la ricorrenza positiva è automatica. La periodicità può impedire il limite ordinario senza impedire l'invariante.

La relazione fra equilibrio e ritorni è

$$\pi_i = \frac{1}{M_i}. \tag{103}$$

Una derivazione interpretativa considera i cicli successivi fra visite a i. Ogni ciclo contiene una visita di riferimento a i e dura in media M_i passi; il rapporto fra numero di visite e tempo tende a $\frac{1}{M_i}$ quando i tempi medi sono finiti. Con le ipotesi di ricorrenza e la proprietà di Markov, i cicli permettono una formulazione rigorosa mediante rinnovo. Il risultato non afferma che il tempo in uno stato sia indipendente dalle visite agli altri.

Se una catena irriducibile è transitoria o nulla ricorrente, non ammette una distribuzione invariante di probabilità; per ogni coppia fissata, $(P^n)_{ij} \to 0$. Non si ottiene una distribuzione limite normalizzata ponendo tutte le componenti uguali a zero. La massa resta totale 1 a ogni passo, ma si disperde su stati sempre più lontani: il limite punto per punto non può essere scambiato con la somma infinita.

> **Nota tecnica A18.** Il documento 5, pagina 69, lega l'esistenza della distribuzione stazionaria all'aperiodicità. L'aperiodicità serve alla convergenza da ogni iniziale, mentre una catena periodica positiva ricorrente possiede comunque un'invariante. A pagina 70 il caso simmetrico $p = \frac{1}{2}$ della passeggiata non ha deriva media positiva negli stati interni: l'assenza di equilibrio normalizzabile dipende dalla diffusione delle escursioni. Precisazioni certe.

Per la matrice finita dell'esempio finale,

$$P = \begin{pmatrix} \frac{3}{4} & \frac{1}{4} & 0 \\ \frac{1}{2} & 0 & \frac{1}{2} \\ \frac{1}{4} & \frac{3}{4} & 0 \end{pmatrix}, \quad \pi = \left(\frac{5}{8}, \frac{1}{4}, \frac{1}{8}\right). \tag{104}$$

Con stati ordinati 0,1,2, il sistema completo è

$$\pi_0 = \frac{3}{4}\pi_0 + \frac{1}{2}\pi_1 + \frac{1}{4}\pi_2, \quad \pi_1 = \frac{1}{4}\pi_0 + \frac{3}{4}\pi_2, \quad \pi_2 = \frac{1}{2}\pi_1, \quad \pi_0 + \pi_1 + \pi_2 = 1. \tag{105}$$

Si può ricavare la soluzione senza invertire matrici. La terza equazione dà $\pi_2 = \frac{\pi_1}{2}$. La seconda dà $\pi_1 = \frac{\pi_0}{4} + 3\frac{\pi_2}{4}$ sostituendo si ottiene $\pi_1 = 2\frac{\pi_0}{5}$ e $\pi_2 = \frac{\pi_0}{5}$. La normalizzazione impone $\left(1 + \frac{2}{5} + \frac{1}{5}\right)\pi_0 = 1$, quindi $\pi_0 = \frac{5}{8}$. Una delle equazioni di bilancio è ridondante perché P ha somme di riga 1: occorre sostituirla con la normalizzazione, non risolvere soltanto il sistema omogeneo.

Nella passeggiata riflessa il bilancio al bordo è $\pi_0 = p\pi_0 + p\pi_1$, da cui $\pi_1 = \left(\frac{q}{p}\right)\pi_0$. Negli stati interni il bilancio è $\pi_j = q\pi_{j-1} + p\pi_{j+1}$. La stessa relazione si propaga e conduce a

$$\pi_j = \left(\frac{q}{p}\right)^j \pi_0, \quad 1 = \pi_0 \sum_{j=0}^{\infty} \left(\frac{q}{p}\right)^j, \quad \pi_0 = \frac{2p-1}{p} \ \text{ se } \ p > \frac{1}{2}. \tag{106}$$

La serie converge solo per $p > q$. Per $p = \frac{1}{2}$ i pesi sarebbero costanti e non sommabili: la catena è ricorrente nulla. Per $p < \frac{1}{2}$ crescono e la catena è transitoria, come già provato. Nel caso positivo $M_0 = \frac{p}{2p-1}$: al tendere di p a $\frac{1}{2}$ dall'alto il tempo medio di ritorno diverge, pur continuando il ritorno a essere quasi certo anche al valore limite.

Per una catena riducibile, si individuano prima le classi chiuse. Nell'esempio conclusivo delle lezioni, gli stati 0 e 1 sono transitori e la classe chiusa è $\{2, 3, 4\}$. Le probabilità stazionarie esterne alla classe sono zero; si risolve il bilancio sulla sottomatrice chiusa. Se vi è una sola classe chiusa raggiunta con probabilità uno e aperiodica, il limite non dipende dall'iniziale. Con più classi chiuse, ogni loro distribuzione invariante può essere combinata in una miscela; il limite, quando esiste, usa come pesi le probabilità di assorbimento nelle diverse classi a partire dall'iniziale. Non si può scegliere arbitrariamente una singola classe ignorando le altre.

L'analisi discreta separa così quattro questioni: quali stati comunicano, se il ritorno è certo, se il suo tempo medio è finito e se vi sono vincoli periodici sulle date. Nel tempo continuo le durate esponenziali sostituiranno i passi fissi e il generatore sostituirà la matrice stocastica, mantenendo la stessa logica di bilancio della probabilità.

7 Catene di Markov a tempo continuo

7.1 Transizioni, generatore ed equazioni differenziali

Fonte A: documento 6, pagine PDF 1–8.

Nel tempo continuo non si sceglie un passo fisso: la catena rimane nello stato per una durata aleatoria e poi salta. La funzione di transizione è $h_{ij}(s,t) = P(X(t) = j | X(s) = i)$ per $s \le t$. La matrice $H(s,t)$ ha righe di probabilità e $H(t,t) = I$. Condizionare a uno stato intermedio dà le stesse equazioni di Chapman–Kolmogorov:

$$H(s,t) = H(s,u)H(u,t), \quad s \le u \le t. \tag{107}$$

Per passare a un modello locale si introduce la matrice dei tassi, o generatore,

$$Q(t) = \lim_{h \downarrow 0} \frac{H(t,t+h) - I}{h}, \quad H(t,t+h) = I + Q(t)h + o(h). \tag{108}$$

Per $i \neq j$, $q_{ij}(t)$ è il tasso istantaneo di passaggio da i a j; non è una probabilità, ma una probabilità per unità di tempo al primo ordine. La diagonale misura la perdita di probabilità dallo stato. Si ha

$$q_{ij} \ge 0 \ \text{ per } \ i \neq j, \quad q_{ii} = -\sum_{j \neq i} q_{ij} \le 0, \quad Q\mathbf{1} = \mathbf{0}. \tag{109}$$

Le somme di riga sono zero perché H ha somme di riga 1: differenziando la normalizzazione si ottiene zero. In uno spazio finito, Q è singolare e possiede l'autovalore zero, con autovettore destro costante. Gli altri autovalori hanno parte reale non positiva; un autovalore non deve essere necessariamente reale. La probabilità evolve entro il simplesso, non può crescere esponenzialmente senza limite.

Si deriva rispetto all'estremo finale usando $H(s,t+h) = H(s,t)H(t,t+h)$, e rispetto a quello iniziale usando $H(s,t) = H(s,s+h)H(s+h,t)$. Il limite fornisce

$$\frac{\partial H(s,t)}{\partial t} = H(s,t)Q(t), \quad \frac{\partial H(s,t)}{\partial s} = -Q(s)H(s,t). \tag{110}$$

L'equazione in avanti agisce a destra perché aggiunge l'ultimo breve intervallo; quella all'indietro agisce a sinistra perché separa il primo. Il segno negativo nasce dal fatto che aumentare s accorcia l'intervallo osservato.

> **Nota tecnica A19.** Nel documento 6, pagina 8, il generatore nell'equazione all'indietro è scritto $Q(t)$. Per una catena non omogenea il termine corretto è $Q(s)$, associato all'estremo iniziale. Nel caso omogeneo la differenza scompare. Correzione certa.

7.2 Permanenza e significato dei tassi

Fonte A: documento 6, pagine PDF 9–19.

Una catena è omogenea quando la legge di transizione dipende soltanto dal tempo trascorso $\tau = t - s$. Il generatore è allora costante e $H(\tau)$ soddisfa $\dot{H} = HQ = QH$ con $H(0) = I$. Per stati finiti la soluzione è

$$H(t) = e^{Qt} = \sum_{n=0}^{\infty} \frac{(Qt)^n}{n!}. \tag{111}$$

Non si esponenziano separatamente gli elementi di Q: si usa il prodotto matriciale nelle potenze. Se $Q = MDM^{-1}$ è diagonalizzabile, $H(t) = Me^{Dt}M^{-1}$ per blocchi di Jordan compaiono polinomi in t moltiplicati per esponenziali. La trasformata di Laplace è $\tilde{H}(s) = (sI - Q)^{-1}$ nel semipiano di convergenza. Questi metodi sono forme diverse della stessa soluzione del sistema lineare.

Nel caso numerabile infinito, la notazione esponenziale richiede cautela: un generatore non limitato e la possibilità di esplosione richiedono una teoria di semigruppi e condizioni di regolarità. Le formule finite sono

immediate; per i modelli infiniti del corso si assume una catena non esplosiva e si verificano le condizioni del modello. Avere solo righe formalmente a somma zero non esclude da solo la fuga attraverso infiniti salti in tempo finito.

Sia V_i il tempo fino al primo vero cambio di stato da i e $F_i(t)$ la sua ripartizione. Indichiamo con $\Lambda_i = -q_{ii}$ il tasso d'uscita. Dato che non si è ancora usciti, la probabilità di uscita nei successivi h è $\Lambda_i h + o(h)$. Ne segue

$$F_i(t+h) - F_i(t) = (1 - F_i(t))\Lambda_i h + o(h), \quad \dot{F}_i = \Lambda_i(1 - F_i), \quad F_i(0) = 0. \tag{112}$$

Separando le variabili, oppure risolvendo l'equazione per la sopravvivenza $S_i = 1 - F_i$, si ottiene $S_{i'} = -\Lambda_i S_i$ e quindi

$$F_i(t) = 1 - e^{-\Lambda_i t}, \quad E[V_i] = \frac{1}{\Lambda_i}. \tag{113}$$

Per $\Lambda_i = 0$ lo stato è assorbente e la permanenza è infinita. Il tasso ha unità inversa del tempo, la diagonale di Q è il suo opposto e non il suo reciproco.

Condizionatamente all'uscita da i, la probabilità che la destinazione sia $j \neq i$ è

$$p_{ij} = \frac{q_{ij}}{\Lambda_i}, \quad q_{ij} = \Lambda_i p_{ij}, \quad \sum_{j \neq i} p_{ij} = 1. \tag{114}$$

Questa è la catena incorporata ai veri salti; ha $p_{ii} = 0$ negli stati non assorbenti. Non coincide con la matrice $H(T)$ osservata dopo un intervallo fisso T, nel quale possono avvenire zero, uno o molti salti. Se più tipi di evento portano alla stessa destinazione, i loro tassi si sommano.

Se il modello a eventi include un cappio, l'evento avviene senza uscita dal descrittore. In un GSMP esponenziale con tassi λ_e,

$$q_{ij} = \sum_{e \in \Gamma(i)} \lambda_e p(j; i, e) \quad (j \neq i), \quad \Lambda_i = \sum_{j \neq i} q_{ij}. \tag{115}$$

La somma dei tassi di tutti gli eventi può superare Λ_i. Il generatore non contiene nella diagonale una perdita di stato per eventi che lo lasciano invariato. Il concetto sarà essenziale quando gli arrivi a un sistema pieno vengono respinti ma continuano a verificarsi.

7.3 Assemblaggio e analisi transitoria

Fonte A: documento 6, pagine PDF 20–24.

Il sistema di assemblaggio delle lezioni riceve pezzi secondo un processo di Poisson di tasso λ e assembla una coppia soltanto quando sono presenti due pezzi, con tempo esponenziale di tasso μ. La capacità totale è due: un ulteriore arrivo quando lo stato è 2 viene perso. Lo stato è $X \in \{0, 1, 2\}$. Gli arrivi portano 0 a 1 e 1 a 2; il completamento porta 2 a 0. Un arrivo in 2 è un cappio e non cambia X:

$$Q = \begin{pmatrix} -\lambda & \lambda & 0 \\ 0 & -\lambda & \lambda \\ \mu & 0 & -\mu \end{pmatrix}. \tag{116}$$

Nel grafo il cappio di arrivo in 2 indica una richiesta respinta. Gli archi che cambiano stato definiscono invece il generatore Equazione 116.

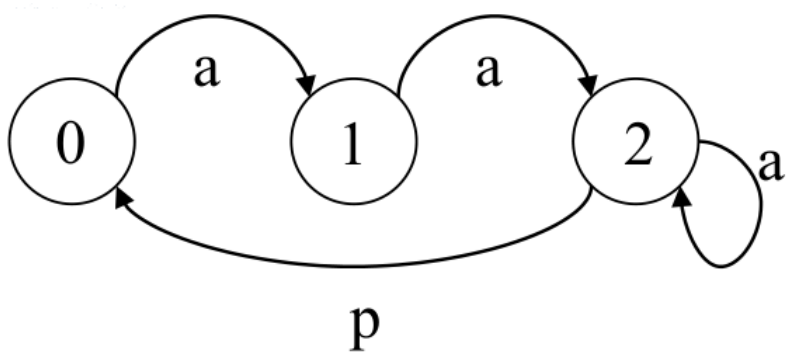


Figura 19: Grafo dell'assemblaggio con arrivi persi al pieno. Documento 6, pagina 20.

La permanenza effettiva nello stato 2 ha tasso μ, non $\lambda + \mu$, poiché si può osservare un numero arbitrario di arrivi rifiutati prima dell'assemblaggio. Gli eventi rifiutati devono però essere contati se si misura il flusso perso.

Con $\Pi(t) = (\pi_0(t), \pi_1(t), \pi_2(t))$, le equazioni di probabilità sono

$$\dot{\pi}_0 = -\lambda\pi_0 + \mu\pi_2, \quad \dot{\pi}_1 = \lambda\pi_0 - \lambda\pi_1, \quad \dot{\pi}_2 = \lambda\pi_1 - \mu\pi_2. \tag{117}$$

Ogni termine ha unità di probabilità per tempo. La somma delle derivate è zero, quindi un'iniziale normalizzata rimane tale. In forma generale, condizionando allo stato iniziale casuale,

$$\Pi(t) = \Pi(0)H(t) = \Pi(0)e^{Qt}, \quad \dot{\Pi}(t) = \Pi(t)Q. \tag{118}$$

Il primo prodotto somma le transizioni da ogni possibile origine. L'equazione differenziale descrive l'evoluzione del vettore di probabilità, non una singola traiettoria del numero di pezzi. Una simulazione produce gradini casuali; la soluzione di questa equazione produce curve regolari di probabilità.

All'equilibrio dell'assemblaggio, $\lambda\pi_0 = \lambda\pi_1 = \mu\pi_2$. Dunque $\pi_0 = \pi_1$, $\pi_2 = \left(\frac{\lambda}{\mu}\right)\pi_0$ e la normalizzazione dà

$$\pi_0 = \pi_1 = \frac{\mu}{2\mu + \lambda}, \quad \pi_2 = \frac{\lambda}{2\mu + \lambda}. \tag{119}$$

Il throughput delle **coppie** è $\mu\pi_2$; quello dei **pezzi assemblati** è $2\mu\pi_2$. Gli arrivi ammessi sono $\lambda(\pi_0 + \pi_1)$ e coincidono con quest'ultimo flusso. La perdita è $\lambda\pi_2$. Specificare l'unità «coppie» o «pezzi» evita un fattore due apparentemente inspiegabile.

7.4 Flussi ed equilibrio

Fonte A: documento 6, pagine PDF 25–32.

La componente j dell'equazione di Kolmogorov può essere riscritta separando entrate e uscite:

$$\dot{\pi}_j(t) = \sum_{i \neq j} \pi_i(t) q_{ij} - \pi_j(t) \sum_{r \neq j} q_{jr}. \tag{120}$$

Il prodotto $\pi_i q_{ij}$ è un flusso di probabilità per unità di tempo. A equilibrio il flusso entrante totale in ogni stato uguaglia quello uscente. Non si richiede che ogni singola coppia di stati si bilanci separatamente: quel requisito più forte è il bilancio dettagliato e vale soltanto per particolari catene reversibili.

$$\pi Q = \mathbf{0}, \quad \pi_j \geq 0, \quad \sum_j \pi_j = 1. \tag{121}$$

Una soluzione normalizzata è invariante. Per una catena finita irriducibile è unica e coincide con il limite da qualunque iniziale. A tempo continuo non serve escludere la periodicità della catena dei salti: la possibilità di permanere nello stesso stato per durate esponenziali disperde i salti nel tempo. Per una catena infinita servono, oltre alla regolarità, ricorrenza positiva ed esistenza di una probabilità normalizzabile.

Nota tecnica A20. Nel documento 6, pagine 25–26, la somma dei tassi uscenti dallo stato j contiene una condizione d'indice non coerente. Essa è $\sum_{r\neq j} q_{jr}$, mentre l'entrata è $\sum_{i\neq j} \pi_i q_{ij}$. La riscrittura mantiene distinti indice d'origine e indice di destinazione. Correzione certa.

Se si conosce l'invariante ν della catena incorporata ai veri salti, l'occupazione nel tempo non è in generale ν: gli stati con permanenza lunga pesano di più. Quando la somma al denominatore è finita,

$$\pi_i = \frac{\frac{\nu_i}{\Lambda_i}}{\sum_j \frac{\nu_j}{\Lambda_j}}. \tag{122}$$

La relazione è una derivazione integrativa del bilancio fra frequenza delle visite e durata media delle visite. Essa prepara una cautela importante: una deriva favorevole della catena dei salti non è sufficiente a garantire un tempo medio di ritorno fisico finito se le permanenze crescono troppo rapidamente.

7.5 Nascita e morte

Fonte A: documento 6, pagine PDF 33–34.

Una catena di nascita e morte su $\mathbb{N}_0$ ammette soltanto transizioni fra stati consecutivi. Il tasso di nascita nello stato j è λ_j; quello di morte è μ_j, con $\mu_0 = 0$. I termini del generatore sono

$$q_{j,j+1} = \lambda_j, \quad q_{j,j-1} = \mu_j, \quad q_{jj} = -(\lambda_j + \mu_j), \tag{123}$$

e gli altri elementi sono zero. Nel conteggio dei clienti, una nascita è un arrivo e una morte una partenza. I tassi possono dipendere dalla popolazione: più clienti in una sorgente finita possono ridurre il tasso dei futuri arrivi, più serventi impegnati possono aumentare il tasso totale delle partenze.

Le equazioni transitorie esplicitano i due ingressi possibili nello stato j e le due uscite:

$$\dot{\pi}_0 = -\lambda_0\pi_0 + \mu_1\pi_1, \quad \dot{\pi}_j = \lambda_{j-1}\pi_{j-1} - (\lambda_j + \mu_j)\pi_j + \mu_{j+1}\pi_{j+1} \quad (j \geq 1). \tag{124}$$

Il bordo va trattato separatamente: non esiste uno stato -1. Il segno meno riguarda tutte le uscite dallo stato corrente, mentre i termini positivi usano tassi valutati nei rispettivi stati di origine. Questa verifica degli indici evita di confondere il tasso di morte da $j+1$ con quello da j.

7.6 Nascita pura e Poisson

Fonte A: documento 6, pagine PDF 35.

Nella nascita pura $\mu_j = 0$ e lo stato cresce di un'unità a ogni salto. Partendo da i, non si può raggiungere $j < i$. La probabilità di restare in i è $h_{ii}(t) = e^{-\lambda_i t}$. Per $j > i$, la ricorrenza in avanti è

$$\dot{h}_{ij}(t) = -\lambda_j h_{ij}(t) + \lambda_{j-1} h_{i,j-1}(t), \quad h_{ij}(0) = 0. \tag{125}$$

Moltiplicando per $e^{\lambda_j t}$ e integrando da 0 a t,

$$h_{ij}(t) = \lambda_{j-1} e^{-\lambda_j t} \int_0^t e^{\lambda_j u} h_{i,j-1}(u)\,\mathrm{d}u. \tag{126}$$

Questa formula permette di costruire le probabilità stato per stato senza risolvere simultaneamente l'intero sistema. È una convoluzione fra il flusso proveniente da $j-1$ e la sopravvivenza in j fino all'istante finale.

Nota tecnica A21. Nel documento 6, pagina 35, il fattore nell'integrale compare con esponente negativo. Dopo l'uso del fattore integrante deve essere $e^{+\lambda_j u}$; il fattore esterno è $e^{-\lambda_j t}$. Correzione certa ottenuta derivando la soluzione.

Quando tutti i tassi sono uguali a λ, la ricorrenza coincide con quella del conteggio di Poisson. Per induzione,

$$h_{ij}(t) = e^{-\lambda t}\frac{(\lambda t)^{j-i}}{(j-i)!} \quad (j \geq i). \tag{127}$$

Con $i = 0$ si recupera $P(N(t) = j)$. Ogni permanenza ha la stessa legge esponenziale indipendente e il numero di salti in un intervallo ha legge di Poisson. Un tasso di nascita dipendente dallo stato conserva la struttura di nascita pura ma non la legge di Poisson omogenea.

7.7 Equilibrio di nascita e morte

Fonte A: documento 6, pagine PDF 36–38.

All'equilibrio le equazioni precedenti diventano algebriche. Dal bordo $\lambda_0\pi_0 = \mu_1\pi_1$. Sostituendo questa uguaglianza nell'equazione dello stato 1 si ottiene $\lambda_1\pi_1 = \mu_2\pi_2$, e il procedimento continua. Equivalentemente, il flusso netto attraverso ogni taglio fra j e $j+1$ deve essere nullo:

$$\lambda_j\pi_j = \mu_{j+1}\pi_{j+1}, \quad \pi_j = \pi_0\prod_{r=0}^{j-1}\frac{\lambda_r}{\mu_{r+1}}. \tag{128}$$

Per un modello irriducibile con tassi positivi e non esplosivo, la distribuzione di probabilità esiste se e solo se la somma dei pesi è finita:

$$S = 1 + \sum_{j=1}^{\infty}\prod_{r=0}^{j-1}\frac{\lambda_r}{\mu_{r+1}} < \infty, \quad \pi_0 = \frac{1}{S}. \tag{129}$$

Il prodotto vuoto per $j = 0$ vale 1. In capacità finita la somma si arresta al massimo stato, con tasso di nascita nullo al bordo superiore; per una catena finita irriducibile la normalizzazione è sempre possibile. Nel caso infinito la convergenza non è un dettaglio del calcolo: è la condizione che impedisce alla popolazione di occupare livelli arbitrariamente alti senza una probabilità sommabile.

Una condizione sufficiente immediata è $\frac{\lambda_j}{\mu_{j+1}} \leq \varepsilon < 1$ per tutti gli indici abbastanza grandi. Infatti il rapporto fra due pesi consecutivi è proprio questo quoziente, quindi la coda della serie è dominata da una geometrica. Non si può sostituire automaticamente il denominatore con μ_j.

> **Nota tecnica A22.** Il documento 6, pagina 38, propone come condizione sufficiente $\frac{\lambda_j}{\mu_j} \leq \varepsilon < 1$ definitivamente. Senza altre ipotesi su μ_j essa non garantisce la normalizzabilità. Un controesempio non esplosivo è $\lambda_0 = 1$, $\mu_j = 2^{-j^2}$ e $\lambda_j = \frac{\mu_j}{2}$ per $j \geq 1$: il rapporto stampato è sempre $\frac{1}{2}$, ma il peso dello stato j è 2^{j^2-j+1} e la serie diverge. Il criterio corretto diretto usa $\frac{\lambda_j}{\mu_{j+1}}$. Correzione certa; i tassi del controesempio sono limitati, quindi l'esplosione non è la causa del difetto.

Questo esempio collega la normalizzazione alla formula fra invariante dei salti e occupazione nel tempo. Anche quando la catena incorporata ritorna rapidamente in numero di salti, permanenze enormi in stati rari possono rendere infinito il tempo medio di ritorno fisico. Nei modelli di coda con tassi costanti o crescente capacità di servizio il controllo si semplifica, ma il principio resta necessario.

7.8 Uniformizzazione

Fonte A: documento 6, pagine PDF 39–44.

L'uniformizzazione rappresenta una catena continua mediante una catena discreta osservata ai tempi di un processo di Poisson indipendente. Per stati finiti, o con tassi d'uscita uniformemente limitati, si sceglie $\gamma \geq \sup_i \Lambda_i$, con $\gamma > 0$, e si pone

$$P^U = I + \frac{Q}{\gamma}, \quad p^U_{ij} = \frac{q_{ij}}{\gamma} \ \text{ per } \ i \neq j, \quad p^U_{ii} = 1 - \frac{\Lambda_i}{\gamma}. \tag{130}$$

Gli elementi sono non negativi e ogni riga somma a 1. Se $\Lambda_i < \gamma$, si introducono salti fittizi da i a se stesso. A ogni opportunità di transizione, generata a tasso γ, il sistema cambia davvero stato con probabilità $\frac{\Lambda_i}{\gamma}$. Il tasso dei cambi reali è quindi ancora Λ_i.

Sia Y_n la catena con matrice P^U e $N_\gamma(t)$ un Poisson indipendente di tasso γ. Allora $X(t) = Y_{N_\gamma(t)}$ ha lo stesso generatore Q. Condizionando al numero di opportunità,

$$H(t) = \sum_{n=0}^{\infty} e^{-\gamma t} \frac{(\gamma t)^n}{n!} \left(P^U\right)^n = e^{-\gamma t} e^{\gamma t P^U} = e^{Qt}. \tag{131}$$

L'ultima uguaglianza usa $\gamma(P^U - I) = Q$ e la commutazione con l'identità. La rappresentazione è esatta, non richiede un passo infinitesimo e fornisce un metodo di calcolo: si tronca la serie quando la coda della distribuzione di Poisson è sufficientemente piccola. L'errore del troncamento può essere controllato dalla massa di Poisson omessa.

La Equazione 131 deve essere confrontata con la Equazione 111: entrambe rappresentano la transizione esatta, ma la prima la esprime come media di potenze di una matrice stocastica.

La forma delle lezioni $P^U = I + QT$ corrisponde a $T = \frac{1}{\gamma}$ e richiede $T \le \frac{1}{\sup_i} \Lambda_i$. Se si fa evolvere questa matrice ogni T unità deterministiche, si ottiene invece un'approssimazione di Eulero della catena continua: la transizione esatta in un intervallo fisso è e^{QT}, che include tutte le potenze di QT. I due modelli hanno la stessa invariante, quando esiste, ma non lo stesso transitorio fisico su un clock deterministico.

$$\pi Q = 0 \Leftrightarrow \pi P^U = \pi, \quad \Pi_{n+1} = \Pi_n P^U. \tag{132}$$

Nota tecnica A23. Nel documento 6, pagine 39–44, l'equivalenza continua/discreta deve essere intesa con un numero di passi Poisson di tasso $\frac{1}{T}$. Un aggiornamento a intervalli deterministici T è un'approssimazione del transitorio, benché conservi il bilancio stazionario. Nella formula tramite la catena incorporata, $p_{ii}^U = 1 - \frac{\Lambda_i}{\gamma}$ assume veri salti e quindi $p_{ii} = 0$. Con una catena di eventi che ammette cappi si deve aggiungere il contributo $\Lambda_i \frac{p_{ii}}{\gamma}$ usando il tasso complessivo degli eventi. Precisazioni certe.

Approfondimento · livello C. W. Whitt, **Continuous-Time Markov Chains**, sezione 3.4, presenta la costruzione con opportunità Poisson e salti fittizi. Essa conferma che l'uniformizzazione preserva l'intera legge della catena, mentre una griglia temporale fissa ha un significato diverso. La condizione di tassi uniformemente limitati permette di scegliere un unico parametro finito. Fonte: note originali, pp. PDF 15–16.

Il collegamento con le code è ora diretto: si definisce il numero presente come stato, si calcolano i tassi di arrivo e completamento abilitati e si impone il bilancio di probabilità. Le condizioni di normalizzazione diventeranno condizioni di stabilità e le probabilità stazionarie permetteranno di calcolare attese, occupazioni e throughput.

8 Teoria delle code

8.1 Struttura, notazione e prestazioni

Fonte A: documento 7, pagine PDF 1–8.

Le code nascono quando più entità richiedono una risorsa non immediatamente disponibile. Il modello sostituisce i dettagli della lavorazione con un tempo di servizio e concentra l'attenzione su arrivi, attesa, disponibilità dei serventi e ammissione. Le prestazioni dipendono sia dai valori medi sia dalla variabilità: due sistemi con la stessa durata media possono avere attese differenti.

Indichiamo con Y_k l'intervallo fra gli arrivi $k-1$ e k, e con Z_k il tempo di servizio del cliente k. Nella notazione delle lezioni, $A(t) = P(Y_k \le t)$ e $B(t) = P(Z_k \le t)$ sono le rispettive ripartizioni. Si assume spesso che ciascuna sequenza sia i.i.d. e che arrivi e servizi siano indipendenti. Le medie definiscono i tassi nominali

$$E[Y] = \frac{1}{\lambda}, \quad E[Z] = \frac{1}{\mu}. \tag{133}$$

Per arrivi non Poisson, λ è comunque il tasso medio sotto le ipotesi di rinnovo; non determina da solo la distribuzione. Il tempo fra partenze è un'altra grandezza: non va identificato automaticamente con Z.

La struttura specifica il numero m di serventi, la capacità K, l'eventuale popolazione finita N, la disciplina di selezione e le classi dei clienti. FIFO serve in ordine di arrivo, LIFO in ordine inverso; priorità e possibili interruzioni richiedono regole precise. Una coda a capacità finita deve dichiarare che cosa accade ai clienti non ammessi: nelle formule seguenti sono persi, senza creare attesa esterna non modellata.

La politica di scheduling decide anche fra classi con requisiti differenti, mentre la disciplina ordina i clienti all'interno di una classe. La politica di ammissione può rifiutare un cliente per una regola di priorità anche con spazio fisico disponibile: il rifiuto non dipende necessariamente soltanto da K.

La notazione di Kendall $A \,/\, B \,/\, m \,/\, K \,/\, N$ riassume distribuzione degli interarrivi, distribuzione dei servizi, serventi, capacità e popolazione. M indica esponenziale senza memoria, D durata deterministica, G legge generale; GI esplicita interarrivi generali indipendenti. I campi omessi sono normalmente infiniti. Per coerenza con i modelli successivi delle lezioni, K conta i clienti totali, inclusi quelli in servizio. Uno spazio d'attesa con b posti e m serventi corrisponde quindi a $K = b + m$ se tutti possono essere utilizzati.

Indichiamo con A_k l'istante di arrivo e D_k quello di partenza; queste lettere indicizzate non sono le ripartizioni $A(t), B(t)$. Il tempo d'attesa è W_k, quello di permanenza totale è S_k:

$$W_k = \text{inizio servizio} - A_k, \quad S_k = D_k - A_k = W_k + Z_k. \tag{134}$$

Per un sistema FIFO senza sorpassi l'indice delle partenze coincide con quello degli arrivi ammessi. $X(t)$ è il numero nel sistema, $X_Q(t)$ il numero in sola attesa. Il carico di lavoro $U(t)$ è il tempo necessario a svuotare il lavoro corrente se non arrivassero altri clienti, secondo la capacità di servizio specificata. Non è un conteggio di clienti: ha unità di tempo e dipende dalle durate residue.

Le prestazioni principali sono throughput, utilizzazione, numero medio presente, attesa e tempo totale medio, probabilità di blocco. Parlare di valori «a regime» presuppone esistenza della legge stazionaria; parlare di medie finite richiede inoltre l'integrabilità delle grandezze. Una distribuzione stazionaria può esistere anche con qualche momento infinito in modelli generali.

Quando esistono, i limiti $\lim_{k\to\infty} P(W_k \le t) = P(W \le t)$ e $\lim_{k\to\infty} P(S_k \le t) = P(S \le t)$ definiscono le distribuzioni di attesa e permanenza a regime. Analogamente $\pi_n = P(X = n)$ ed $E[U]$ descrivono popolazione e carico stazionari. I limiti non sono garantiti dalla sola definizione della coda.

8.2 Utilizzazione, ricorrenze e attesa

Fonte A: documento 7, pagine PDF 9–17.

Per un servente che lavora quando vi è lavoro, l'utilizzazione è la frazione di tempo occupato. In un sistema stabile senza perdite, il flusso ammesso coincide nel lungo periodo con le partenze. Se il tasso di servizio quando occupato è μ, il throughput θ soddisfa

$$\theta = \mu(1 - \pi_0) = \lambda, \quad \rho = \frac{\lambda}{\mu} = 1 - \pi_0. \tag{135}$$

L'uguaglianza con λ richiede il bilancio dei clienti e l'assenza di perdite; il parametro nominale $\frac{\lambda}{\mu}$ non è automaticamente la probabilità di occupazione in una coda con rifiuti. Un throughput vicino alla capacità si accompagna spesso a una crescita dell'attesa, particolarmente nei modelli variabili qui studiati. Non è una legge universale per ogni sequenza deterministica: la forma precisa del compromesso dipende dal modello.

Per m serventi identici, se $B(t)$ indica ora il numero occupato, la media del loro grado d'utilizzo è $\frac{E[B]}{m}$. In un sistema aperto stabile senza perdite il carico offerto è $\frac{\lambda}{\mu}$, quindi $E[B] = \frac{\lambda}{\mu}$ e $\rho = \frac{\lambda}{m\mu}$. L'utilizzazione di ogni singolo servente coincide con ρ se l'assegnazione è simmetrica; con priorità fissa al servente 1 possono differire gli utilizzi individuali pur restando corretta la media.

Le equazioni campione per campione della coda FIFO a un servente non richiedono l'esponenziale. Il cliente k comincia quando è arrivato e il predecessore ha finito:

$$D_k = \max(A_k, D_{k-1}) + Z_k, \quad W_k = \max(0, D_{k-1} - A_k). \tag{136}$$

Usando $A_k = A_{k-1} + Y_k$ e $D_{k-1} = A_{k-1} + W_{k-1} + Z_{k-1}$ si ricava la ricorrenza di Lindley:

$$W_k = \max(0, W_{k-1} + Z_{k-1} - Y_k), \quad S_k = \max(0, S_{k-1} - Y_k) + Z_k. \tag{137}$$

Nel grafico, gli intervalli superiori sono gli interarrivi, quelli inferiori i servizi e i tratti di attesa sono segnati fra arrivo e avvio del servizio. Il quarto cliente arriva dopo che il sistema si è svuotato, perciò la sua attesa è nulla, come impone il massimo nella Equazione 137.

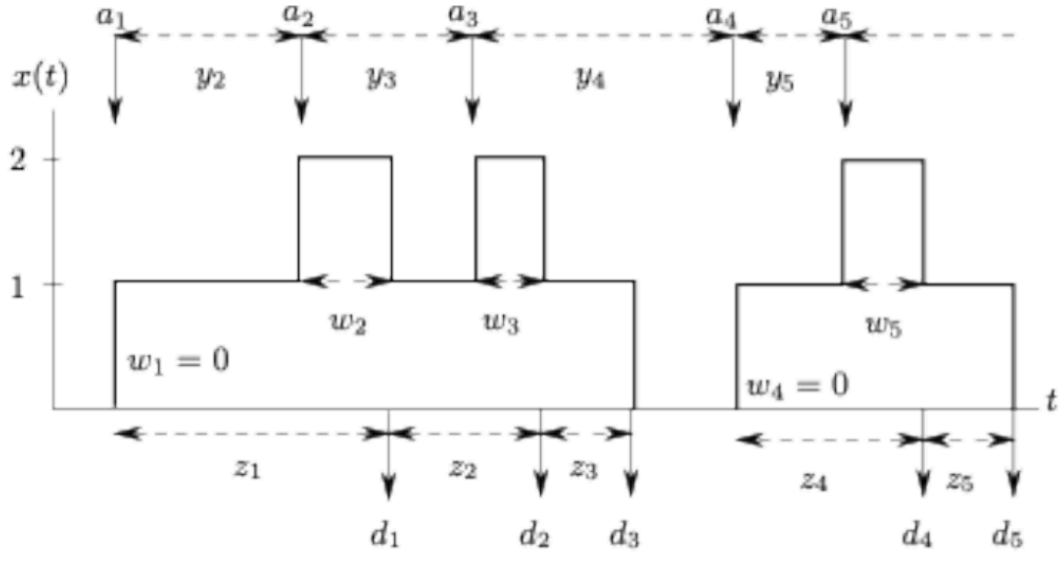


Figura 20: Arrivi, partenze, servizi e attese di una realizzazione FIFO. Documento 7, pagina 15.

Il termine dentro il massimo è il lavoro lasciato dal cliente precedente meno il tempo in cui il sistema ha potuto smaltirlo. Se è negativo il servente è tornato inattivo prima del nuovo arrivo e l'attesa viene azzerata. Il massimo introduce la non linearità del vincolo di non negatività. Le ricorrenze permettono sia la simulazione con campioni assegnati sia l'analisi di leggi generali; non si deve aggiungere un servizio al lavoro già terminato durante un intervallo vuoto.

8.3 Legge di Little

Fonte A: documento 7, pagine PDF 18–21.

La legge di Little collega tre grandezze senza richiedere arrivi Poisson né servizi esponenziali. Per un sistema inizialmente vuoto, siano $N_a(t)$ gli arrivi ammessi e $N_d(t)$ le partenze. Il bilancio dei clienti è $X(t) = N_a(t) - N_d(t)$. L'area sotto la curva di popolazione è

$$u(t) = \int_0^t X(s)\,\mathrm{d}s = \sum_{k:A_k \le t} (\min(D_k, t) - A_k). \tag{138}$$

Ogni cliente contribuisce 1 alla popolazione in ogni istante della sua presenza; integrando la sua funzione indicatrice si ottiene il tempo di permanenza osservato. Sommare prima sui clienti o integrare prima sul tempo dà la stessa area. I clienti non ancora partiti contribuiscono con un tempo troncato all'orizzonte.

La figura presenta una seconda lettura della stessa area: la distanza verticale fra i conteggi cumulativi degli arrivi e delle partenze è $X(t)$; la distanza orizzontale fra l'arrivo e la partenza di un dato cliente è la sua permanenza. La zona grigia totalizza tutti i contributi.

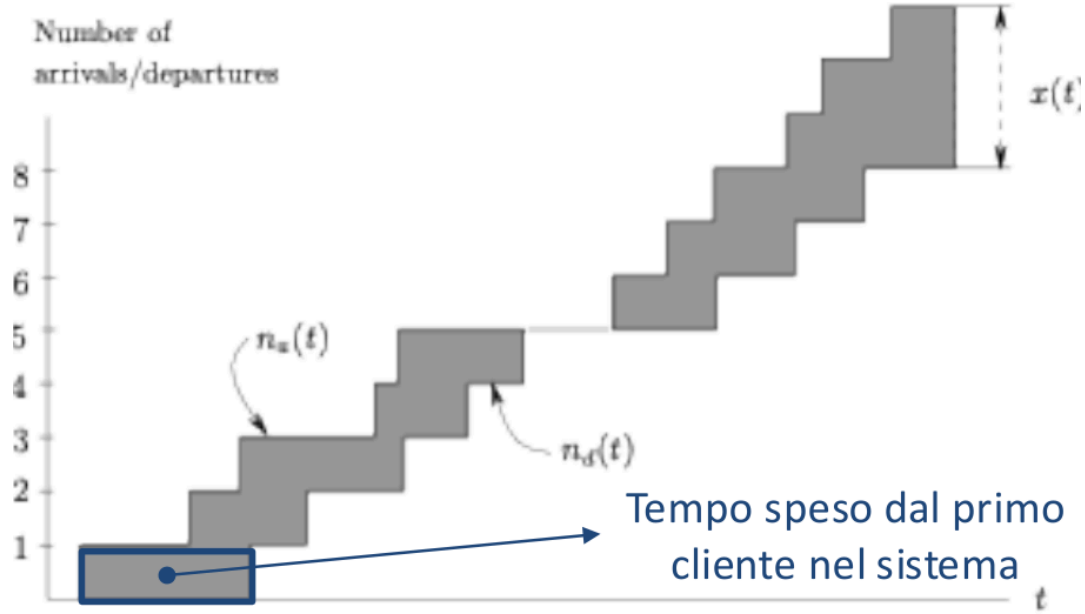


Figura 21: Interpretazione geometrica del bilancio di Little. Documento 7, pagina 18.

Definiamo $|x|(t) = \frac{u(t)}{t}$, $|s|(t) = \frac{u(t)}{N_a}(t)$ e $\lambda(t) = N_a \frac{t}{t}$, quando il denominatore non è zero. Per ogni orizzonte finito vale esattamente

$$|x|(t) = \lambda(t)|s|(t). \tag{139}$$

Se i limiti esistono con il necessario controllo dei contributi di bordo, il tempo medio troncato per cliente converge alla permanenza media. In condizioni stazionarie ed ergodiche con medie finite si ottiene

$$E[X] = \lambda_{\text{eff}} E[S], \quad E\left[X_Q\right] = \lambda_{\text{eff}} E[W]. \tag{140}$$

Il tasso corretto è quello dei clienti effettivamente entrati nel confine considerato. Una coda che respinge metà delle richieste non può usare tutti gli arrivi esterni per collegare la popolazione interna ai tempi dei soli clienti ammessi. Lo stesso principio vale per una rete: si usa il tasso di ingresso nella rete e il tempo totale nella rete, non la somma dei tassi di visita dei nodi.

Little non specifica quale fra le tre quantità sia più facile da calcolare: ne permette di ricavare una dalle altre due. Non prova da sola la stabilità, né consente di moltiplicare medie inesistenti. Un'iniziale non vuota aggiunge contributi di bordo all'identità finita; essi scompaiono nel limite solo sotto le condizioni appropriate. Questo è il senso delle ipotesi necessarie al passaggio dal diagramma campione alla formula delle medie.

8.4 Coda M/M/1 e dimensionamento

Fonte A: documento 7, pagine PDF 22–34.

La M/M/1 ha arrivi Poisson di tasso λ, servizi esponenziali indipendenti di tasso μ, un servente e capacità illimitata. Con $X = n$, la nascita ha tasso λ per ogni n e la morte ha tasso μ per $n \geq 1$. Le equazioni locali danno $\lambda\pi_n = \mu\pi_{n+1}$. Ponendo $\rho = \frac{\lambda}{\mu}$,

$$\pi_n = \rho^n \pi_0, \quad \pi_0 = \left(\sum_{n=0}^{\infty} \rho^n \right)^{-1} = 1 - \rho, \quad \pi_n = (1-\rho)\rho^n. \tag{141}$$

La serie converge solo per $\rho < 1$: il servente deve avere capacità strettamente superiore al carico medio. Per $\rho \geq 1$ non vi è una probabilità stazionaria normalizzata sulla popolazione. Non si deve usare una formula di equilibrio con denominatore nullo o negativo. Per $\lambda > \mu$ il flusso in uscita può tendere alla capacità μ mentre il numero in attesa cresce: saturazione del throughput e stabilità sono proprietà diverse.

La media del numero si ricava differenziando la serie geometrica. Per $0 \leq \rho < 1$, $\sum n\rho^{n-1} = \frac{1}{(1-\rho)^2}$, quindi

$$E[X] = (1-\rho) \sum_{n=0}^{\infty} n\rho^n = \frac{\rho}{1-\rho}. \tag{142}$$

Il servente è occupato con probabilità ρ. Sottraendo il cliente medio in servizio si ottiene $E\left[X_Q\right] = E[X] - \rho = \frac{\rho^2}{1-\rho}$. Little e $S = W + Z$ danno

$$E[S] = \frac{1}{\mu - \lambda}, \quad E[W] = \frac{\rho}{\mu(1-\rho)} = \frac{\lambda}{\mu(\mu-\lambda)}, \quad E\left[X_Q\right] = \frac{\rho^2}{1-\rho}. \tag{143}$$

Il throughput è λ e l'utilizzazione ρ. A carico basso, $E[S] \to \frac{1}{\mu}$ e $E[W] \to 0$ vicino alla saturazione tutte le quantità con denominatore $1 - \rho$ divergono. Nei grafici delle lezioni, l'ascissa è il carico ρ, l'ordinata è un numero medio oppure un tempo secondo il grafico: la divergenza verticale a 1 esprime la perdita di margine di capacità.

> **Nota tecnica A24.** Il documento 7, pagina 29, nell'osservazione finale scrive che $E[X]$ tende a $\frac{1}{\mu}$ a basso carico. Il limite riguarda $E[S]$; $E[X]$ tende a zero. La correzione è certa anche dimensionalmente, poiché $\frac{1}{\mu}$ è un tempo.

Nella simulazione, un blocco che conta solo le entità nello spazio di attesa corrisponde a X_Q, non a X. Per confrontare un risultato SimEvents con la teoria occorre quindi identificare il confine del conteggio e la durata del transitorio. Una media di una singola simulazione finita non è identica alla media teorica; il confronto richiede un orizzonte adeguato e un controllo dell'incertezza statistica.

Nel primo esercizio il tasso d'arrivo è un job al secondo e si richiede un tempo totale medio non superiore a mezzo secondo. Si impone $\frac{1}{\mu - 1} \leq .5$, quindi $\mu \geq 3$ servizi al secondo. L'uguaglianza produce esattamente il limite; per una richiesta stretta $E[S] < .5$ occorre $\mu > 3$. La differenza fra «non superiore» e «inferiore» non va eliminata nel passaggio algebrico.

> **Nota tecnica A35.** Il testo del documento 7, pagina 32, dice «non ecceda 0.5 s», ma la soluzione usa una disuguaglianza stretta e conclude $\mu > 3$. Per «non ecceda» è ammessa l'uguaglianza e la soluzione è $\mu \geq 3$ la conclusione stretta vale per «inferiore a 0.5 s». È una correzione certa della corrispondenza fra testo e vincolo.

Nel collegamento di comunicazione la capacità è $c = 1200$ bit/s e la lunghezza media di un messaggio è 600 bit. Assumendo servizio esponenziale coerente con il modello, $\mu = \frac{c}{E[L]} = 2$ messaggi/s. Il vincolo sull'attesa $E[W] < 1$ secondo richiede

$$\frac{\lambda}{2(2-\lambda)} < 1, \quad 0 \le \lambda < 2, \quad \lambda < \frac{4}{3} \ \text{messaggi/s}. \tag{144}$$

La condizione di stabilità viene imposta prima di moltiplicare per $2-\lambda$, così il verso della disuguaglianza è preservato. Convertire bit/s in messaggi/s è essenziale: non si può confrontare direttamente il tasso di messaggi con il bitrate del canale.

8.5 Coda M/M/m ed Erlang C

Fonte A: documento 7, pagine PDF 35–50.

La M/M/m ha una coda comune e m serventi identici. Quando sono presenti n clienti, lavorano $\min(n,m)$ serventi e il tasso totale dei completamenti è $\mu_n = \min(n,m)\mu$. L'arrivo resta λ. Poniamo $a = \frac{\lambda}{\mu}$ e $\rho = \frac{\lambda}{m\mu} = \frac{a}{m}$. Il parametro a è il numero medio di serventi che il carico richiede; ρ è il carico medio per servente. La stabilità richiede $\rho < 1$.

Dai prodotti di nascita e morte si ottiene

$$\pi_n = \begin{cases} \frac{a^n}{n!}\pi_0 & 0 \le n < m \\ \frac{a^n}{m!\,m^{n-m}}\pi_0 & n \ge m \end{cases}. \tag{145}$$

Prima della saturazione i denominatori sono $\mu, 2\mu, \dots, n\mu$; dopo m clienti il tasso di morte non cresce più e ogni ulteriore fattore è $\frac{\lambda}{m\mu} = \rho$. Normalizzando la coda geometrica,

$$\pi_0 = \left(\sum_{n=0}^{m-1} \frac{a^n}{n!} + \frac{a^m}{m!(1-\rho)} \right)^{-1}. \tag{146}$$

Per $m = 1$ si recupera $\pi_0 = 1-\rho$. La probabilità che tutti i serventi siano occupati è

$$C = P(X \ge m) = \sum_{n=m}^{\infty} \pi_n = a^m \frac{\pi_0}{m!(1-\rho)}. \tag{147}$$

Per gli arrivi Poisson questa è anche la probabilità di dover attendere, osservando il numero presente immediatamente prima dell'arrivo. L'uguaglianza fra osservazione nel tempo e osservazione agli arrivi è la proprietà PASTA, che richiede che il processo non anticipi gli arrivi futuri.

Approfondimento · livello C. PASTA, «Poisson Arrivals See Time Averages», giustifica l'uso delle probabilità temporali prima dell'arrivo. Un argomento d'intensità considera gli arrivi che trovano lo stato n: in un intervallo $\mathrm{d}t$ il loro numero medio è $\lambda P(X(t^-) = n)\,\mathrm{d}t$. Il rapporto rispetto al numero medio di tutti gli arrivi restituisce la probabilità temporale in condizioni stazionarie. Non si richiede che tutta la traiettoria di X sia indipendente dagli arrivi: X è costruito anche da essi. Riferimento didattico consultato: A. R. Odoni, Queueing Systems, Lecture 3, pagina PDF 5.

La media dei serventi occupati può essere dimostrata espandendo la somma, anziché assunta dalla sola intuizione. Per $n < m$, $n\frac{a^n}{n!} = a\frac{a^{n-1}}{(n-1)!}$ per $n \ge m$ si contano tutti i m serventi. Quindi

$$E[B] = \pi_0 a \sum_{r=0}^{m-2} \frac{a^r}{r!} + m\pi_0 \frac{a^m}{m!(1-\rho)} = a = m\rho. \tag{148}$$

L'uguaglianza finale si verifica confrontando con $\frac{a}{\pi_0}$: il termine mancante alla prima somma è compensato dalla parte geometrica, usando $a = m\rho$. Una dimostrazione alternativa impone il bilancio $\lambda = \mu E[B]$. L'utilizzazione media per servente è dunque ρ, con la cautela già indicata sull'assegnazione non simmetrica.

Per la sola attesa, se $n = m + r$ si hanno r clienti oltre i serventi. La coda della distribuzione dà

$$E\left[X_Q\right] = \pi_0 \frac{a^m}{m!} \sum_{r=0}^{\infty} r\rho^r = \pi_0 \frac{a^m}{m!} \frac{\rho}{(1-\rho)^2} = C\frac{\rho}{1-\rho}. \tag{149}$$

Il termine $r = 0$ non contribuisce. Non si sottrae sempre m da X: per $X < m$ il numero in attesa è zero, perciò $X_Q = \max(X - m, 0)$. Sommando servizio e attesa e applicando Little,

$$E[X] = m\rho + C\frac{\rho}{1-\rho}, \quad E[W] = \frac{C}{m\mu - \lambda}, \quad E[S] = \frac{1}{\mu} + \frac{C}{m\mu - \lambda}. \tag{150}$$

La probabilità di attesa non coincide con l'utilizzazione: un servente può essere spesso occupato mentre la possibilità di trovare **tutti** i serventi occupati resta piccola. Aumentare m mantenendo il carico totale modifica sia ρ sia C; non basta dividere per m l'attesa della M/M/1. Le formule descrivono il beneficio della condivisione di una coda comune, sotto le ipotesi di servizi esponenziali e capacità infinita.

Per dimensionare un centralino con possibilità di attesa si assegnano λ, durata media della chiamata $T = \frac{1}{\mu}$ e soglia p; si cerca il minimo intero m che soddisfa $\lambda < m\mu$ e $C\left(m, \frac{\lambda}{\mu}\right) < p$. La Equazione 147 esprime questa specifica. Se non sono ammessi posti d'attesa si usa invece Erlang B, nella Equazione 159.

8.6 Infiniti serventi

Fonte A: documento 7, pagine PDF 51–54.

Nella M/M/∞ ogni cliente inizia immediatamente il proprio servizio. Il tasso totale di morte nello stato n è $n\mu$, senza saturazione. Ponendo $a = \frac{\lambda}{\mu}$, la distribuzione di nascita e morte diventa

$$\pi_n = \pi_0 \frac{a^n}{n!}, \quad \pi_0 = \left(\sum_{n=0}^{\infty} \frac{a^n}{n!}\right)^{-1} = e^{-a}, \quad X \sim \text{Poisson}(a). \tag{151}$$

La serie esponenziale converge per ogni a finito. La popolazione media e il numero medio di serventi occupati sono entrambi a; l'attesa è nulla e la permanenza coincide con il servizio:

$$E[X] = a, \quad E[W] = 0, \quad E[S] = \frac{1}{\mu}, \quad \theta = \lambda, \quad P(X > 0) = 1 - e^{-a}. \tag{152}$$

L'ultima quantità è la probabilità che il sistema non sia vuoto; non è l'utilizzazione di un singolo servente di una famiglia infinita. Il modello rappresenta un centro di ritardo in cui ogni cliente dispone della propria risorsa. Il ritardo è esponenziale, non deterministico.

> **Nota tecnica A25.** Il documento 7, pagine 51–53, riporta una condizione $\rho < 1$ anche per gli infiniti serventi. Non è necessaria: $\sum \frac{a^n}{n!} = e^a$ converge per ogni $a = \frac{\lambda}{\mu} < \infty$ con $\mu > 0$. Il parametro che le slide chiamano ρ è qui indicato con a, perché non rappresenta un'utilizzazione per servente. Correzione certa.

8.7 Capacità finita M/M/1/K

Fonte A: documento 7, pagine PDF 55–65.

La capacità totale $K \geq 1$ limita lo stato a $0, \ldots, K$. Gli arrivi offerti sono Poisson di tasso λ, ma solo quelli che trovano $n < K$ vengono ammessi. Il tasso di nascita della catena è quindi $\lambda_n = \lambda$ per $n < K$ e zero al bordo. Il tasso di morte è $\mu_n = \mu$ per $1 \leq n \leq K$, con $\mu_0 = 0$. Un arrivo respinto in K non è una nascita.

Le equazioni locali danno ancora pesi ρ^n, con $\rho = \frac{\lambda}{\mu}$, ma ora la somma è finita:

$$\pi_n = \rho^n \pi_0, \quad \pi_0 = \begin{cases} \frac{1-\rho}{1-\rho^{K+1}} & \rho \neq 1 \\ \frac{1}{K+1} & \rho = 1 \end{cases}. \tag{153}$$

Non occorre $\rho < 1$ per l'esistenza dell'equilibrio in una capacità finita. Quando il carico supera la capacità media il sistema rimane spesso pieno e respinge molti clienti, anziché accumularli senza limite. Per $\rho = 1$ tutti i livelli sono equiprobabili: il caso va trattato mediante la somma finita o il limite, non sostituendo nella forma $\frac{0}{0}$.

Per PASTA, la probabilità di blocco di una richiesta esterna è $P_B = \pi_K$. Il tasso ammesso e il throughput sono

$$\lambda_{\text{eff}} = \theta = \lambda(1-\pi_K) = \mu(1-\pi_0), \quad \rho_{\text{eff}} = \frac{\theta}{\mu} = 1-\pi_0. \tag{154}$$

Il parametro offerto ρ può essere maggiore di 1, mentre ρ_{eff} è una probabilità e non lo supera. Per $\rho \neq 1$, $\rho_{\text{eff}} = \frac{\rho(1-\rho^K)}{1-\rho^{K+1}}$. A capacità finita, aumentare gli arrivi può aumentare il throughput verso μ, ma una quota crescente viene persa.

Il numero medio deriva dalla somma geometrica finita $Z_K(\rho) = \sum_{n=0}^{K} \rho^n$. Poiché $\rho Z_K' = \sum n\rho^n$, si ha $E[X] = \rho\frac{Z_K'}{Z_K}$. Derivando il logaritmo di $\frac{1-\rho^{K+1}}{1-\rho}$ si trova

$$E[X] = \frac{\rho}{1-\rho} - (K+1)\frac{\rho^{K+1}}{1-\rho^{K+1}}, \quad \rho \neq 1. \tag{155}$$

La forma equivalente delle lezioni è

$$E[X] = \frac{\rho}{1-\rho^{K+1}}\left(\frac{1-\rho^K}{1-\rho} - K\rho^K\right). \tag{156}$$

Per $\rho = 1$, la media della distribuzione uniforme è $\frac{K}{2}$. Il numero medio in sola attesa si ottiene sottraendo l'occupazione del servente: $E\left[X_Q\right] = E[X] - (1-\pi_0)$. Un'altra identità utile, ottenuta spostando l'indice nella somma, è

$$E\left[X_Q\right] = \sum_{n=1}^{K}(n-1)\pi_n = \rho E[X] - K\rho^{K+1}\pi_0. \tag{157}$$

Little va applicata ai clienti ammessi:

$$E[S] = \frac{E[X]}{\lambda_{\text{eff}}}, \quad E[W] = \frac{E\left[X_Q\right]}{\lambda_{\text{eff}}} = E[S] - \frac{1}{\mu}. \tag{158}$$

Per $\lambda = 0$ il rapporto è indeterminato come rapporto di flussi nulli, ma il tempo di un cliente ipotetico isolato si ricava per limite: servizio medio $\frac{1}{\mu}$ e attesa zero. Per $K = 1$ non vi è spazio d'attesa, quindi $X_Q = 0$ le formule lo confermano. Per $K \to \infty$ e $\rho < 1$ si recupera la M/M/1. Se invece $\rho > 1$, il limite di grandi capacità non crea una coda infinita stabile.

> **Nota tecnica A26.** Nel documento 7, pagina 55, l'intervallo di indici stampato per il tasso di morte include 0 ed esclude il bordo superiore: deve essere $1, \dots, K$. A pagina 56 il termine intermedio della somma da 1 a K deve essere $\frac{\rho(1-\rho^K)}{1-\rho}$, non $\frac{\rho(1-\rho^{K+1})}{1-\rho}$. A pagina 61 il cambio d'indice coerente con $n-1$ è $j = n-1$. Le formule finali sopra derivano dalla somma diretta. Correzioni certe.

L'esercizio di dimensionamento confronta tre macchine con arrivi medi di un pezzo al minuto, tempi medi di servizio rispettivamente 2, $\frac{5}{6}$ e $\frac{1}{2}$ minuti, e costi 100, 300 e 500. Ogni posizione di capacità costa 80 secondo il conteggio economico adottato nelle slide. Si richiede blocco inferiore al 10%. Per la prima macchina $\mu = .5$ e $\rho = 2$: il throughput non supera .5 pezzi/min, quindi almeno metà degli arrivi deve essere persa per qualunque K. Nessuna capacità soddisfa il vincolo.

Per la seconda, $\mu = 1.2$ e $\rho = \frac{5}{6}$ la formula del blocco si semplifica a $P_B = \frac{5^K}{6^{K+1}-5^{K+1}}$. Per la terza, $\mu = 2$, $\rho = \frac{1}{2}$ e $P_B = \frac{1}{2^{K+1}-1}$. Si controllano i più piccoli interi ammissibili:

Macchina	K	P_B	Vincolo	Costo
2	5	circa .100706	non soddisfatto	700
2	6	circa .077424	soddisfatto	780
3	2	$\frac{1}{7}$	non soddisfatto	660
3	3	$\frac{1}{15}$	soddisfatto	740

Tabella 8: Scelta della capacità nell'esercizio con soglia di blocco 0.1.

Il minimo fra le alternative ammissibili è la macchina 3 con $K = 3$, costo 740. La capacità è scelta minima perché il costo cresce con K e il blocco diminuisce quando si aggiungono posti. Se si ammettesse invece il valore circa .100706 come tollerabile, la macchina 2 con $K = 5$ costerebbe 700, ma violerebbe il vincolo originario. Se i posti a pagamento fossero soltanto quelli d'attesa, il costo sarebbe macchina più $80(K - 1)$: il confronto andrebbe dichiarato con questa nuova convenzione.

> **Nota tecnica A27.** Nel documento 7, pagina 65, il primo valore esemplificativo del blocco per la macchina 2 è $\frac{5}{9}$. Per $\rho = \frac{5}{6}$ e $K = 1$ il valore corretto è $\frac{\rho}{1+\rho} = \frac{5}{11}$. La formula generale $\frac{5^K}{6^{K+1} - 5^{K+1}}$ è invece corretta. La soglia al 10% esclude $K = 5$ anche se il superamento è piccolo. Correzione e distinzione del vincolo certe.

8.8 Perdita pura ed Erlang B

Fonte A: documento 7, pagine PDF 66–68.

La M/M/m/m ha m serventi e nessun posto d'attesa. Un arrivo che trova tutti occupati è perso. Nello stato $n = 0, \dots, m$, il tasso di nascita è λ se $n < m$, il tasso di morte è $n\mu$. Con $a = \frac{\lambda}{\mu}$,

$$\pi_n = \frac{\frac{a^n}{n!}}{\sum_{j=0}^{m} \frac{a^j}{j!}}, \quad B = P_B = \pi_m = \frac{\frac{a^m}{m!}}{\sum_{j=0}^{m} \frac{a^j}{j!}}. \tag{159}$$

È la formula di Erlang B. Il parametro a misura carico offerto in unità di lavoro medio, non probabilità di utilizzazione. La distribuzione è una Poisson troncata e rinormalizzata. In quanto catena finita, ammette equilibrio per ogni carico finito; non serve $\frac{a}{m} < 1$.

Il throughput è $\theta = \lambda(1 - B)$. Spostando l'indice nella somma del numero occupato si ottiene

$$E[X] = a(1 - B), \quad E[W] = 0, \quad E[S] = \frac{1}{\mu}, \quad \rho_{\text{medio}} = \frac{a(1 - B)}{m}. \tag{160}$$

Non ci sono clienti in attesa; quelli ammessi subiscono solo il servizio. La formula distingue il traffico offerto a da quello effettivamente trasportato $a(1 - B)$. Aumentare i serventi riduce il blocco; la prestazione centrale di un sistema senza attesa è la probabilità di perdita, non il tempo medio in coda che è identicamente nullo.

8.9 Popolazione finita e terminali

Fonte A: documento 7, pagine PDF 69–75.

Nel modello M/M/1//N esistono solo N clienti, che alternano un periodo esterno di elaborazione o riflessione e una richiesta al servente. Ogni cliente esterno genera la prossima richiesta dopo un tempo esponenziale di tasso λ. Con n clienti già presso il servente, ne restano $N - n$ fuori: il tasso complessivo d'arrivo è $(N - n)\lambda$, non una costante. Il tasso di completamento è μ per $n \geq 1$.

La catena è finita su $0, \dots, N$. Ponendo $\rho = \frac{\lambda}{\mu}$, le equazioni locali danno

$$\pi_n = \pi_0 \prod_{j=0}^{n-1} \frac{(N - j)\lambda}{\mu} = \pi_0 \frac{N!}{(N - n)!} \rho^n, \quad \pi_0 = \left(\sum_{n=0}^{N} \frac{N!}{(N - n)!} \rho^n \right)^{-1}. \tag{161}$$

Il parametro ρ è un rapporto fra il tasso di un singolo cliente esterno e quello del servente; non è l'utilizzazione del servente e non deve essere minore di 1. Il throughput è $\theta = \mu(1 - \pi_0)$, uguale al tasso medio $(N - E[X])\lambda$ degli arrivi dal gruppo esterno.

Indichiamo con R il tempo medio di risposta dal momento della richiesta al completamento. Applicando Little sia al centro di servizio sia al gruppo esterno, il cui tempo medio individuale è $\frac{1}{\lambda}$,

Lo schema rappresenta il servente principale in alto e i possibili ritardi individuali in basso. Ogni cliente esterno occupa una propria fase di ritardo, perciò il tasso di rientro dipende dal numero $N - X$ di clienti fuori dal servente.

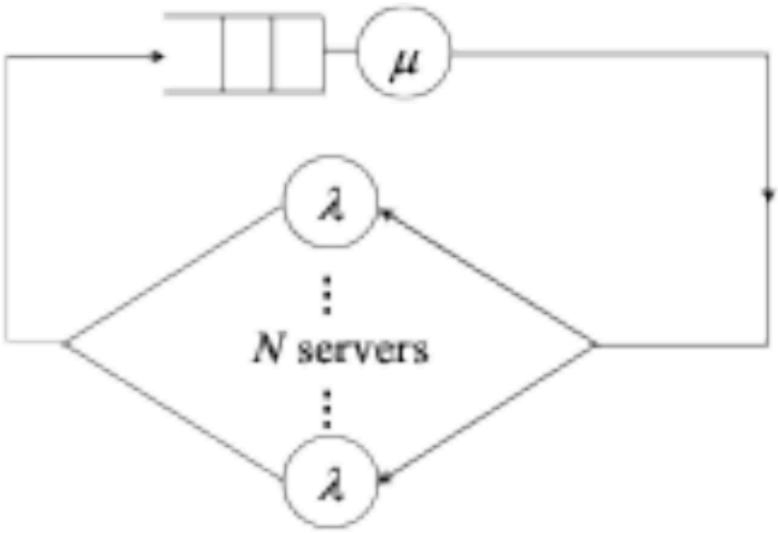


Figura 22: Centro di servizio e ritardi della popolazione finita. Documento 7, pagina 73.

$$E[X] = \theta E[R], \quad N - E[X] = \frac{\theta}{\lambda}, \quad E[R] = \frac{N}{\theta} - \frac{1}{\lambda}. \tag{162}$$

La relazione conserva la popolazione totale e fornisce il tempo di risposta senza una nuova somma di attese. Nel sistema di terminali, il periodo esterno è il tempo di riflessione dell'utente. Nel sistema produttivo a maschere o supporti, N è il numero di supporti che circolano: ogni supporto rilasciato ritorna alla fase esterna prima di richiedere di nuovo la macchina.

I grafici delle lezioni riportano l'andamento del throughput e della risposta al crescere di N. Per pochi clienti, il servente rimane spesso inattivo: aggiungere popolazione aumenta il throughput. Quando il servente è quasi sempre occupato, θ si avvicina a μ e il throughput cresce poco, mentre la risposta tende all'asintoto $\frac{N}{\mu} - \frac{1}{\lambda}$. Il punto N^* è quindi una scelta di compromesso, da definire mediante soglia sul tempo di risposta o beneficio marginale del throughput; il solo grafico non determina un unico ottimo economico senza un criterio di costo.

Nel grafico della risposta l'ascissa è la popolazione N, l'ordinata è $E[R]$ in unità di tempo; la linea tratteggiata è l'asintoto $\frac{N}{\mu} - \frac{1}{\lambda}$. Una specifica esplicita $E[R] < \beta$ equivale a $\frac{N}{\mu(1-\pi_0)} < \beta + \frac{1}{\lambda}$, con π_0 calcolata per ciascun N.

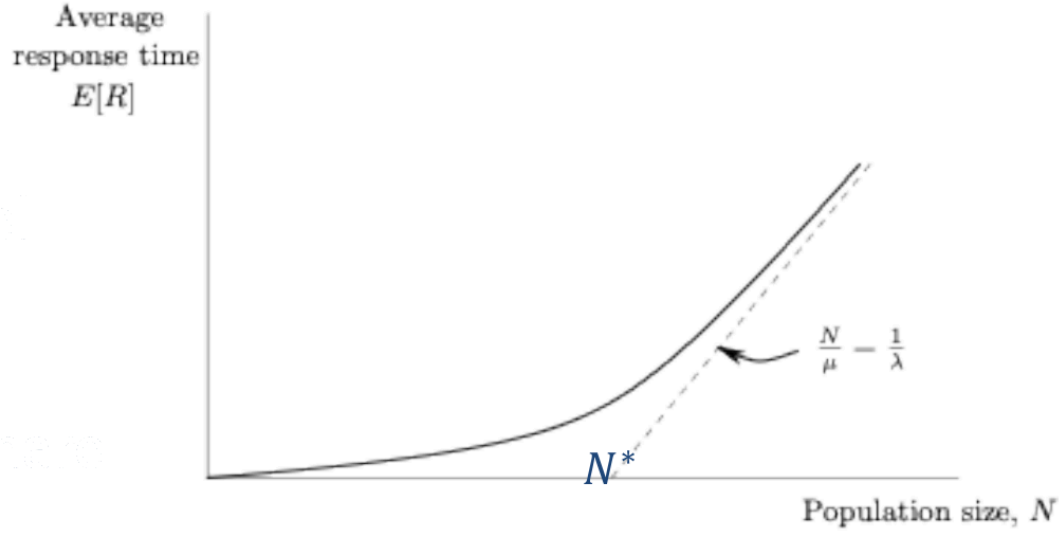


Figura 23: Tempo di risposta e popolazione, con asintoto di saturazione. Documento 7, pagina 75.

8.10 Modello M/M/m/K/N

Fonte A: documento 7, pagine PDF 76–78.

Il modello generale combina popolazione finita N, capacità totale K e m serventi, con $K \geq m$. Lo stato massimo è $H = \min(K, N)$. La popolazione esterna ha $N - n$ clienti e ogni servente occupato completa a tasso μ:

Nel caso con popolazione ancora esterna e sistema pieno, le richieste respinte rientrano nella fase esterna e ritentano dopo un nuovo ritardo esponenziale medio $\frac{1}{\lambda}$, come specificato nelle lezioni. Tali tentativi sono eventi senza aumento della popolazione interna.

$$\lambda_n = (N-n)\lambda \quad (0 \leq n < H), \quad \lambda_H = 0, \quad \mu_n = \min(n, m)\mu \quad (1 \leq n \leq H). \tag{163}$$

La distribuzione deriva direttamente dai prodotti e si può scrivere mediante pesi w_n:

$$w_n = \begin{cases} \binom{N}{n}\rho^n & 0 \leq n < m \\ \frac{N!}{(N-n)!m!m^{n-m}}\rho^n & m \leq n \leq H \end{cases}, \quad \pi_n = \frac{w_n}{\sum_{j=0}^{H} w_j}, \quad \rho = \frac{\lambda}{\mu}. \tag{164}$$

Prima di m, il prodotto dei tassi di morte contiene $n!\mu^n$ e produce il coefficiente binomiale. Oltre m, i completamenti restano a tasso $m\mu$ e ogni ulteriore rapporto aggiunge un fattore $(N-n)\frac{\rho}{m}$. La forma espansa della normalizzazione riportata nelle lezioni è equivalente:

$$\pi_0^{-1} = \sum_{n=0}^{m-1} \binom{N}{n} \rho^n + \binom{N}{m-1} \rho^{m-1} \sum_{n=m}^{H} \frac{(N-m+1)!}{(N-n)!} \left(\frac{\rho}{m}\right)^{n-m+1}. \tag{165}$$

Questa scrittura assume $N \geq m$ se $N < m$, basta la prima formula dei pesi limitata a H. Non serve un vincolo $\rho < 1$, perché lo spazio è finito.

Il throughput e le prestazioni si ottengono dalle medie di stato:

$$\begin{aligned} \theta &= \sum_{n=0}^{H-1} (N-n)\lambda\pi_n = \mu \sum_{n=1}^{H} \min(n, m)\pi_n, \\ E[X] &= \sum_{n=0}^{H} n\pi_n, \quad E[S] = \frac{E[X]}{\theta}. \end{aligned} \tag{166}$$

La prima uguaglianza è il bilancio fra arrivi ammessi e completamenti. Il numero medio in attesa è $\sum \max(n - m, 0)\pi_n$ e l'attesa media si ricava dividendo per θ. La proprietà PASTA con un tasso esterno costante non può essere applicata automaticamente a una sorgente finita il cui tasso dipende da n.

> **Nota tecnica A28.** Il documento 7, pagina 76, indica in un passaggio il rifiuto al raggiungimento di una lunghezza N. Il bordo di capacità è K, mentre N è la popolazione. Lo stato massimo è $\min(K, N)$; il blocco per capacità può verificarsi con clienti ancora esterni quando $N > K$. Correzione certa di ruolo e indice.

Questi modelli mostrano perché occorre ricavare i tassi dallo stato prima di applicare un formulario. Capacità finita, popolazione finita e numero di serventi modificano fattori differenti del prodotto di equilibrio. Una volta calcolate correttamente le probabilità, throughput, occupazione e Little costituiscono il collegamento comune fra tutti i casi. Le reti del prossimo capitolo useranno questi risultati come modelli locali dei nodi.

9 Reti di code

9.1 Reti aperte, chiuse e stato congiunto

Fonte A: documento 8, pagine PDF 1–3.

Una rete collega nodi di servizio mediante regole di instradamento. Un nodo comprende la coda e i serventi che la precedono o la seguono secondo lo schema adottato. Le reti sono aperte se ammettono ingressi dall'esterno e uscite; sono chiuse se i clienti restano nella rete e la popolazione totale è costante. Le stesse configurazioni rappresentano job che visitano CPU e dischi, pezzi fra stazioni produttive o richieste che attraversano più risorse.

Con M nodi, lo stato di conteggio è $\boldsymbol{X} = (X_1, \dots, X_M)$, dove ogni componente include il servizio al nodo. L'obiettivo centrale è la distribuzione congiunta

$$\pi(n_1, \dots, n_M) = P(X_1 = n_1, \dots, X_M = n_M). \tag{167}$$

Sapere soltanto le medie locali non specifica le dipendenze fra nodi. La forma prodotto, quando valida, permette di costruire la congiunta da fattori locali. Deve però essere dimostrata sotto ipotesi precise: collegare code già note non garantisce automaticamente indipendenza o arrivi interni Poisson.

9.2 Teorema di Burke

Fonte A: documento 8, pagine PDF 4–10.

Per una M/M/1 stabile **in equilibrio**, con arrivi Poisson di tasso $\lambda < \mu$, il teorema di Burke afferma che il processo delle partenze è Poisson di tasso λ. Il tasso d'uscita uguaglia quello d'ingresso per conservazione dei clienti; la natura Poisson è un'informazione più forte. Significa che i tempi successivi fra partenze sono esponenziali indipendenti. Non significa che il processo degli arrivi e quello delle partenze siano fra loro indipendenti.

La ricostruzione delle lezioni parte da $\Psi_k = D_k - D_{k-1}$. Per la ricorrenza della coda,

$$\Psi_k = \max(A_k - D_{k-1}, 0) + Z_k. \tag{168}$$

Se il cliente k trova il sistema occupato, il servente non si svuota prima di avviare il suo servizio e $\Psi_k = Z_k$. Se lo trova vuoto, fra le due partenze compare anche un periodo inattivo $I = A_k - D_{k-1}$, esponenziale di tasso λ, seguito dal servizio esponenziale di tasso μ. I pesi dei due casi sono $\rho = \frac{\lambda}{\mu}$ e $1 - \rho$, usando la distribuzione vista dagli arrivi Poisson.

Per I e Z indipendenti la densità della somma è una convoluzione:

$$f_{I+Z}(t) = \int_0^t \lambda e^{-\lambda u} \mu e^{-\mu(t-u)} \, \mathrm{d}u = \lambda \frac{\mu}{\mu - \lambda} \big(e^{-\lambda t} - e^{-\mu t} \big). \tag{169}$$

Il passaggio intermedio raccoglie $\lambda \mu e^{-\mu t}$ e integra $e^{(\mu - \lambda)u}$, dando $\frac{e^{(\mu-\lambda)t} - 1}{\mu - \lambda}$. La trasformata di Laplace è il prodotto delle trasformate:

$$\tilde{f}_{I+Z}(s) = \lambda \frac{\mu}{(s+\lambda)(s+\mu)} = \lambda \frac{\mu}{\mu - \lambda} \left(\frac{1}{s+\lambda} - \frac{1}{s+\mu} \right). \tag{170}$$

Integrando la densità da 0 a t,

$$F_{I+Z}(t) = \frac{\mu}{\mu - \lambda} \big(1 - e^{-\lambda t}\big) - \frac{\lambda}{\mu - \lambda} \big(1 - e^{-\mu t}\big). \tag{171}$$

La miscela delle due alternative è

$$P(\Psi \le t) = \rho \big(1 - e^{-\mu t}\big) + (1 - \rho) F_{I+Z}(t) = 1 - e^{-\lambda t}. \tag{172}$$

La semplificazione usa $\rho = \frac{\lambda}{\mu}$ e $1 - \rho = \frac{\mu - \lambda}{\mu}$: i due coefficienti di $e^{-\mu t}$ si cancellano. È stata ricavata la legge marginale esponenziale del tempo fra partenze in regime. Da sola questa legge non prova l'indipendenza di tutti gli intervalli successivi, necessaria per concludere che l'intero processo è Poisson.

Approfondimento · livello C. Il completamento mediante reversibilità è trattato da F. Kelly ed E. Yudovina, Lecture Notes on Stochastic Networks, sezione 2.1. La M/M/1 stazionaria soddisfa il bilancio dettagliato $\pi_n \lambda = \pi_{n+1} \mu$, quindi il processo invertito nel tempo ha la stessa legge. Le partenze del processo diretto diventano gli arrivi di quello inverso, che sono Poisson: questo stabilisce anche gli incrementi indipendenti. In equilibrio il risultato si estende alla M/M/m con capacità d'attesa infinita, la cui popolazione è ancora una nascita e morte reversibile con tasso d'arrivo costante. L'inizializzazione stazionaria è essenziale.

Nota tecnica A29. Nel documento 8, pagina 4, le «partenze esponenziali i.i.d.» sono presentate come caratteristica generale dei nodi markoviani. L'ipotesi di base riguarda i **tempi di servizio**; la natura Poisson delle partenze richiede un risultato come Burke e le sue condizioni. Le pagine 5–10 calcolano la marginale di Ψ: l'indipendenza degli intervalli è completata sopra con la reversibilità. Precisazione certa.

Se una M/M/1 parte vuota, il primo cliente deve prima arrivare e poi essere servito: la prima partenza non ha in generale un'attesa esponenziale di tasso λ dall'origine. Questa osservazione mostra concretamente perché non si può usare Burke senza equilibrio. Nelle reti prive di ricircoli, il teorema aiuta a propagare flussi Poisson attraverso i nodi; con feedback non si può invece assumere che ogni flusso interno sia Poisson indipendente.

9.3 Equazioni di traffico e tandem

Fonte A: documento 8, pagine PDF 11–15.

La rete aperta delle lezioni ha nodi a capacità illimitata, clienti di una sola classe, disciplina FIFO, m_i serventi esponenziali al nodo i con tasso individuale μ_i. Gli arrivi esterni ai diversi nodi sono Poisson indipendenti con tassi r_i. Dopo un servizio al nodo i, il cliente va al nodo j con probabilità p_{ij} oppure esce con $p_{i0} = 1 - \sum_{j=1}^{M} p_{ij}$. Le decisioni di routing sono indipendenti dai tempi e dal passato, date le probabilità del modello.

Il traffico totale al nodo i, comprendendo visite ripetute, è λ_i. Il bilancio dei flussi medi dà

$$\lambda_i = r_i + \sum_{j=1}^{M} \lambda_j p_{ji}, \quad \boldsymbol{\lambda} = \boldsymbol{r} + \boldsymbol{\lambda} R. \tag{173}$$

$R = [p_{ij}]$ è la matrice di routing interno, sostocastica per righe; qui i vettori sono riga. Con vettori colonna si scriverebbe $(I - R^T)\boldsymbol{\lambda} = \boldsymbol{r}$. L'apertura va intesa come possibilità di uscita finale da ogni classe di routing raggiunta; una condizione sufficiente e usuale è raggio spettrale di R minore di 1. Allora $(I - R)^{-1} = I + R + R^2 + \dots$ e $\boldsymbol{\lambda} = \boldsymbol{r}(I - R)^{-1}$: i termini contano le visite dopo zero, uno, due o più trasferimenti.

Nota tecnica A30. Nel documento 8, pagina 11, la prima equazione di traffico usa p_{ij}, mentre la seconda usa correttamente p_{ji}. A pagina 17 manca inoltre il pedice j su un tasso sommato. Con la convenzione «origine in riga, destinazione in colonna» la forma è sempre $\lambda_i = r_i + \sum_j \lambda_j p_{ji}$. Correzione certa.

Nel tandem di due nodi a un servente, gli arrivi esterni di tasso λ entrano nel nodo 1, ogni servizio 1 trasferisce il cliente al nodo 2 e ogni servizio 2 lo fa uscire. Quindi $\lambda_1 = \lambda_2 = \lambda$ e la stabilità richiede $\lambda < \mu_1$ e $\lambda < \mu_2$. Le transizioni dello stato (n_1, n_2) sono $(+1, 0)$ a tasso λ, $(-1, +1)$ a tasso μ_1 se $n_1 > 0$ e $(0, -1)$ a tasso μ_2 se $n_2 > 0$.

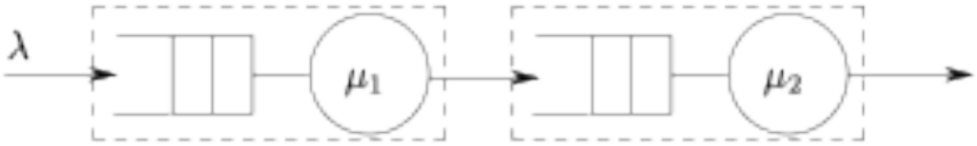


Figura 24: Due nodi in tandem. Documento 8, pagina 12.

Per uno stato interno, i predecessori sono $(n_1 - 1, n_2)$ per un arrivo, $(n_1 + 1, n_2 - 1)$ per un trasferimento e $(n_1, n_2 + 1)$ per un'uscita dal nodo 2. I quattro casi di bilancio sono

$$\begin{aligned} &\lambda\pi(n_1 - 1, n_2) + \mu_1\pi(n_1 + 1, n_2 - 1) + \mu_2\pi(n_1, n_2 + 1) \\ &\quad = (\lambda + \mu_1 + \mu_2)\pi(n_1, n_2) \quad (n_1, n_2 > 0). \end{aligned} \tag{174}$$

$$\lambda\pi(n_1 - 1, 0) + \mu_2\pi(n_1, 1) = (\lambda + \mu_1)\pi(n_1, 0) \quad (n_1 > 0). \tag{175}$$

$$\mu_1\pi(1, n_2 - 1) + \mu_2\pi(0, n_2 + 1) = (\lambda + \mu_2)\pi(0, n_2) \quad (n_2 > 0). \tag{176}$$

$$\mu_2\pi(0, 1) = \lambda\pi(0, 0), \quad \sum_{n_1=0}^{\infty}\sum_{n_2=0}^{\infty} \pi(n_1, n_2) = 1. \tag{177}$$

Proviamo la forma $\pi(n_1, n_2) = c\rho_1^{n_1}\rho_2^{n_2}$ con $\rho_i = \frac{\lambda}{\mu_i}$. Dividendo l'equazione interna per la probabilità candidata, i tre termini entranti diventano $\frac{\lambda}{\rho_1} = \mu_1$, $\mu_1\frac{\rho_1}{\rho_2} = \mu_2$ e $\mu_2\rho_2 = \lambda$: la loro somma coincide con l'uscita. Le stesse sostituzioni verificano i tre bordi. La normalizzazione separa le serie geometriche e determina

$$\pi(n_1, n_2) = (1 - \rho_1)\rho_1^{n_1}(1 - \rho_2)\rho_2^{n_2} = \pi_1(n_1)\pi_2(n_2). \tag{178}$$

I numeri ai nodi sono indipendenti a un **istante fissato in equilibrio**. Non sono processi indipendenti lungo il tempo: una partenza da 1 è immediatamente un arrivo in 2. Il nodo con minore tasso di servizio è il primo a perdere stabilità aumentando λ, quindi costituisce il collo di bottiglia del tandem.

9.4 Feedback e teorema di Jackson

Fonte A: documento 8, pagine PDF 16–20.

Nel nodo con ricircolo, dopo il servizio il cliente rientra con probabilità p ed esce con $1 - p$. Il tasso delle visite è $\lambda_{\text{visite}} = r + p\lambda_{\text{visite}} = \frac{r}{1-p}$. Il processo di conteggio dei clienti ha nascite esterne a tasso r e morti effettive a tasso $(1 - p)\mu$ quando non è vuoto; le completazioni ricircolate sono cappi. La stabilità richiede $r < (1 - p)\mu$.

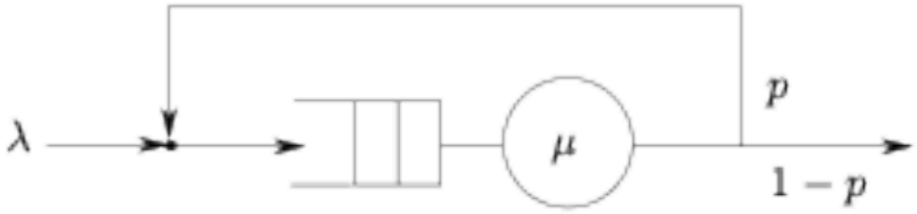


Figura 25: Coda con ricircolo probabilistico. Documento 8, pagina 16.

Il flusso che si presenta alla coda comprende clienti esterni e ritorni generati dal suo stesso passato: non si può dichiararlo Poisson indipendente dal sistema. La presenza del ricircolo non distrugge tuttavia automaticamente la forma prodotto stazionaria. È questo il contenuto rilevante del teorema di Jackson. L'osservazione delle lezioni sulla legge iperesponenziale si può precisare nel modello stazionario di questo singolo nodo, con $0 < r < (1 - p)\mu$. Sia J l'intervallo fra due arrivi **alla coda**, esterni o ricircolati. Dopo un tale arrivo la popolazione ha legge geometrica positiva di rapporto $\eta = \frac{r}{(1-p)\mu}$. Lo si verifica pesando lo stato finale $n \geq 1$ con i due flussi $r\pi_{n-1} + p\mu\pi_n = \mu\pi_n$ e rinormalizzando. Prima del prossimo arrivo, le sole transizioni non contate sono le uscite definitive; da questa popolazione geometrica il tempo per svuotarsi, ignorando i nuovi arrivi, è esponenziale di tasso $(1 - p)\mu - r$. Durante l'occupazione il tasso degli arrivi contati è $r + p\mu$. La competizione ha dunque tasso totale μ; se vince lo svuotamento si aggiunge un'attesa esponenziale di tasso r.

$$E\big[e^{-sJ}\big] = \frac{(r+p\mu)s + r\mu}{(s+\mu)(s+r)}, \quad P(J>t) = we^{-rt} + (1-w)e^{-\mu t}, \quad w = \frac{(1-p)\mu - r}{\mu - r}. \tag{179}$$

I pesi sono non negativi e sommano a 1, perciò la marginale è una miscela di due esponenziali. Si ha $E[J] = \frac{1-p}{r}$, coerentemente con il tasso delle visite. Questa marginale non autorizza a trattare gli intervalli come indipendenti. Le uscite **definitive**, invece, sono Poisson di tasso r: il numero totale evolve come una M/M/1 con tasso effettivo di servizio $(1-p)\mu$, alla quale si applica Burke in equilibrio.

Per una rete aperta con le ipotesi della sezione precedente, le equazioni di traffico risolubili e $\lambda_i < m_i\mu_i$ a ogni nodo, il teorema dà

$$\pi(\boldsymbol{n}) = \prod_{i=1}^{M} \pi_i(n_i), \tag{180}$$

dove π_i è la distribuzione della M/M/m_i isolata con carico λ_i. Il risultato vale anche con cicli nel routing. Esso riguarda la distribuzione di popolazione e non autorizza a sostituire tutte le traiettorie degli arrivi interni con processi Poisson indipendenti.

Una verifica algebrica ricostruita spiega la forma prodotto senza supporre tale indipendenza. Poniamo $c_i(n) = \mu_i \min(n, m_i)$ e $c_i(0) = 0$. I fattori locali soddisfano $\pi_i(n)c_i(n) = \lambda_i \pi_i(n-1)$. Per lo stato $\boldsymbol{n}$, un arrivo esterno a i proviene da $\boldsymbol{n} - \boldsymbol{e}_i$ e contribuisce, se $n_i > 0$, $\pi(\boldsymbol{n})c_i(n_i)\frac{r_i}{\lambda_i}$. Un trasferimento $j \to i$ proviene da $\boldsymbol{n} + \boldsymbol{e}_j - \boldsymbol{e}_i$ e contribuisce

$$\pi\big(\boldsymbol{n} + \boldsymbol{e}_j - \boldsymbol{e}_i\big)c_j\big(n_j + 1\big)p_{ji} = \pi(\boldsymbol{n})c_i\frac{n_i}{\lambda_i}\lambda_j p_{ji}. \tag{181}$$

La formula assume $n_i > 0$ per $i = j$ si possono aggiungere i cappi come transizioni virtuali identiche su entrambi i lati del bilancio. Sommando arrivi esterni e trasferimenti che riempiono la posizione i, il fattore fra parentesi è $r_i + \sum_j \lambda_j p_{ji} = \lambda_i$ e rimane $\pi(\boldsymbol{n})c_i(n_i)$. Le entrate provenienti da un cliente che esce dalla rete al nodo j contribuiscono invece $\pi(\boldsymbol{n})\lambda_j p_{j0}$. La verifica per rapporti assume $\lambda_i > 0$. Un nodo con traffico nullo e non alimentato da alcuna sorgente raggiungibile ha distribuzione concentrata in zero e può essere separato prima del calcolo; non si divide per un tasso nullo.

Sommando le equazioni di traffico su tutti i nodi si trova $\sum_j \lambda_j p_{j0} = \sum_i r_i$. L'entrata complessiva nello stato coincide quindi con $\pi(\boldsymbol{n})\big(\sum_i c_i(n_i) + \sum_i r_i\big)$, uguale all'uscita complessiva, con la stessa eventuale inclusione virtuale dei cappi. La normalizzazione separa le somme perché lo spazio aperto è un prodotto di $\mathbb{N}_0$ e ogni fattore è sommabile. Questa prova mostra dove entrano routing e stabilità.

Nell'esempio a tre nodi, l'ingresso esterno è solo r_1. Il nodo 1 ritorna a se stesso con p_{11}, va a 2 con p_{12} e va a 3 con $p_{13} = 1 - p_{11} - p_{12}$ il nodo 2 torna a 1 con $p_{21} = 1 - p_{22}$ oppure ricircola a 2. Dal nodo 3 si esce. La figura associa ciascun coefficiente alla sua freccia, evitando di scambiare gli indici.

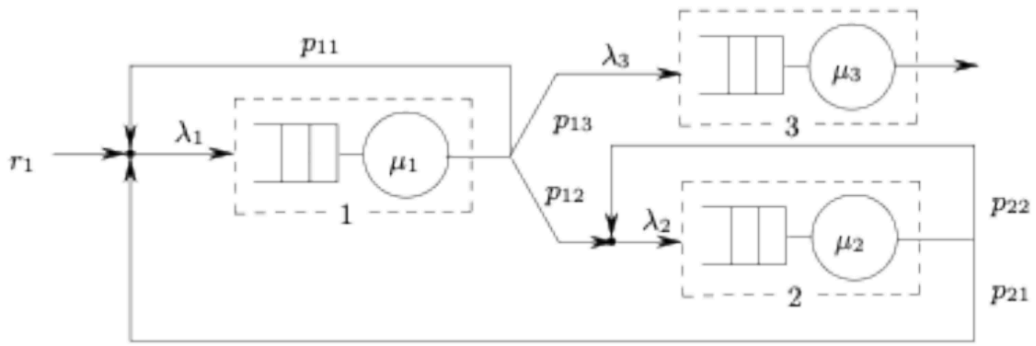


Figura 26: Rete aperta a tre nodi con ricircoli. Documento 8, pagina 2, ripresa a pagina 18.

$$\lambda_1 = r_1 + p_{11}\lambda_1 + p_{21}\lambda_2, \quad \lambda_2 = p_{12}\lambda_1 + p_{22}\lambda_2, \quad \lambda_3 = p_{13}\lambda_1. \tag{182}$$

Dalla seconda equazione $p_{21}\lambda_2 = p_{12}\lambda_1$. Sostituendo nella prima, $r_1 = (1 - p_{11} - p_{12})\lambda_1 = p_{13}\lambda_1$. Se $p_{13}, p_{21} > 0$,

$$\lambda_1 = \frac{r_1}{p_{13}}, \quad \lambda_2 = \frac{p_{12}}{p_{21}p_{13}} r_1, \quad \lambda_3 = r_1. \tag{183}$$

Con un servente per nodo, $\rho_i = \frac{\lambda_i}{\mu_i} < 1$ e $\pi(\boldsymbol{n}) = \prod_{i=1}^{3}(1-\rho_i)\rho_i^{n_i}$. Il numero medio totale si somma per linearità dell'attesa, senza bisogno di indipendenza per questa sola operazione, e Little sulla rete usa l'ingresso esterno:

$$E[X_1 + X_2 + X_3] = \sum_{i=1}^{3} \frac{\rho_i}{1-\rho_i}, \quad E[S_{\text{rete}}] = \frac{\sum_{i=1}^{3} E[X_i]}{r_1}. \tag{184}$$

I tassi interni contano visite ripetute: usarne la somma come tasso dei nuovi clienti della rete sottostimerebbe il tempo totale di attraversamento.

> **Nota tecnica A31.** Il documento 8, pagina 20, accenna a estensioni con arrivi dipendenti dalla popolazione totale o tassi di servizio dipendenti dal numero locale. Queste richiedono condizioni di compatibilità e fattori di equilibrio modificati; non garantiscono in generale la stessa indipendenza dei conteggi. La dipendenza locale del servizio si tratta con i prodotti $\frac{\lambda_i}{c_i(n)}$ sotto ipotesi appropriate. Non si estende la formula di Jackson ad arrivi arbitrariamente dipendenti dallo stato.

9.5 Dimensionamento del routing

Fonte A: documento 8, pagine PDF 21–26.

L'esercizio ha un nodo 1 con due serventi, ciascuno di tasso 20 al minuto, e un nodo 2 con un servente dello stesso tasso. Gli arrivi esterni al nodo 1 hanno tasso 2 al minuto. Dopo il nodo 1 si ritorna al medesimo nodo con probabilità p oppure si passa al nodo 2 con $1-p$; dal nodo 2 si esce. La figura distingue il ritorno dal trasferimento in avanti.

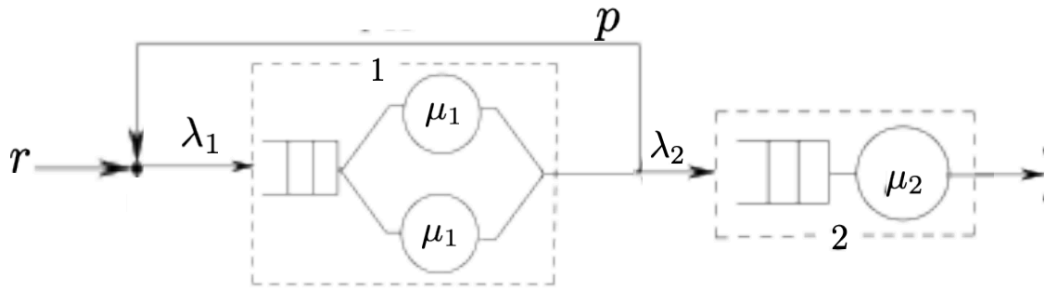


Figura 27: Rete con due serventi al primo nodo e routing da dimensionare. Documento 8, pagina 21.

Il bilancio dà $\lambda_1 = 2 + p\lambda_1$ e $\lambda_2 = (1-p)\lambda_1$, quindi

$$\lambda_1 = \frac{2}{1-p}, \quad \lambda_2 = 2, \quad \rho_1 = \frac{1}{20(1-p)}, \quad \rho_2 = \frac{1}{10}. \tag{185}$$

La stabilità del primo nodo richiede $p < .95$ quella del secondo è già soddisfatta. Aumentando p si aumenta il lavoro richiesto al primo nodo senza modificare il flusso netto verso il secondo. Il vincolo di stabilità va mantenuto durante la ricerca delle radici.

La soluzione delle lezioni uguaglia i numeri medi **totali**. Nel nodo 2, $E[X_2] = \frac{\rho_2}{1-\rho_2} = \frac{1}{9}$. Nel primo, usando la M/M/2,

$$\pi_{0,1} = \left(1 + 2\rho_1 + \frac{(2\rho_1)^2}{2(1-\rho_1)}\right)^{-1} = \frac{1-\rho_1}{1+\rho_1} = \frac{19-20p}{21-20p}. \tag{186}$$

Sostituendo questa normalizzazione nella media si trova

$$E[X_1] = 2\rho_1 + 2\frac{\rho_1^3}{1-\rho_1^2} = 2\frac{\rho_1}{1-\rho_1^2} = 40\frac{1-p}{(19-20p)(21-20p)}. \tag{187}$$

Uguagliando a $\frac{1}{9}$ si ottiene $360(1-p) = (19-20p)(21-20p)$ e dunque

$$400p^2 - 440p + 39 = 0, \quad p = \frac{11 \pm \sqrt{82}}{20}. \tag{188}$$

La radice ammissibile è $\frac{11-\sqrt{82}}{20} \approx .097230743$ l'altra supera 1. Il valore arrotondato .097 riportato nelle lezioni è coerente con l'obiettivo di uguagliare i numeri totali.

Il testo dell'esercizio parla però di clienti **in attesa**. Se si intende la sola attesa, il servizio va escluso da entrambi i nodi: $E\big[X_{Q,2}\big] = \frac{\rho_2^2}{1-\rho_2} = \frac{1}{90}$ e $E\big[X_{Q,1}\big] = 2\frac{\rho_1^3}{1-\rho_1^2}$. Occorre allora risolvere

$$2\frac{\rho_1^3}{1-\rho_1^2} = \frac{1}{90}, \quad \rho_1 = \frac{1}{20(1-p)}, \quad 0 \le p < .95. \tag{189}$$

La soluzione numerica è $p \approx .7147374684$. La funzione a sinistra cresce strettamente con ρ_1 su $(0,1)$, e ρ_1 cresce con p, perciò la radice ammissibile è unica. Le due soluzioni rispondono a due obiettivi diversi, non a due metodi alternativi per lo stesso obiettivo.

> **Nota tecnica A32.** Il documento 8, pagina 21, richiede uguaglianza del numero medio «in attesa», ma nelle pagine 22–26 usa $E[X]$ comprensivo del servizio. La soluzione .097 è corretta per i numeri totali; per la sola attesa si ottiene circa .714737. L'ambiguità del testo originale è dichiarata, e le due interpretazioni sono svolte separatamente.

9.6 Reti chiuse e Gordon–Newell

Fonte A: documento 8, pagine PDF 27–30.

Una rete chiusa ha $r_i = 0$ e routing stocastico, $\sum_j p_{ij} = 1$. Nessun cliente entra o esce e la popolazione totale è fissata:

$$\mathcal{S}_N = \left\{ \boldsymbol{n} \in \mathbb{N}_0^M : \sum_{i=1}^{M} n_i = N \right\}, \quad |\mathcal{S}_N| = \binom{M+N-1}{M-1}. \tag{190}$$

Il conteggio si ricava distribuendo N elementi indistinguibili in M comparti, equivalenti a N simboli separati da $M-1$ divisori. Lo spazio è finito anche se i singoli buffer non hanno una capacità imposta. Il vincolo di somma impedisce in generale l'indipendenza dei conteggi: sapere che tutti i clienti sono a un nodo determina che gli altri sono vuoti.

Le equazioni di traffico sono ora omogenee:

$$\lambda_i = \sum_{j=1}^{M} \lambda_j p_{ji}, \quad \boldsymbol{\lambda} = \boldsymbol{\lambda} R. \tag{191}$$

Se il routing è irriducibile, determinano un vettore positivo a meno di un fattore comune e hanno rango $M-1$. Le λ_i così scelte sono frequenze relative di visita, non throughput assoluti già determinati. La popolazione N e i tempi di servizio fissano successivamente la scala fisica. Con routing riducibile possono esistere più componenti e vincoli di popolazione separati: la conclusione «una sola costante libera» richiede l'irriducibilità.

Per nodi a un solo servente di tasso $\mu_i > 0$, poniamo $\rho_i = \frac{\lambda_i}{\mu_i}$. Il teorema di Gordon–Newell fornisce

$$\pi(\boldsymbol{n}) = \frac{1}{C(N)} \prod_{i=1}^{M} \rho_i^{n_i}, \quad C(N) = \sum_{\boldsymbol{n} \in \mathcal{S}_N} \prod_{i=1}^{M} \rho_i^{n_i}. \tag{192}$$

La somma è finita; non serve $\rho_i < 1$. I parametri sono pesi relativi, non utilizzazioni di nodi aperti. Moltiplicare tutte le λ_i per $c > 0$ moltiplica ogni peso per c^N e moltiplica $C(N)$ dello stesso fattore: la probabilità finale resta uguale.

La verifica ricostruita del bilancio esplicita il vincolo sugli indici. Il flusso uscente, includendo eventuali cappi come eventi virtuali, è $\pi(\boldsymbol{n}) \sum_{i:n_i>0} \mu_i$. Per entrare al nodo i da un servizio al nodo j, lo stato precedente è $\boldsymbol{n} + \boldsymbol{e}_j - \boldsymbol{e}_i$; deve essere $n_i > 0$ perché il cliente sottratto al nodo di destinazione sia presente nello stato finale. Il rapporto dei pesi è

$$\frac{\pi(\boldsymbol{n} + \boldsymbol{e}_j - \boldsymbol{e}_i)}{\pi(\boldsymbol{n})} = \frac{\rho_j}{\rho_i}. \tag{193}$$

Il flusso entrante diviso per $\pi(\boldsymbol{n})$ è quindi

$$\sum_{i:n_i>0} \sum_j \mu_j p_{ji} \frac{\rho_j}{\rho_i} = \sum_{i:n_i>0} \frac{1}{\rho_i} \sum_j \lambda_j p_{ji} = \sum_{i:n_i>0} \mu_i. \tag{194}$$

La seconda uguaglianza usa il traffico relativo. Si verifica dunque il bilancio globale; se si escludono i cappi $i = j$, lo stesso contributo viene sottratto a entrambi i lati. La normalizzazione completa la soluzione. Il risultato ha forma prodotto nei pesi, ma la costante comune e il vincolo di popolazione accoppiano i nodi.

> **Nota tecnica A33.** Nel documento 8, pagina 28, il traffico chiuso usa un ordine d'indici non coerente con il routing: occorre p_{ji}. Nelle pagine 29–30 il predecessore $\boldsymbol{n} + \boldsymbol{e}_j - \boldsymbol{e}_i$ richiede $n_i > 0$, non $n_j > 0$. I coefficienti sono tassi di flusso, non probabilità di una transizione in un intervallo fissato. Le correzioni sono certe.

9.7 Esempio chiuso a tre nodi

Fonte A: documento 8, pagine PDF 31–34.

Due clienti circolano fra tre nodi a un servente: dal nodo 1 vanno a 2 con probabilità p e a 3 con $1 - p$; da 2 e 3 tornano sicuramente a 1. La figura specifica i due rami e il ritorno comune.

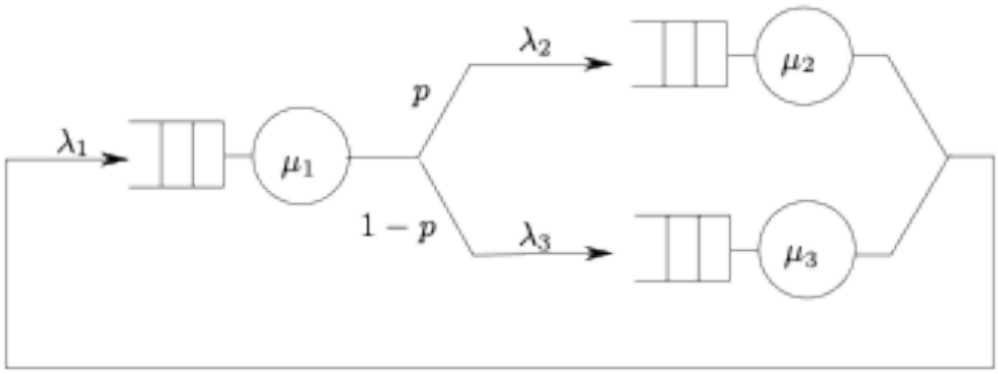


Figura 28: Topologia chiusa a tre nodi. Documento 8, pagina 2, ripresa nell'esempio a pagina 31.

Le equazioni relative sono $\lambda_1 = \lambda_2 + \lambda_3$, $\lambda_2 = p\lambda_1$, $\lambda_3 = (1-p)\lambda_1$. Si può scegliere per comodità $\lambda_1 = \mu_1$, ottenendo

$$\rho_1 = 1, \quad \rho_2 = p\frac{\mu_1}{\mu_2}, \quad \rho_3 = (1-p)\frac{\mu_1}{\mu_3}. \tag{195}$$

I sei stati sono $(2,0,0)$, $(1,1,0)$, $(1,0,1)$, $(0,2,0)$, $(0,1,1)$ e $(0,0,2)$. I rispettivi pesi sono $1, \rho_2, \rho_3, \rho_2^2, \rho_2\rho_3, \rho_3^2$, quindi

$$C(2) = 1 + \rho_2 + \rho_3 + \rho_2^2 + \rho_2\rho_3 + \rho_3^2. \tag{196}$$

In termini dei parametri fisici, il termine misto è $p(1-p)\frac{\mu_1^2}{\mu_2\mu_3}$, i termini lineari sono $p\frac{\mu_1}{\mu_2}$ e $(1-p)\frac{\mu_1}{\mu_3}$, e i quadratici sono i loro quadrati. Questa enumerazione ricostruisce tutti i termini della costante e controlla che nessuno stato sia stato omesso.

Con $p = .5$, $\mu_1 = 4$, $\mu_2 = 1$, $\mu_3 = 2$, si ha $\rho_2 = 2$, $\rho_3 = 1$ e $C(2) = 11$. La distribuzione è

$$\pi(0,1,1) = \pi(1,1,0) = \frac{2}{11}, \quad \pi(1,0,1) = \pi(2,0,0) = \pi(0,0,2) = \frac{1}{11}, \quad \pi(0,2,0) = \frac{4}{11}. \tag{197}$$

La somma è $\frac{2+2+1+1+1+4}{11} = 1$. La probabilità che il nodo 1 sia vuoto è $\frac{4+2+1}{11} = \frac{7}{11}$, per cui l'utilizzazione del suo servente è $\frac{4}{11}$. Il throughput fisico al nodo 1 è dunque $\mu_1 \times \frac{4}{11} = \frac{16}{11}$ le visite ai nodi 2 e 3 hanno entrambi tasso $\frac{8}{11}$. Questi tassi fisici non coincidono con la scelta arbitraria $\lambda_1 = \mu_1 = 4$ fatta per costruire i pesi: il loro rapporto è quello imposto dal routing.

Il grafo originale elenca i sei stati e associa a ogni arco un tasso. Per esempio da 200 una completazione del nodo 1 porta a 110 con tasso $p\mu_1$ o a 101 con $(1-p)\mu_1$; da 020 il nodo 2 porta a 110 con μ_2. I tassi non sono moltiplicati per il numero di clienti in un nodo a un solo servente: anche con due clienti ne viene servito uno alla volta.

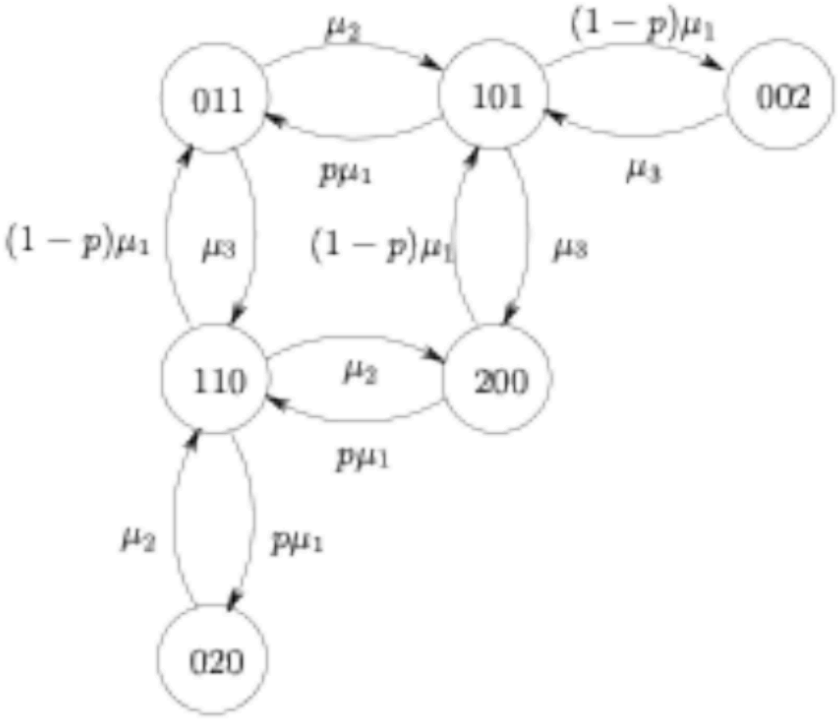


Figura 29: Grafo di transizione dell'esempio con due clienti. Documento 8, pagina 34.

Nota tecnica A34. Il documento 8, pagina 31, annuncia correttamente sei stati ma nell'elenco ne scrive cinque: manca $(0,0,2)$. A pagina 33 il dato finale è ripetuto come $\mu_1 = 2$ il risultato $C = 11$ e i pesi richiedono $\mu_3 = 2$, con $\mu_1 = 4$. L'omissione dello stato e il refuso d'indice sono corretti esplicitamente.

Il corso conduce così dalla definizione di stato alla forma prodotto attraverso una sequenza di ipotesi controllabili. Gli automi descrivono ciò che può accadere, i clock stabiliscono quando accade, le leggi stocastiche descrivono l'incertezza e le catene di Markov rendono trattabili i casi senza memoria. Nelle code e nelle reti, conservazione dei clienti e conservazione della probabilità trasformano tali modelli in strumenti per il dimensionamento. Ogni applicazione deve ripercorrere questo ordine: confine, stato, eventi, leggi temporali, esistenza dell'equilibrio e infine prestazioni.

Fonti e tracciabilità

La fonte principale dell'intera dispensa è il materiale didattico di Paolo Salaris per il corso di Modellistica e Simulazione dei Processi di Produzione Discreti dell'Università di Pisa. Gli identificatori usati nelle note di provenienza corrispondono ai seguenti documenti. Tutte le pagine sono state lette in testo e attraverso la loro resa grafica; le ripetizioni sono integrate nelle sezioni concettuali, non replicate come pagine autonome.

ID	Documento originale	Pagine
0	Less0_Sistemi&Modelli.pdf	36
1	Less1_Linguaggi&Automi.pdf	51
2	Less2_SEDTemporizzati.pdf	25
3	Less3_SEDStocasticiTemporizzati_1.pdf	14
4	Less3_SEDStocasticiTemporizzati_2.pdf	47
5	Less4_Catene di Markov_TD.pdf	78
6	Less5_Catene di Markov_TC.pdf	44
7	Less6_Teoria delle Code.pdf	78
8	Less7_Reti di Code.pdf	34
Totale		407

Tabella 9: Corpus di riferimento; la numerazione identifica i PDF, non la numerazione dei capitoli.

Le fonti esterne seguenti sono state consultate il 21 ottobre 2026 per chiarimenti circoscritti agli argomenti introdotti nelle lezioni. I collegamenti portano ai documenti effettivamente accessibili, senza attribuire pagine o edizioni non verificate.

P. W. Glynn, A GSMP Formalism for Discrete Event Systems, Proceedings of the IEEE, vol. 77, n. 1, 1989. Testo dell'articolo. Consultate le sezioni II–V per il ruolo dello stato interno e dei clock; utilizzato nel capitolo 4. La cartella web contiene «1992», ma la data stampata nell'articolo è 1989.

P. Glasserman e D. D. Yao, Generalized Semi-Markov Processes: Antimatroid Structure and Second-Order Properties, Mathematics of Operations Research, vol. 17, n. 2, 1992. Testo dell'articolo. Consultata la sezione 2.1 per controllare la semantica dei clock persistenti, nuovi e interrotti. Non sono introdotti gli argomenti ulteriori dell'articolo.

W. Whitt, Continuous-Time Markov Chains, note universitarie, Columbia University, 19 dicembre 2006. Testo delle note. Consultate le sezioni 3.4 e 4 per uniformizzazione e distinzione fra legge invariante, catena incorporata e occupazione nel tempo; richiamo esterno nel capitolo 7.

A. R. Odoni, Queueing Systems: Lecture 3, MIT OpenCourseWare, 18 ottobre 2006. Materiale ufficiale. Consultata in particolare la pagina PDF 5 per il richiamo alla proprietà PASTA, utilizzato nel capitolo 8. Non si estende il programma alla M/G/1 sviluppata in altre pagine del documento.

F. Kelly ed E. Yudovina, Lecture Notes on Stochastic Networks, versione disponibile sul sito del Statistical Laboratory di Cambridge. Testo consultato. Utilizzata la sezione 2.1, pagine stampate 22–23, per completare la dimostrazione di Burke mediante reversibilità. L'anno di questa specifica versione del file non viene dedotto dalla data di indicizzazione web.

N. Berestycki e P. Sousi, Applied Probability, University of Cambridge, 18 marzo 2015. Testo delle note. Consultata la sezione 3.4 come controllo incrociato dell'ipotesi di equilibrio e dell'argomento di inversione temporale per Burke. Nessuna estensione ai capitoli estranei al corso è stata incorporata.

Le slide citano inoltre Hopcroft, Motwani e Ullman, **Introduction to Automata Theory, Languages, and Computation**, terza edizione, 2006, e un esercizio tratto da Cassandras. Questi riferimenti sono riportati come provenienza dichiarata dal materiale del docente: i rispettivi libri non sono stati consultati direttamente per questa dispensa, né sono attribuite loro pagine ulteriori non verificate.

I file di verifica allegati completano la tracciabilità: `copertura_slide.csv` associa ogni pagina alla sezione pertinente; `equazioni.csv` identifica i gruppi di relazioni numerate e i relativi sorgenti; `figure.csv` registra i ritagli; `anomalie.md` riunisce le note tecniche; `fonti.md` descrive gli usi delle fonti esterne. Le incertezze del materiale originale sono mantenute visibili: natura dell'azione sul pendolo, campioni mancanti nell'esercizio dei clock e distinzione fra attesa e popolazione totale nell'esercizio sul routing.